

ESTUDIO DE SEGMENTACIÓN DE CLIENTES EN MARKETING BANCARIO

Un análisis multivariante de las características y patrones de comportamiento de los clientes

Claudia Aguilar, María del Pilar Forero, Yéssica Lourido, Carmen Palacios y Cristina Tuá

Universitat Politècnica de Catalunya

Facultat de Matemàtiques i Estadística

27 de Febrero de 2026

ÍNDICE

Definición del proyecto **4**

Fuente de los datos . . . 4

Contexto de los datos . . . 5

Estructura de la matriz de datos . . . 5

Plan de trabajo **11**

Descomposición de tareas y diagrama de Gantt . . . 11

Escaleta de distribución de tareas . . . 12

Plan de riesgos . . . 13

Estructura de los datos y descriptiva **14**

Motivación del trabajo . . . 14

Descripción formal de la estructura de los datos . . . 14

Listado de variables y su información (Metadata) . . . 16

Descriptiva univariante **18**

Analisis descriptivo . . . 18

Descripción del proceso de preprocesamiento . . . 24

Descriptiva bivariante **27**

Análisis descriptivo . . . 27

Variables cuantitativas . . . 27

Variables categóricas . . . 28

Variable numérica y variable categórica. . . . 32

Descripción de las principales dificultades . . . 33

Principales conocimientos obtenidos del análisis bivariante . . . 33

Clustering **34**

Particional . . . 34

Jerárquico . . . 36

Árbol jerárquico . . . 37

Profiling **39**

Visualizar las relaciones entre parejas de variables y clases . . . 39

Fase 1: Significación de las variables . . . 39

Fase 2: Caracterización de los clústers . . . 41

Visualizaciones en mapas de clases . . . 42

ACP **46**

Resultados principales del análisis . . . 46

Contribución de las variables . . . 50

Calidad de la representación . . . 51

Descripción de las dimensiones . . . 52

Interpretación de las relaciones entre variables y entre individuos . . . 52

Conclusiones . . . 55

ACM **56**

Resultados principales del análisis . . . 56

Comprobación de individuos y carcaterísticas . . . 58

Variables en ACM . . . 58

Coordenadas de las categorías . . . 60

Calidad de la representación . . . 60

Contribuciones . . . 61

Individuos . . . 62

Descripción de dimensiones . . . 65

Conclusiones . . . 65

Encontrar las coincidencias y discrepancias con ACP . . . 66

FAMD **67**

Resultados principales del análisis . . . 67

Interpretar las categorias . . . 68

Interpretar las relaciones . . . 71

Clustering jerárquico **72**

Describir la matriz y mostrar el árbol . . . 72

Profiling de los clusters . . . 74

Compararación de resultados . . . 77

Análisis discriminante **79**

Resultados del análisis 79

Matriz de confusión e interpretación 80

Discriminador o clasificador alternativo **82**

Matriz de confusión 82

Importancia de las variables 83

Comparación con el análisis discriminate y justificación de las diferencias 83

Análsis comparativa **85**

Disusión general 85

Análisis de las coincidencias y divergencias entre métodos 85

Conclusiones generales **87**

Plan de trabajo real 87

Referencias **89**

Definición del proyecto

Fuente de los datos

Los datos utilizados en este trabajo provienen del conjunto de datos de Bank Marketing, encontrados en el repositorio UCI Machine Learning Repository (UCI Machine Learning Repository 2012). El conjunto de datos se puede consultar en la siguiente web: https://archive.ics.uci.edu/ml/datasets/Bank+Marketing

Además, los datos han estado descritos y analizados en profundidad en (Moro, Cortez, and Rita 2014), que es la referencia principal de donde hemos extraído la información del dataset.

Contexto de los datos

El conjunto de datos hace referencia a campañas de marketing realizadas por una entidad bancaria portuguesa. Están basados principalmente por llamadas telefónicas a los clientes. El objetivo de las campañas fue promocionar depósitos a cierto plazo. En muchos casos era necesario contactar varias veces con un mismo cliente para saber si, finalmente, quería el depósito.

Las variables del dataset recogen información demográfica de los clientes (la edad, la profesión o el nivel educativo), además de datos relacionados con la llamada o el marketing (duración de la llamada o número de contactos). También observamos algunos indicadores económicos agregados (IPC o Euríbor).

El objetivo del trabajo es explorar y comprender el comportamiento de los clientes a partir de sus características socioeconómicas y de la interacción con el banco. Para ello utilizaremos técnicas de análisis multivariante que permitan reducir la dimensionalidad, identificar patrones y caracterizar diferentes perfiles de clientes.

Estructura de la matriz de datos

El primer paso es leer los datos para obtener el dataset:

```
library(readxl)
dades<-read.csv2('bank-additional-full.csv',header=TRUE,sep=";")
nrow(dades)
```

```
## [1] 41188
```

Observamos que nuestro dataframe tiene 41188 filas, por tanto, cogemos una muestra aleatoria para poder trabajar de forma más sencilla con estos.

```
set.seed(123)
muestra <- dades[sample(nrow(dades), 5000), ]
```

Intentamos observar el dataframe para ver que tipo de variables tenemos y si se han leído correctamente:

```
str(muestra)
```

```
## 'data.frame':    5000 obs. of  21 variables:
##  $ age           : int  34 42 30 33 36 27 39 31 56 24 ...
##  $ job       : chr  "entrepreneur" "blue-collar" "blue-collar" "services" ...
##  $ marital       : chr  "married" "divorced" "married" "married" ...
##  $ education    : chr  "high.school" "basic.9y" "basic.4y" "high.school" ...
##  $ default       : chr  "unknown" "no" "no" "no" ...
##  $ housing       : chr  "no" "no" "yes" "unknown" ...
##  $ loan          : chr  "no" "no" "no" "unknown" ...
##  $ contact      : chr  "telephone" "cellular" "cellular" "cellular" ...
##  $ month         : chr  "may" "apr" "apr" "aug" ...
```

```
##  $ day_of_week   : chr  "wed" "mon" "mon" "thu" ...
##  $ duration      : int  436 20 42 240 136 342 79 459 354 18 ...
##  $ campaign      : int  1 2 3 2 2 1 1 4 2 8 ...
##  $ pdays         : int  999 999 999 999 999 999 999 999 999 999 ...
##  $ previous      : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ poutcome    : chr  "nonexistent" "nonexistent" "nonexistent" "nonexistent" ...
##  $ emp.var.rate  : chr  "1.1" "-1.8" "-1.8" "-2.9" ...
##  $ cons.price.idx: chr  "93.994" "93.075" "93.075" "92.201" ...
##  $ cons.conf.idx : chr  "-36.4" "-47.1" "-47.1" "-31.4" ...
##  $ euribor3m     : chr  "4.859" "1.405" "1.405" "0.873" ...
##  $ nr.employed   : chr  "5191" "5099.1" "5099.1" "5076.2" ...
##  $ y             : chr  "no" "no" "no" "no" ...
```

Observamos que las variables no están categorizadas correctamente, por tanto transformamos esas variables a sus categorías correctas.

```
# Convertimos las siguientes variables en numéricas:
vars_num <- c("emp.var.rate","cons.price.idx","cons.conf.idx",
              "euribor3m","nr.employed")

muestra[vars_num] <- lapply(muestra[vars_num], function(x)
  as.numeric(as.character(x))
)


# También convertimos en factor las que deberian ser factores:
vars_factor <- c("job","marital","education","contact",
                 "month","day_of_week","poutcome",
                 "default","housing","loan","y")


muestra[vars_factor] <- lapply(muestra[vars_factor], factor)
```

```
varTypes <- sapply(muestra, class)

# Definimos lo que es una variable numérica
varNum <- names(varTypes)[which(varTypes %in% c("integer", "numeric"))]

# Seleccionamos las variables numéricas
varNum <- muestra %>%
  select(where(is.numeric)) %>%
  names
```

Las variables numéricas de nuestro estudio son: age, duration, campaign, pdays, previous, emp.var.rate, cons.price.idx,

cons.conf.idx, euribor3m, nr.employed.

```
# Definimos el concepto de categórica
varCat <- names(varTypes)[which(varTypes %in% c("factor", "character"))]

# Seleccionamos variables categóricas
varCat <- muestra %>%
  select(where(is.factor) | where(is.character)) %>%
  names
```

Las variables categóricas de nuestro estudio son: job, marital, education, default, housing, loan, contact, month, day_of_week, poutcome, y.

A continuación, presentamos una descripción de cada variable y su interpretación dentro del contexto económico:

- Age: edad (numérico).
- Job: tipo de trabajo (categórico): “administrativo”, “desconocido”, “desempleado”, “dirección”, “empleada del hogar”, “emprendedor”, “estudiante”, “obrero”, “autónomo”, “jubilado”, “técnico”, “servicios”.
- Marital: estado civil (categórico): “casado”, “divorciado”, “soltero” (nota: “divorciado” incluye divorciados o viudos).
- Education: nivel educativo (categórico): “desconocido”, “secundaria”, “primaria”, “superior”.
- Default: ¿tiene crédito en mora/incumplimiento? (binario): “sí”, “no”.
- Balance: saldo medio anual, en euros (numérico).
- Housing: ¿tiene préstamo hipotecario? (binario): “sí”, “no”.
- Loan: ¿tiene préstamo personal? (binario): “sí”, “no”.
- Contact: tipo de comunicación de contacto (categórico): “desconocido”, “teléfono fijo”, “móvil”.
- Day: día del mes del último contacto (numérico).
- Month: mes del último contacto (categórico): “ene”, “feb”, “mar”, …, “nov”, “dic”.
- Duration: duración del último contacto, en segundos (numérico).
- Campaign: número de contactos realizados durante esta campaña para este cliente (numérico, incluye el último contacto).
- Pdays: número de días desde el último contacto en una campaña anterior (numérico, -1 significa que no fue contactado previamente).
- Previous: número de contactos realizados antes de esta campaña para este cliente (numérico)
- Poutcome: resultado de la campaña de marketing anterior (categórico): “desconocido”, “otro”, “fracaso”, “éxito”.

- y: ¿el cliente ha contratado un depósito a plazo? (binario): “sí”, “no”.

Al leer la estructura la web de la que provienen los datos, observamos que a los “NA” se les llama **unknown**, por tanto, convertimos estos a NA.

```
muestra[muestra == "unknown"] <- NA
```

También procedemos a transformar las variables binarias (Yes/No) a respuesta (1/0).

```
library(dplyr)
muestra <- muestra %>%
  mutate(
    y = case_when(
      y == "yes" ~ 1,
      y == "no"  ~ 0
    ),
    contact = case_when(
      contact == "cellular"  ~ 1,
      contact == "telephone" ~ 0
    ),
    default = case_when(
      default == "yes" ~ 1,
      default == "no"  ~ 0
    ),
    housing = case_when(
      housing == "yes" ~ 1,
      housing == "no"  ~ 0
    ),
    loan = case_when(
      loan == "yes" ~ 1,
      loan == "no"  ~ 0
    ),
  )
```

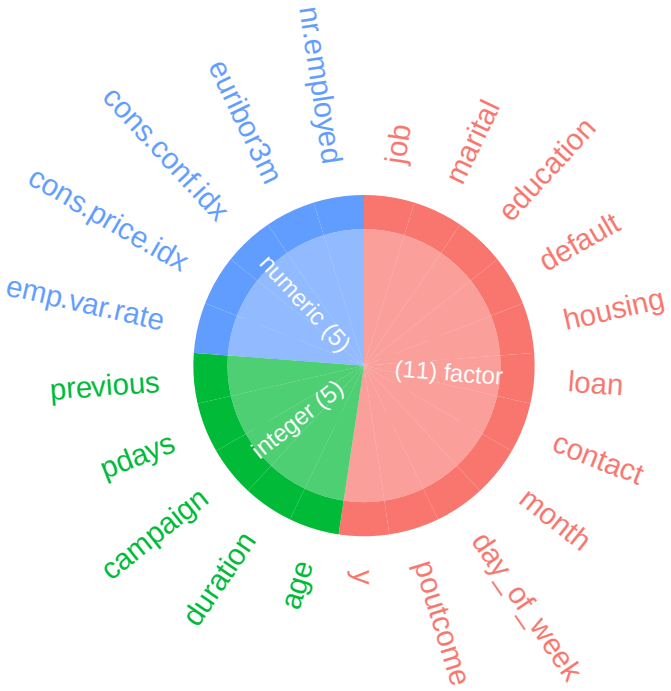
```
muestra <- muestra %>%
  mutate(across(c(y, contact, default, housing, loan),
                ~ factor(.x, levels = c(0,1))))
```

Ahora que ya tenemos nuestros datos finales, vamos a hacer una breve descripción y conteo de estos:

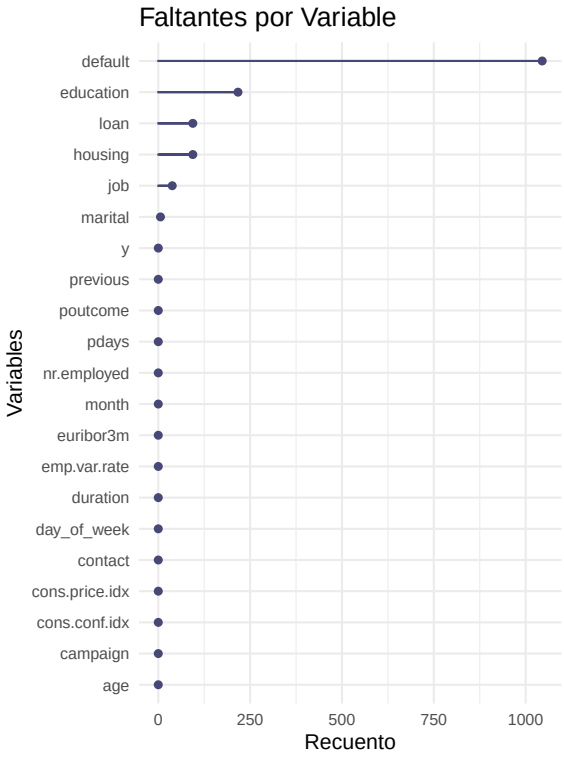
Table 1: ESTRUCTURA MATRICIAL

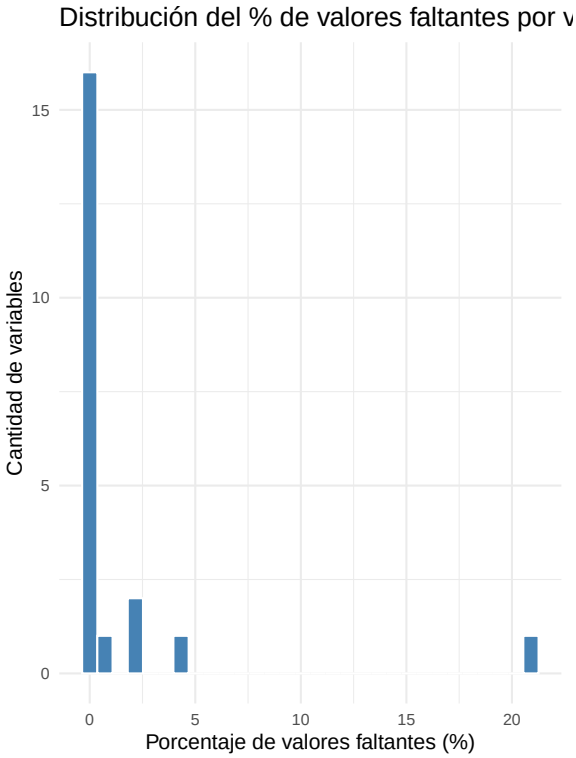
Numero_Columnas	Numero_Filas	Numero_NA_total	Filas_con_NA	Porcentaje_NA_total
21	5000	1494	1282	1.422857

```
inspect_types(muestra) %>% show_plot()
```



Añadimos también los siguientes gráficos que describen la distribución de los valores faltantes.


Faltantes por Variable
default
education
loan
housing
job
marital
y
previous
poutcome
pdays
nr.employed
month
euribor3m
emp.var.rate
duration
day_of_week
contact
cons.price.idx
cons.conf.idx
campaign
age
Variables
0
250
500
750
1000
Recuento


Distribución del % de valores faltantes por v
15
10
5
0
Cantidad de variables
0
5
10
15
20
Porcentaje de valores faltantes (%)

Plan de trabajo

Descomposición de tareas y diagrama de Gantt

Presentamos la secuencia temporal de las tareas mediante un diagrama de Gantt, agrupando los bloques de trabajo según las fechas límite originales:



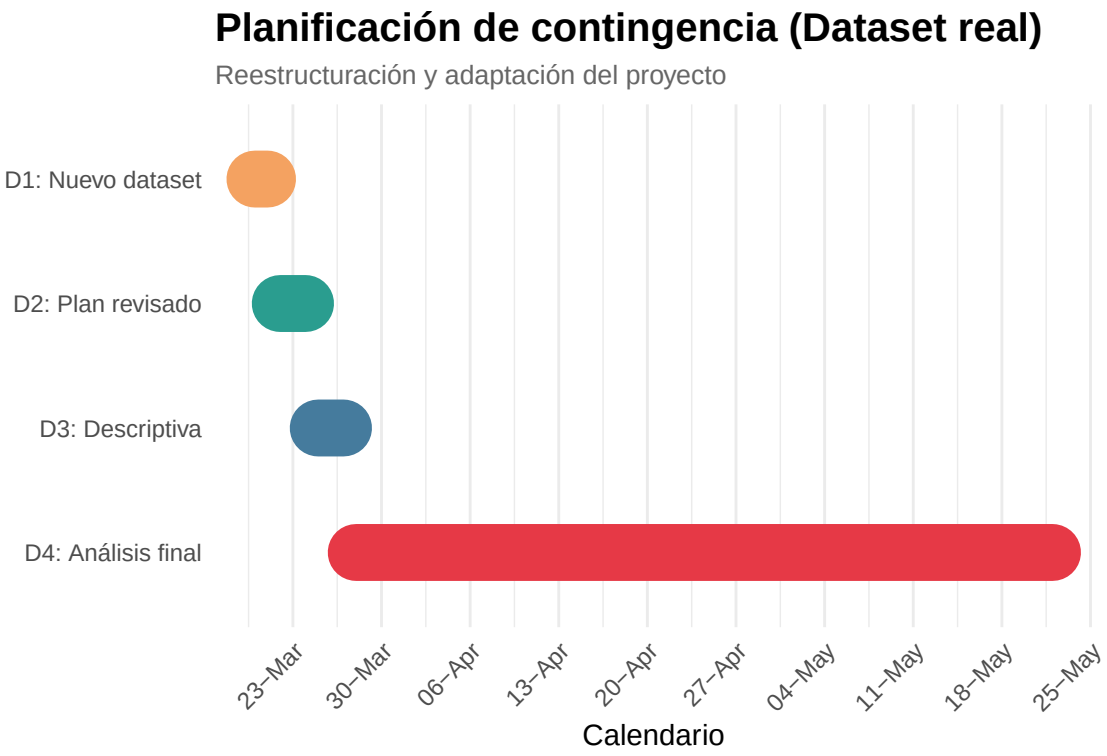
Durante la fase de análisis descriptivo y bivariante, detectamos anomalías estructurales en la base de datos original que comprometían la validez del estudio.

Nota Técnica: Observamos que las variables categóricas presentaban una distribución de frecuencias perfectamente uniforme ($P(X =$

así como una ausencia total de colinealidad en el análisis bivariante. Estas características son indicativas de un dataset sintético generado aleatoriamente, carente de las estructuras de correlación necesarias para aplicar técnicas de reducción de la dimensionalidad (PCA) o algoritmos de partición (Clustering) con sentido estadístico.

Debido a esto, nosotras decidimos que la mejor opción era sustituir la fuente de datos por una base real, lo que requirió una re-ejecución de las fases D1 y D2 en un tiempo adaptado.

A continuación, mostramos el nuevo diagrama los plazos ajustados para las entregas pendientes:



Escaleta de distribución de tareas

La realización del proyecto se ha organizado mediante una distribución equilibrada de las tareas entre los miembros del grupo, teniendo en cuenta las diferentes fases del análisis propuestas.

En primer lugar, las tareas de selección, modificación y descripción del conjunto de datos han estado realizadas conjuntamente por todos los integrantes del grupo, por tal de asegurar una comprensión del contexto de los datos y sus objetivos.

Posteriormente, se detalla la distribución de tareas correspondientes a las entregas 3 (E3) y 4 (E4) junto con su responsable:

Table 2: Cuadrícula de asignación de tareas del proyecto

MIEMBROS	Carmen	Yéssica	Pilar	Cristina	Claudia
E3:Estructura de los datos y descriptiva	X				
E3:Descriptiva univariante		X			
E3:Descriptiva bivariante			X		
E3:Clustering				X	
E3:Profiling					X
E4:ACP y ACM	X				
E4:AMD		X			
E4:Análisis discriminante				X	
E4:Discriminador alternativo			X		
E4:Clustering jerárquico sobre FAMD					X

Los apartados finales de análisis comparativo, conclusiones generales y la elaboración del plan de trabajo final se

realizarán de manera conjunta por todos los miembros del grupo, con el objetivo de integrar los distintos resultados obtenidos y asegurar una interpretación global del proyecto.

Cabe destacar que esta distribución de tareas puede estar sujeta a modificaciones en función de las necesidades del proyecto o de imprevistos que puedan surgir a lo largo de su desarrollo. En caso de que se produzca algún cambio en la asignación de tareas, este se indicará en la propia entrega.

Plan de riesgos

Los principales riesgos a los que nos enfrentamos en la realización de este trabajo son los siguientes, añadiendo los pasos que seguiremos para solventarlos:

1. **Carga computacional**: El uso de 5.000 observaciones puede ralentizar los algoritmos de clustering jerárquico. *Solución:* Optimizaremos el uso de memoria mediante métodos particionales previos o el uso de funciones con una mayor capacidad computacional en R.

2. **Sesgo por datos faltantes (NAs) artificiales**: Al haber introducido NAs de forma aleatoria para cumplir los requisitos, existe el riesgo de perder relaciones multivariantes clave. *Solución:* Si en la fase D3 el análisis descriptivo muestra distorsiones graves, reajustaremos la semilla (`set.seed`) de generación.

3. **Inconsistencia o errores en los datos**: El registro de nuestros datos puede contener distintos errores como tasas demasiado altas o totalmente incoherentes afectando al análisis. *Solución:* Detectar los posibles outliners, verificar los valores sospechosos y corregirlos si conocemos los valores reales o simplemente eliminarlos mediante distintas técnicas estadísticas.

4. **Multicolinealidad**: Nuestra base de datos contiene un elevado número de variables, lo que puede provocar una fuerte correlación entre sí, afectando a modelos estadísticos de regresión al no ser capaz de diferenciar qué variable realmente esta influenciando. *Solución:* La matriz de correlación y los VIF's nos permiten detectar la multicolinealidad en nuestros datos. Eliminar, combinar o usar PCA sobre la base de datos nos permitirá eliminar la multicolinealidad.

5. **Ruido en los datos**: Ante la gran cantidad de información con la que estamos trabajando, es sencillo encontrar observaciones que nos impidan detectar los patrones en los datos dada su aleatoriedad. *Solución:* Entre las posibles soluciones está el suavizado de datos, la agrupación por categorías y la eliminación de los valores extremos.

6. **Divergencias en la interpretación de resultados**: Existe el riesgo de que las estructuras relacionales identificadas en los métodos factoriales (ACP y ACM) no coincidan visualmente con la partición de grupos del Clustering, generando conclusiones contradictorias. *Solución:* Añadiremos una fase de validación cruzada mediante el análisis FAMD para actuar como puente entre variables de distinta naturaleza. También unificaremos los criterios de "profiling" de los clústeres mediante etiquetas descriptivas consensuadas, asegurándonos de que la conclusión final sea coherente y robusta.

Estructura de los datos y descriptiva

Motivación del trabajo

El objetivo de este trabajo es analizar los factores que influyen en el éxito de las campañas de marketing bancario, en concreto, en la suscripción de depósitos. El conjunto de datos incluye información sobre características de los clientes, su situación financiera, así como variables relacionadas con la campaña telefónica realizada y el contexto socioeconómico del momento.

El análisis de estos datos permite estudiar posibles relaciones entre el perfil del cliente, las condiciones económicas y la probabilidad de éxito de una campaña de marketing. Además, también permite identificar patrones de comportamiento en los clientes y factores determinantes en la toma de decisiones para futuras campañas de marketing.

Descripción formal de la estructura de los datos

El conjunto de datos utilizados proviene de la base de datos Bank Marketing, encontrados en el repositorio UCI Machine Learning Repository (UCI Machine Learning Repository 2012). El dataset contiene 41.188 observaciones y 21 variables.

Por una parte, cada fila / observación representa un cliente contactado durante la campaña comercial, que se llevó a cabo de manera telefónica, realizada por una entidad bancaria portuguesa. Por otra parte, las variables / columnas recogen información sobre el cliente, la campaña y el contexto económico del momento. El conjunto de datos incluye tanto variables categóricas, concretamente 11, por ejemplo el estado civil o el tipo de trabajo, como 10 variables numéricas entre las cuales encontramos la edad o los indicadores macroeconómicos.

El periodo temporal en el que se realizó la campaña va desde mayo de 2008 hasta noviembre de 2010, lo que permite analizar la evolución de las campañas junto a un contexto económico real.

La variable objetivo del estudio es y, que indica si el cliente ha suscrito o no un depósito bancario, tratándose de una variable categórica binaria.

Para facilitar el análisis de los datos hemos decidido trabajar con una muestra de 5000 observaciones. Esta muestra ha sido seleccionada mediante un muestreo aleatorio simple para asegurar la representatividad del conjunto de datos original. Además, hemos realizado recodificaciones en las variables binarias, transformándolas a formato numérico (0/1), con el fin de facilitar su tratamiento en modelos estadísticos. Por otra parte, los valores "unknown" los hemos tratado como valores faltantes (NA) para su posterior análisis, tal y como indica el creador de la base de datos.

Para resumir de forma estructurada las principales características del conjunto de datos presentamos una tabla descriptiva que recoge el número de observaciones, variables y la presencia de valores faltantes.

Table 3: Estructura matricial

		Tipo de variables		Valores faltantes		
Numero_Filas	**Numero_Columnas**	**Numero_Variables_Numéricas**	**Numero_Variables_Categóricas**	**Numero_NA_total**	**Numero_NA_filas**	**Porcentaje_NA**
5000	21	10	11	1494	1282	1.42

Con el objetivo de complementar la descripción formal de la estructura de los datos, realizamos un análisis descriptivo inicial utilizando el paquete DataExplorer de R, que permite tener una visión general rápida del conjunto de datos.



El análisis de valores faltantes muestra un alto nivel de variables completas, con únicamente un 1.4% de observaciones con valores perdidos, lo que indica que la pérdida de información es mínima. Además no existen variables completamente vacías.

En cuanto a la estructura del conjunto de datos, se observa un equilibrio entre los tipos de variables, con un 52.4% de variables discretas y un 47.6% de variables continuas. El 74.4% de las observaciones están completas, lo que proporciona una base suficientemente sólida para llevar a cabo el análisis.

El gráfico de barras muestra la calidad de los datos midiendo la cantidad y el porcentaje de valores faltantes por cada variable. La mayoría de las variables contienen un 0% o un porcentaje muy bajo de datos perdidos. Sin embargo, la variable *default* destaca significativamente al presentar un 20.9% de valores faltantes, lo que indica que requiere especial atención en el análisis.

Listado de variables y su información (Metadata)

A continuación, presentamos una descripción de cada variable, su interpretación dentro del contexto y los valores que esta puede tener.

Table 4: Descripción de las variables

Variable	Descripción	Ambito	Tipo	Min	Max	Categorias
age	Edad del cliente	Demografía	Numérica continua	17	88	
job	Tipo de trabajo	Socioeconómico	Categórica nominal			entrepreneur, blue-collar, services, admin., technician, self-employed, management, housemaid, student, retired, unemployed
marital	Estado civil	Demografía	Categórica nominal			married, divorced, single
education	Nivel educativo	Educación	Categórica ordinal			high.school, basic.9y, basic.4y, university.degree, basic.6y, professional.course, illiterate
default	Tiene crédito en impago	Finanzas	Categórica binaria (codificada 0/1)			0, 1
housing	Tiene préstamo hipotecario	Finanzas	Categórica binaria (codificada 0/1)			0, 1
loan	Tiene préstamo personal	Finanzas	Categórica binaria (codificada 0/1)			0, 1
contact	Tipo de contacto (teléfono/móvil)	Marketing	Categórica nominal			0, 1
month	Mes del último contacto	Temporal	Categórica ordinal			may, apr, aug, nov, jun, jul, sep, oct, mar, dec
day_of_week	Día de la semana del contacto	Temporal	Categórica nominal			wed, mon, thu, fri, tue
duration	Duración de la llamada (segundos)	Marketing	Numérica continua	1	4199	
campaign	Número de contactos durante la campaña	Marketing	Numérica discreta	1	43	
pdays	Días desde el último contacto previo	Marketing	Numérica discreta	0	999	
previous	Número de contactos previos	Marketing	Numérica discreta	0	6	
poutcome	Resultado de la campaña anterior	Marketing	Categórica nominal			nonexistent, failure, success
emp.var.rate	Tasa de variación del empleo	Economía	Numérica continua	-3.4	1.4	
cons.price.idx	Índice de precios al consumo	Economía	Numérica continua	92.201	94.767	
cons.conf.idx	Índice de confianza del consumidor	Economía	Numérica continua	-50.8	-26.9	
euribor3m	Tipo de interés Euribor a 3 meses	Economía	Numérica continua	0.634	5.045	
nr.employed	Número de empleados	Economía	Numérica continua	4963.6	5228.1	

Table 4: Descripción de las variables *(continued)*

Variable	Descripción	Ambito	Tipo	Min	Max	Categorias
y	Suscripción al depósito (variable objetivo)	Marketing / Resultado	Categórica binaria (codificada 0/1)			0, 1

Descriptiva univariante

Analisis descriptivo

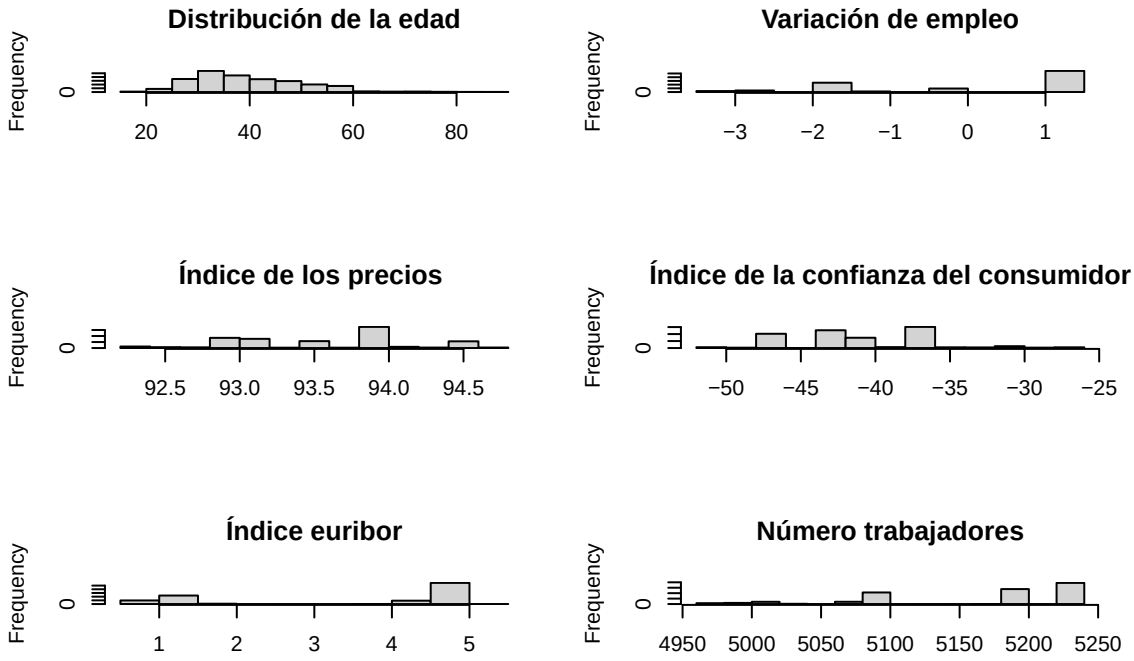
El análisis univariante nos permitirá comprender y analizar mejor individualmente todas las variables con las que contamos.

Comenzaremos por las variables numéricas:

Table 5: Resumen estadístico de variables numéricas

emp.var.rate	Min. :-3.40000	1st Qu.:-1.80000	Median : 1.10000	Mean : 0.05586	3rd Qu.: 1.40000	Max. : 1.40000
cons.price.idx	Min. :92.20	1st Qu.:93.08	Median :93.80	Mean :93.58	3rd Qu.:93.99	Max. :94.77
cons.conf.idx	Min. :-50.80	1st Qu.:-42.70	Median :-41.80	Mean :-40.67	3rd Qu.:-36.40	Max. :-26.90
euribor3m	Min. :0.634	1st Qu.:1.334	Median :4.857	Mean :3.589	3rd Qu.:4.961	Max. :5.045
nr.employed	Min. :4964	1st Qu.:5099	Median :5191	Mean :5166	3rd Qu.:5228	Max. :5228

```
## ==== Gráficamente:
```



Comenzaremos analizando la variable emp.var.rate, la cual nos muestra que cuenta con una media mucho menor que su mediana y con valores bastante negativos. Gráficamente, se observan bloques en valores específicos, lo que nos lleva a pensar que estos valores dependen de los periodos en los que se encuentre.

La siguiente variable a analizar es cons.price.idx con una distribución bastante simétrica y poca variabilidad, no parece haber extremos fuertes.

Continuamos con el cons.conf.idx que presenta solo valores negativos y una media mayor a la mediana, por lo que podremos considerar una ligera asimetría positiva.

El euribor3m cuenta con valores muy bajos, cerca del 0.6, que afectan a la media, la cual es mucho menor a la mediana, presentando una asimetría negativa ya que la mayoría de datos se encuentran en valores altos, cerca del cinco.

Por último, la variable nr.employed tiene una distribución bastante concentrada, poca dispersión, podemos afirmar que es una variable muy estable. El gráfico nos muestra claramente que casi es una variable discreta que al igual que la variable emp.var.rate depende de dos grandes periodos.

Las conclusiones generales que podemos sacar de analizar estas variables numéricas es que no asumiremos normalidad para ninguna de ellas y que todas son realmente influyentes ya que en general nos muestran cómo separan contextos económicos.

Por otra parte, en relación a las variables que nos faltan por analizar, disponemos de un conjunto amplio de categóricas que describen las características de los clientes, así como aspectos relacionados con la campaña de marketing. Aunque, en principio, podría parecer adecuado analizar todas las variables categóricas disponibles, esta estrategia no resulta óptima desde el punto de vista analítico.

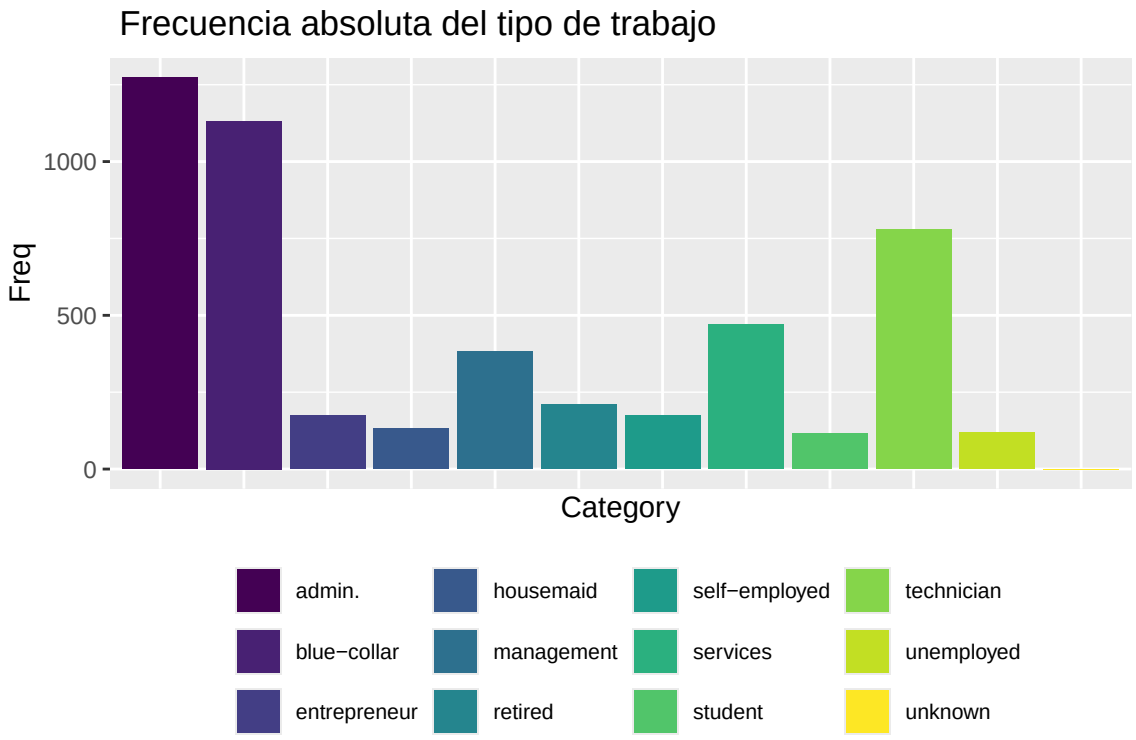
Por ello, realizaremos una selección de las variables categóricas esenciales:

Job (tipo de trabajo), relacionado con los ingresos y la estabilidad económica de los clientes. Marital (estado civil), pues influye en los hábitos financieros de cada persona. Education (nivel educativo), estrechamente relacionado con la cultura financiera. Housing (préstamo hipotecario) y Loan (préstamo personal), muestra el nivel de endeudamiento. Poutcome (resultado de las campañas anteriores), enseña cómo responde el cliente a las distintas campañas.

```
## ================= Job ================
```

	Var1	Freq	Frecuencia relativa
1	admin.	1274	0.257
2	blue-collar	1132	0.228
3	entrepreneur	174	0.035
4	housemaid	133	0.027
5	management	381	0.077
6	retired	211	0.043
7	self-employed	175	0.035
8	services	470	0.095
9	student	115	0.023
10	technician	779	0.157
11	unemployed	118	0.024
12	unknown	0	0.000

```
## - - -
```

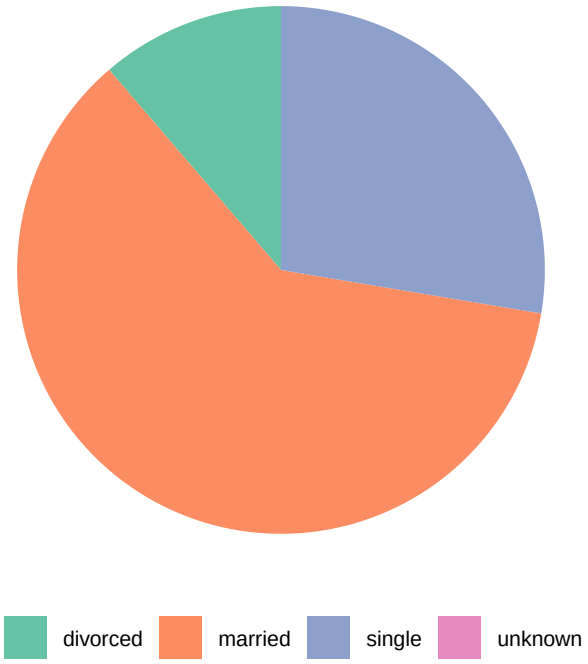


La gráfica muestra que las categorías admin. y blue-collar concentran la mayor frecuencia, mientras que grupos como self-employed y technician tienen una representación significativa menor.

```
## ================= Marital ================

##       Var1 Freq Frecuencia relativa
## 1 divorced  564               0.113
## 2  married 3050               0.611
## 3   single 1380               0.276
## 4  unknown    0               0.000

## - - -
```

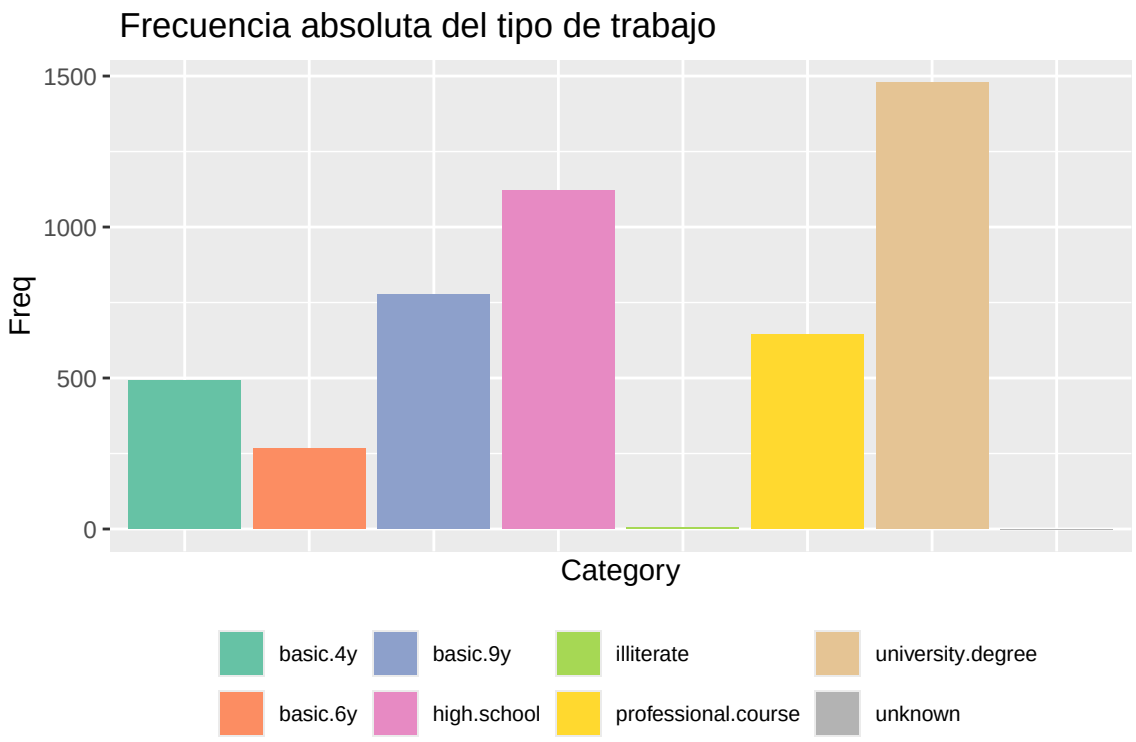


En este caso, podemos ver claramente que lo que predomina en este muestra son clientes casados, seguidos de los solteros y, finalmente, en menor medida los divorciados.

```
## ================= Education ================
```

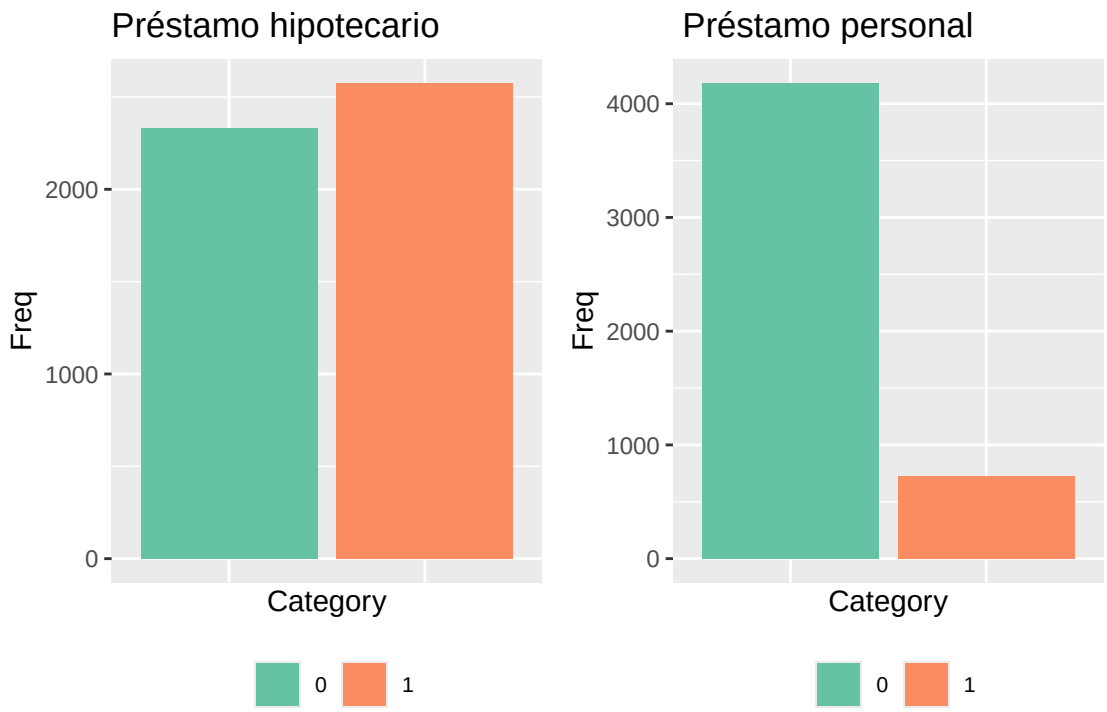
```
##                   Var1 Freq Frecuencia relativa
## 1            basic.4y  492               0.103
## 2            basic.6y  266               0.056
## 3            basic.9y  776               0.162
## 4         high.school 1122               0.235
## 5          illiterate    4               0.001
## 6 professional.course  643               0.134
## 7   university.degree 1480               0.309
## 8             unknown    0               0.000
```

```
## - - -
```



En relación al nivel de estudios, observamos que tiene una mayor frecuencia estar licenciado en un grado de universidad, seguido del 'high school', lo que consideraríamos en España como el instituto. En menor medida vemos que están los 'basics' ordenados de mayor nivel a menor.

```
## ================= Housing y Loan ================
```

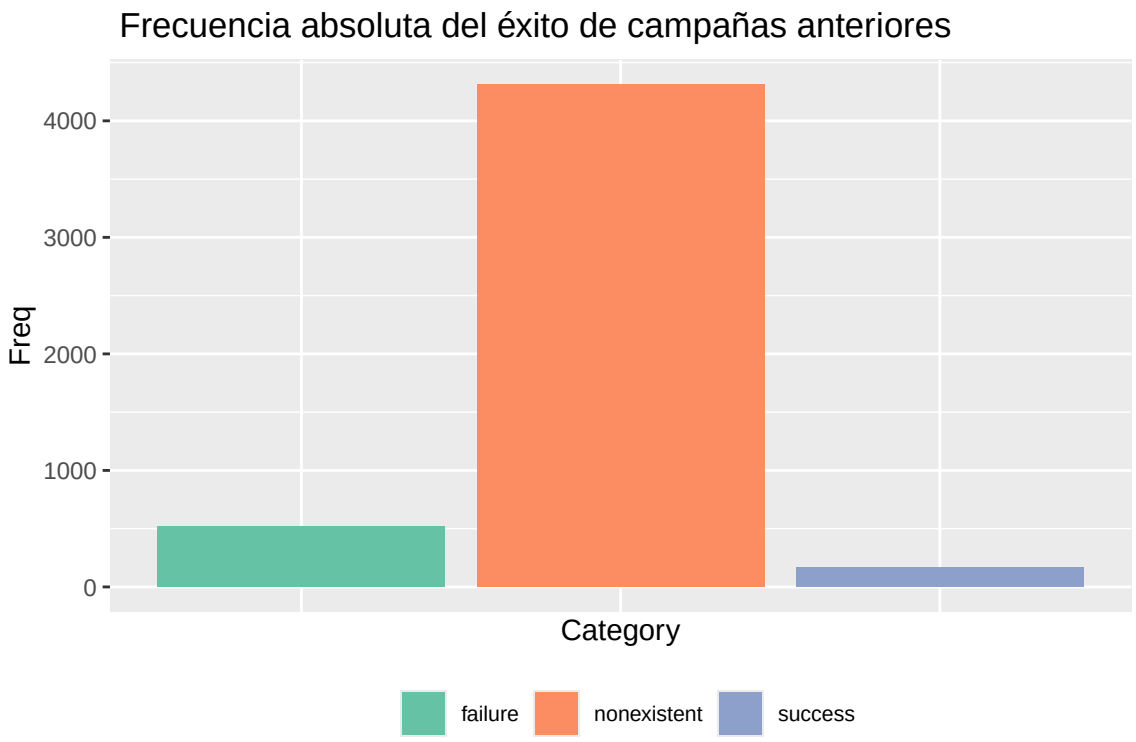


Observamos que mientras la deuda hipotecaria presenta una distribución bastante equilibrada entre quienes tienen y no tienen deuda, en los préstamos personales predomina claramente la ausencia de deuda.

```
## ================= Poutcome ================

##          Var1 Freq Frecuencia relativa
## 1     failure  520               0.104
## 2 nonexistent 4309               0.862
## 3     success  171               0.034

## - - -
```



Por último, apreciamos que no tenemos mucha información en relación a cómo de bien fueron las campañas de marketing anteriores ya que predomina la respuesta 'no exist'. Centrándonos en las otras dos opciones: éxito y fracaso, vemos que es más frecuente que no sea una campaña exitosa, pero con una mínima diferencia.

Descripción del proceso de preprocesamiento

Antes de realizar cualquier análisis, es fundamental asegurarnos de que los datos con los que trabajaremos sean confiables y consistentes. Esto implica un proceso de preprocesamiento en el que se identifican y corrigen posibles errores, se trabaja con los valores faltantes, se detectan y analizan valores atípicos, y se verifica la coherencia de las variables para que podamos garantizar unos resultados y conclusiones que reflejen correctamente toda la información. Durante los apartados anteriores ya hemos llevado a cabo análisis que nos pueden asegurar que los datos de nuestra base no contienen errores, ni de concordancia ni de medición. Por ello, ahora nos centraremos en la corrección de los NA's y de los outliers.

Comenzaremos trabajando con los valores faltantes, haciendo un test de "missing completely at random", para saber si estos NA's son MCAR.

```
naniar::mcar_test(muestra)
```

```
## # A tibble: 1 x 4
##   statistic    df p.value missing.patterns
##       <dbl> <dbl>   <dbl>            <int>
## 1      794.   227       0               13
```

El p-valor de nuestro test es cero, por lo que rechazaremos la hipótesis nula de que los missings son mcar y usaremos métodos de imputación más complejos para evitar cualquier tipo de sesgo al eliminar esos NA's.

```
##   missForest iteration 1 in progress...done!
##     estimated error(s): 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
##     difference(s): 0 0
##     time: 0.028 seconds
##
##   missForest iteration 2 in progress...done!
##     estimated error(s): 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
##     difference(s): 0 0
##     time: 0.031 seconds
```

```
# comprobacion
set.seed(123)
muestra <- imputado$ximp[sample(nrow(dades), 5000), ]
kable(colSums(is.na(muestra)))
```

	x
age	0
job	0
marital	0
education	0
default	0
housing	0
loan	0
contact	0
month	0
day_of_week	0
duration	0
campaign	0
pdays	0
previous	0
poutcome	0
emp.var.rate	0
cons.price.idx	0
cons.conf.idx	0
euribor3m	0
nr.employed	0
y	0

Finalmente, para acabar con el preprocesamiento analizaremos los outliers, valores extremos, de nuestra base de datos.

```r
for(col in names(muestra)){

  if(is.numeric(muestra[[col]])){
escalado <- scale(muestra[[col]], scale=TRUE)
  }
}

sum(abs(escalado) > 3)
```

```
## [1] 135
```

```r
sol <-c()
for(col in names(muestra)){
  if(is.numeric(muestra[[col]])){
test <- EnvStats::rosnerTest(dades[[col]], k = 10)
sol <-c(sol, test$all.stats)
  }
}
sum(sol$outlier)
```

```
## [1] 0
```

Probando distintos métodos y test vemos que el número de outliers puede variar entre los 10-100 outliers, lo que es tan solo un 2.8% de nuestros datos. Como nuestra muestra cuenta con 5000 observaciones, la proporción de posibles outliers es demasiado pequeña como para que pueda afectar o sesgar nuestros resultados.

Descriptiva bivariante

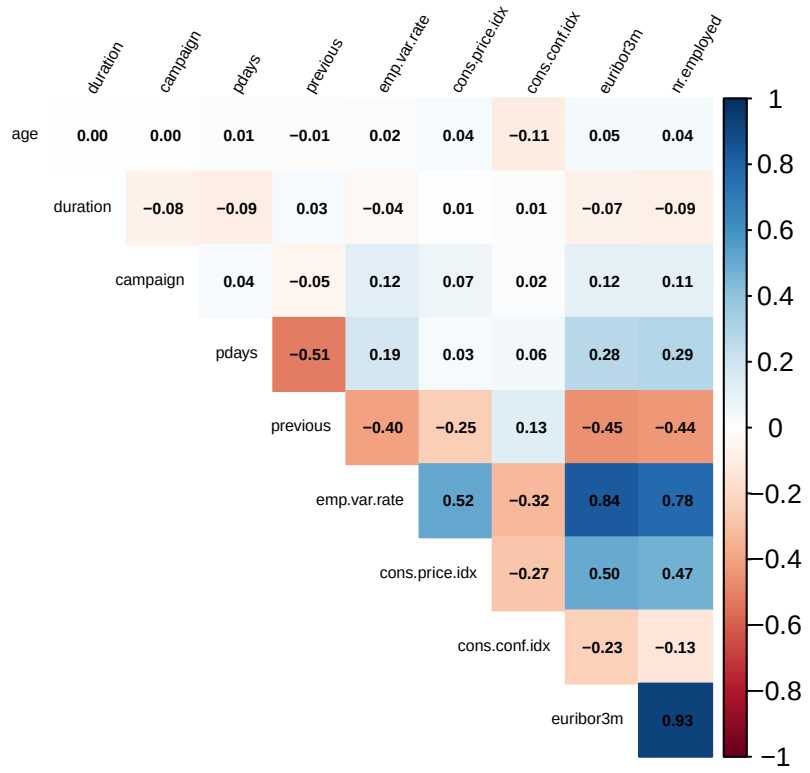
El análisis descriptivo bivariante en una muestra multivariante adquiere una gran relevancia ya que permite comenzar a construir explicaciones acerca de la información que estamos manejando. Amplía los conocimientos obtenidos en el análisis univariante, siendo más exhaustivo. Destaca la facilidad de interpretación frente a las comparaciones de un mayor número de variables. Además, permite detectar multicolinealidad. Si dos variables numéricas están muy correlacionadas su coexistencia puede generar problemas en nuestro modelo.

Para esta sección estableceremos tres modalidades de análisis según las variables a estudiar: numérica-numérica, categórica-numérica y categórica-categórica.

Análisis descriptivo

Variables cuantitativas

Para este apartado se utiliza el coeficiente de correlación de Spearman dado que las variables numéricas no cumplen el supuesto de normalidad, confirmado mediante los tests realizados en la descriptiva univariante.



Var1	Var2	Freq
nr.employed	euribor3m	0.9298422
euribor3m	emp.var.rate	0.8365424
nr.employed	emp.var.rate	0.7760232
cons.price.idx	emp.var.rate	0.5193265

Var1	Var2	Freq
euribor3m	cons.price.idx	0.5019317
nr.employed	cons.price.idx	0.4725134
nr.employed	pdays	0.2922230
euribor3m	pdays	0.2774183

Tras los resultados obtenidos caben destacar cuatro correlaciones más fuertes que las demás:
- nr.employed y euribor3m. Vemos que el número de empleados y el tipo de interés a 3 meses se mueve de manera prácticamente idéntica.
- euribor3m y emp.var.rate. De nuevo el número de empleados está relacionado con el tipo de interés a 3 meses.
- nr.employed y emp.var.rate. Ambas variables vemos que están relacionados el número de empleados y la tasa de variación de empleados.

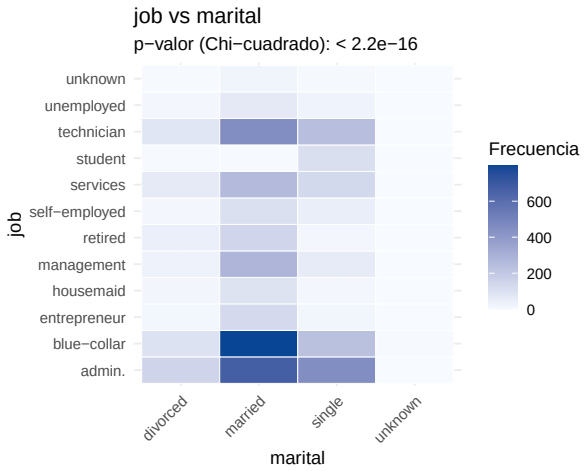
Ante esto, para solucionar un posible problema de multicolinealidad, podríamos eliminar una de las variables ya que vemos que las tres tienen un comportamiento similar.

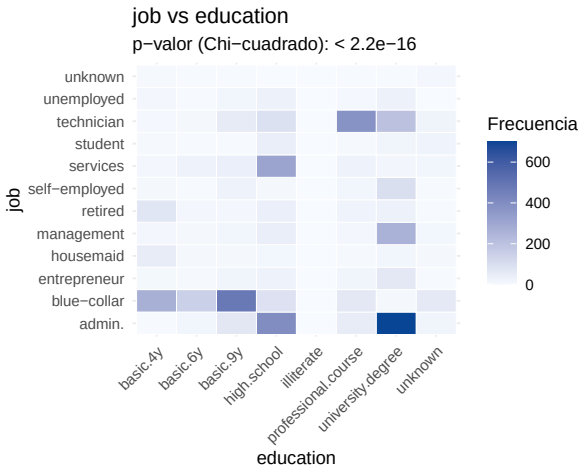
Var1	Var2	Freq
previous	pdays	-0.5144223
euribor3m	previous	-0.4530587
nr.employed	previous	-0.4375748
emp.var.rate	previous	-0.4017145
cons.conf.idx	emp.var.rate	-0.3215096
cons.conf.idx	cons.price.idx	-0.2719747
cons.price.idx	previous	-0.2462436
euribor3m	cons.conf.idx	-0.2304943

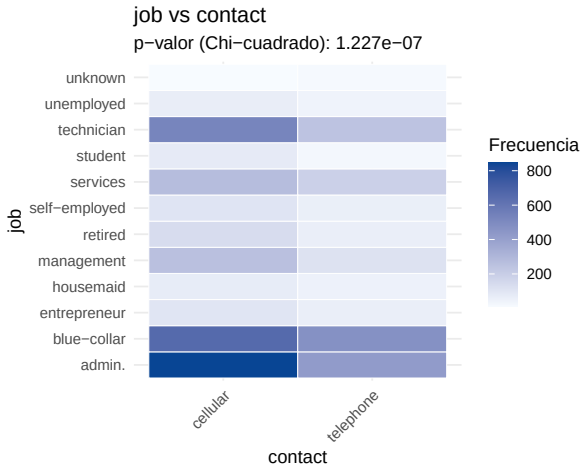
La correlación más fuerte negativamente ocurre entre `pdays` y `previous`. Tiene sentido ya que la primera se refiere a los días desde el último contacto y la segunda los contactos realizados. Esto significaría que a medida que pasa más tiempo desde la última llamada, el número de contactos previos tiende a ser menor en los registros recientes, o viceversa.

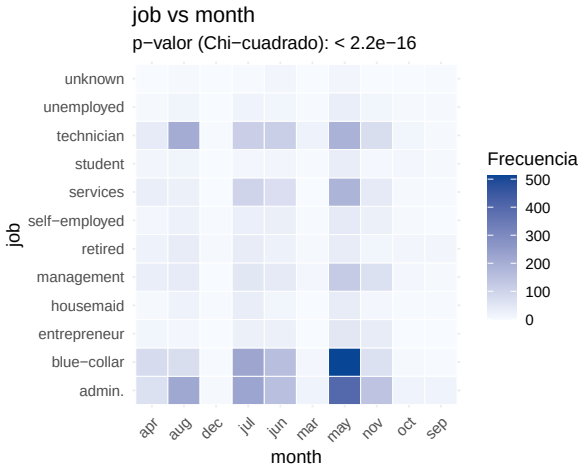
Variables categóricas

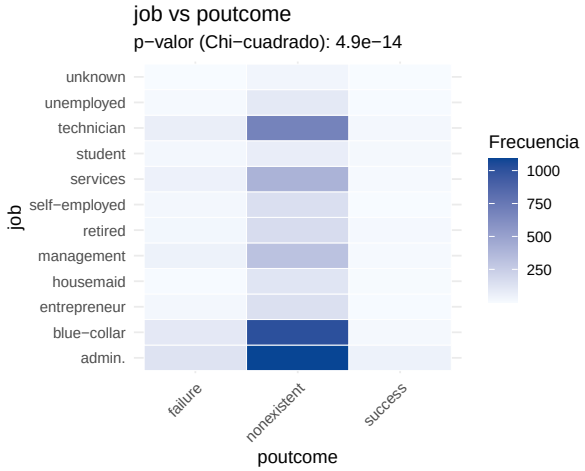
Para cada pareja de las variables restantes realizamos una tabla de contingencia y posteriormente una gráfica correspondiente para su posterior análisis descriptivo.

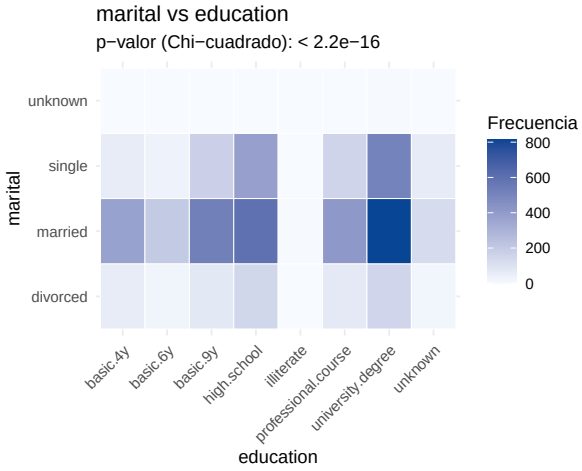

job vs marital
p−valor (Chi−cuadrado): < 2.2e−16
job
unknown
unemployed
technician
student
services
self−employed
retired
management
housemaid
entrepreneur
blue−collar
admin.
divorced
married
single
unknown
marital
Frecuencia
600
400
200
0

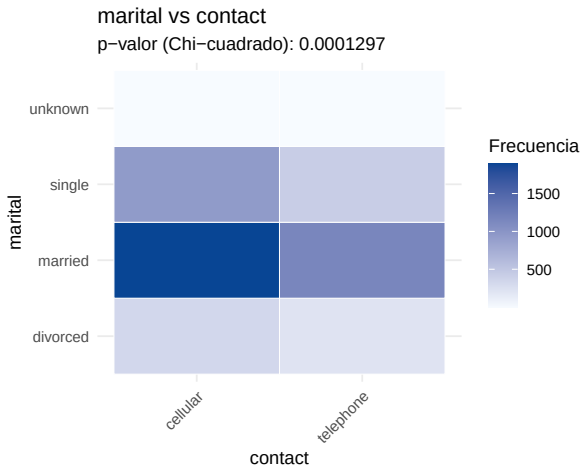

job vs education
p−valor (Chi−cuadrado): < 2.2e−16
job
unknown
unemployed
technician
student
services
self−employed
retired
management
housemaid
entrepreneur
blue−collar
admin.
basic.4y
basic.6y
basic.9y
high.school
illiterate
professional.course
university.degree
unknown
education
Frecuencia
600
400
200
0

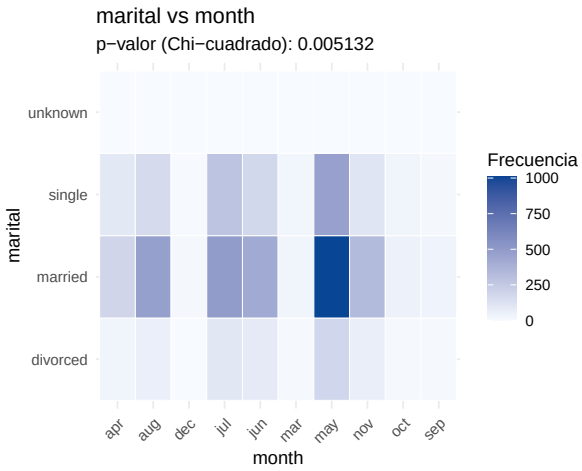

job vs contact
p−valor (Chi−cuadrado): 1.227e−07
job
unknown
unemployed
technician
student
services
self−employed
retired
management
housemaid
entrepreneur
blue−collar
admin.
cellular
telephone
contact
Frecuencia
800
600
400
200

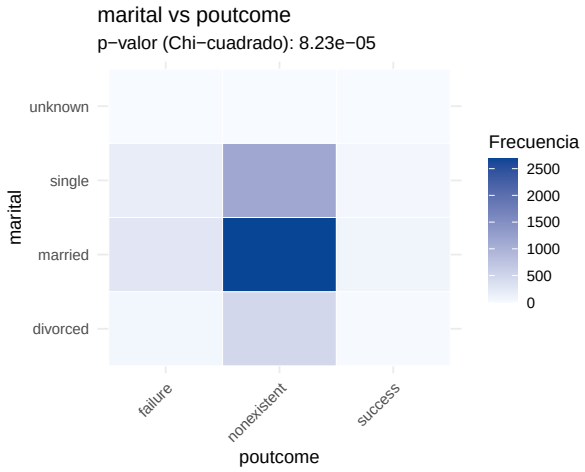

job vs month
p−valor (Chi−cuadrado): < 2.2e−16
job
unknown
unemployed
technician
student
services
self−employed
retired
management
housemaid
entrepreneur
blue−collar
admin.
apr
aug
dec
jul
jun
mar
may
nov
oct
sep
month
Frecuencia
500
400
300
200
100
0

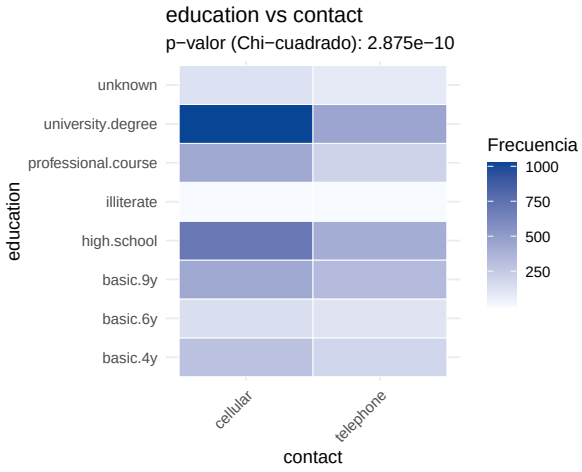

job vs poutcome
p−valor (Chi−cuadrado): 4.9e−14
job
unknown
unemployed
technician
student
services
self−employed
retired
management
housemaid
entrepreneur
blue−collar
admin.
failure
nonexistent
success
poutcome
Frecuencia
1000
750
500
250

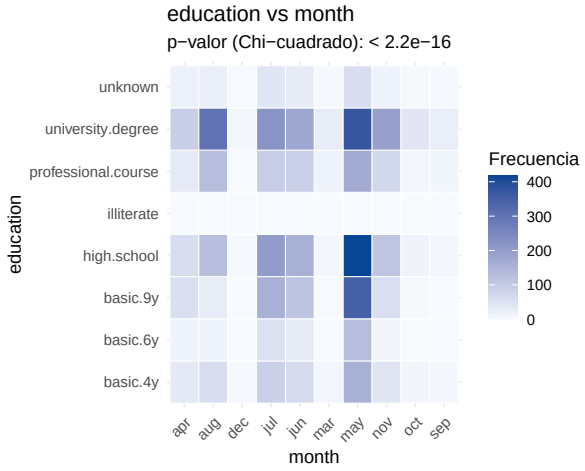

marital vs education
p−valor (Chi−cuadrado): < 2.2e−16
marital
unknown
single
married
divorced
basic.4y
basic.6y
basic.9y
high.school
illiterate
professional.course
university.degree
unknown
education
Frecuencia
800
600
400
200
0

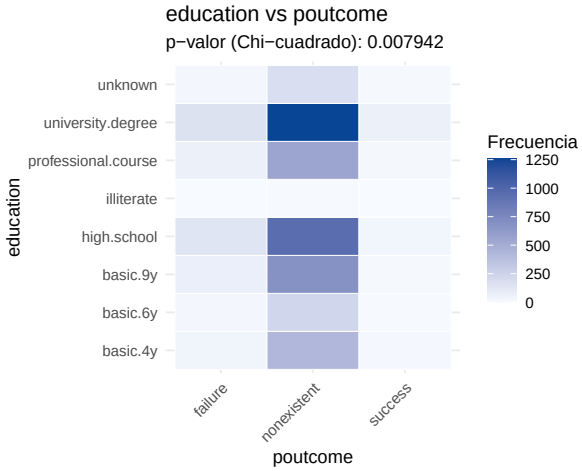

marital vs contact
p−valor (Chi−cuadrado): 0.0001297
unknown
single
married
divorced
marital
cellular
telephone
contact
Frecuencia
1500
1000
500

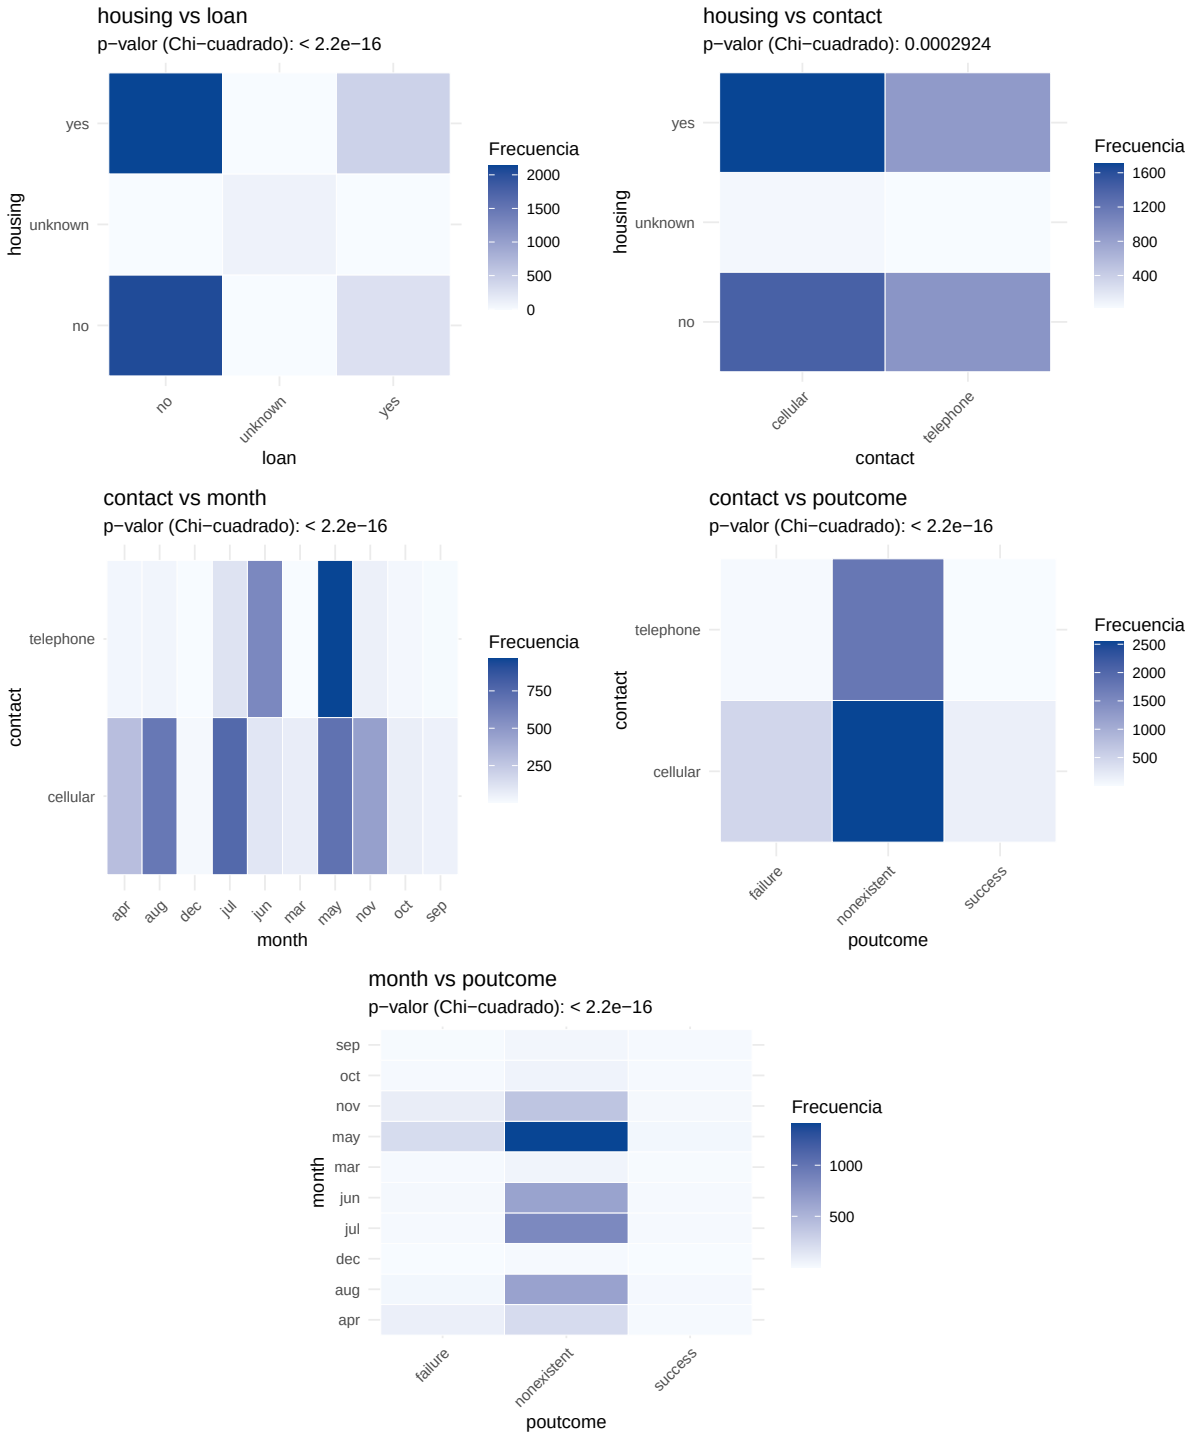

marital vs month
p−valor (Chi−cuadrado): 0.005132
unknown
single
married
divorced
marital
apr
aug
dec
jul
jun
mar
may
nov
oct
sep
month
Frecuencia
1000
750
500
250
0


marital vs poutcome
p−valor (Chi−cuadrado): 8.23e−05
unknown
single
married
divorced
marital
failure
nonexistent
success
poutcome
Frecuencia
2500
2000
1500
1000
500
0


education vs contact
p−valor (Chi−cuadrado): 2.875e−10
unknown
university.degree
professional.course
illiterate
high.school
basic.9y
basic.6y
basic.4y
education
cellular
telephone
contact
Frecuencia
1000
750
500
250

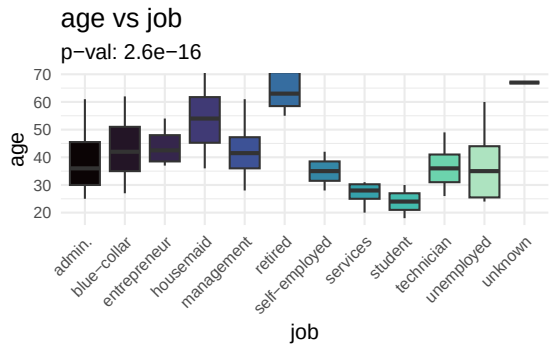

education vs month
p−valor (Chi−cuadrado): < 2.2e−16
unknown
university.degree
professional.course
illiterate
high.school
basic.9y
basic.6y
basic.4y
education
apr
aug
dec
jul
jun
mar
may
nov
oct
sep
month
Frecuencia
400
300
200
100
0

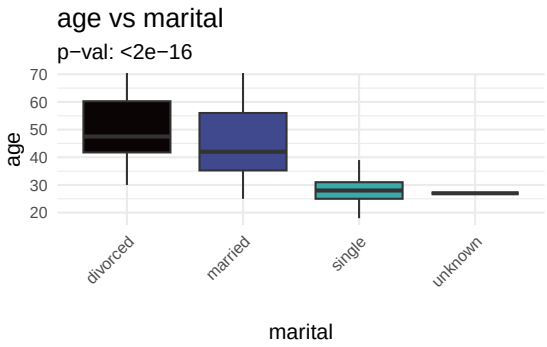

education vs poutcome
p−valor (Chi−cuadrado): 0.007942
unknown
university.degree
professional.course
illiterate
high.school
basic.9y
basic.6y
basic.4y
education
failure
nonexistent
success
poutcome
Frecuencia
1250
1000
750
500
250
0

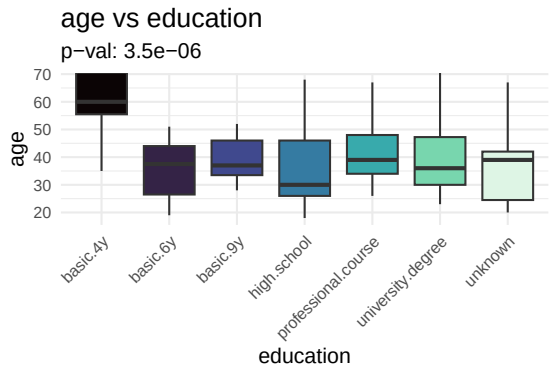


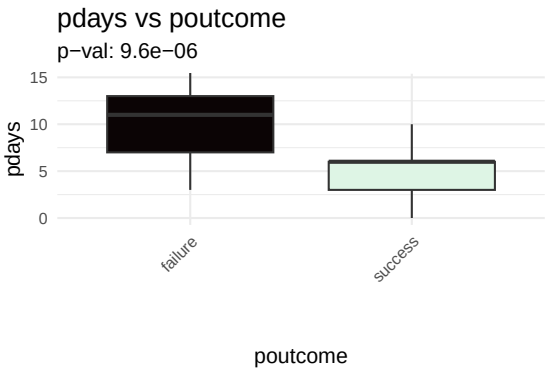
Para el análisis descriptivo hay ciertas relaciones que pueden resultar interesantes. El puesto de administrativo está altamente correlacionado con las personas que tienen un grado universitario.

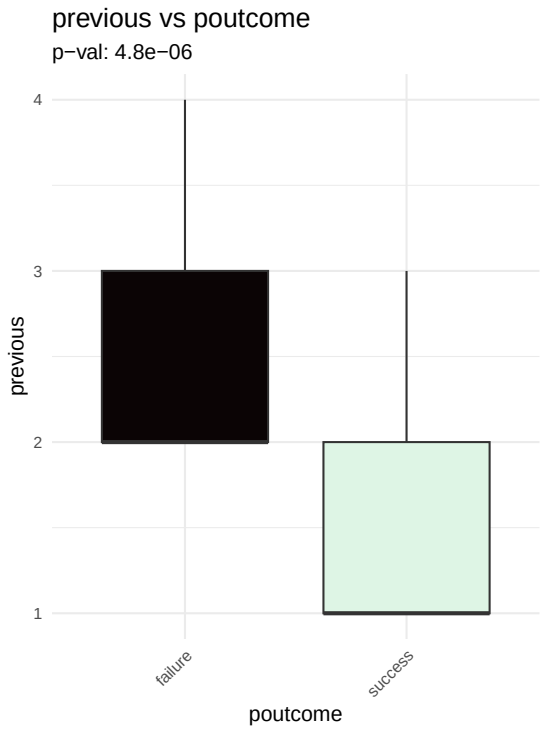
Variable numérica y variable categórica.

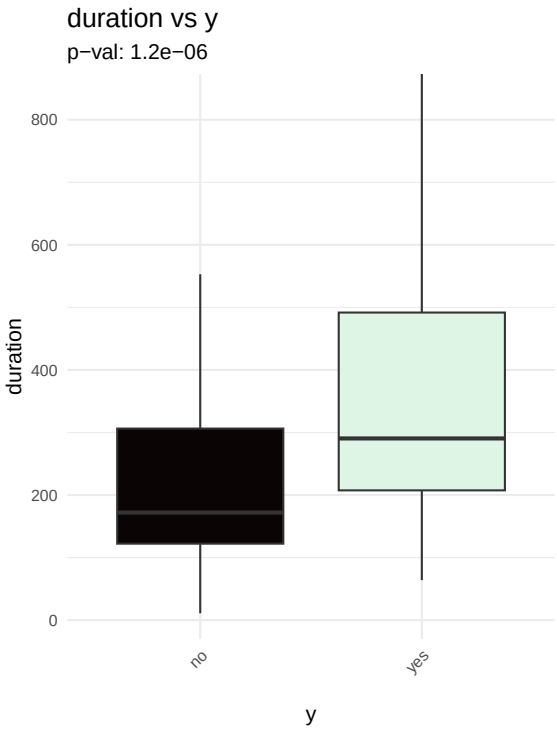












Descripción de las principales dificultades

En primer lugar, la presencia de multicolinealidad entre las variables numéricas económicas ha sido el problema más relevante. A partir de la matriz de correlaciones de Spearman, se detectaron correlaciones muy elevadas entre euribor3m, emp.var.rate y nr.employed. Dado que estas tres variables contienen información prácticamente redundante, en fases posteriores del análisis será necesario considerar la eliminación de alguna de ellas o combinarlas mediante técnicas de reducción de dimensionalidad para evitar problemas en los modelos estadísticos.

En segundo lugar, la variable pdays presentó una distribución muy particular, con la gran mayoría de valores iguales a 999, indicando que el cliente no había sido contactado previamente. Esto dificultó su tratamiento como variable continua estándar y condicionó su interpretación en las relaciones con otras variables.

En tercer lugar, en el análisis de variables categóricas mediante tablas de contingencia y el test chi-cuadrado, algunas combinaciones de categorías poco frecuentes generaron frecuencias esperadas muy bajas, lo que puede comprometer la validez del test en esos casos concretos. Sus resultados deben interpretarse con cautela.

Principales conocimientos obtenidos del análisis bivariante

Respecto a las variables numéricas, se ha confirmado que las variables económicas (euribor3m, emp.var.rate, nr.employed y cons.price.idx) están fuertemente correlacionadas entre sí, lo que indica que todas reflejan el mismo contexto macroeconómico y contienen información redundante. También se ha observado una relación inversa entre pdays y previous: cuanto más tiempo ha pasado desde el último contacto previo, menor tiende a ser el número de contactos anteriores registrados, lo cual tiene sentido desde el punto de vista del proceso de campaña.

En cuanto a las variables categóricas, los tests chi-cuadrado han revelado que la mayoría de las parejas de variables presentan asociaciones estadísticamente significativas. Destaca especialmente la relación entre el tipo de trabajo y el nivel educativo, lo que confirma que el perfil socioeconómico del cliente es una característica coherente y estructurada. Asimismo, se ha observado que el tipo de contacto y el mes de la llamada están relacionados con el resultado de campañas anteriores, lo que sugiere que el contexto y el momento de la campaña influyen en el comportamiento del cliente.

Finalmente, el análisis conjunto de variables numéricas y categóricas ha mostrado que la edad está significativamente relacionada con el tipo de trabajo y el estado civil, y que la duración de la llamada presenta diferencias según la respuesta final del cliente, apuntando a que las interacciones más largas tienden a asociarse con una mayor probabilidad de respuesta positiva.

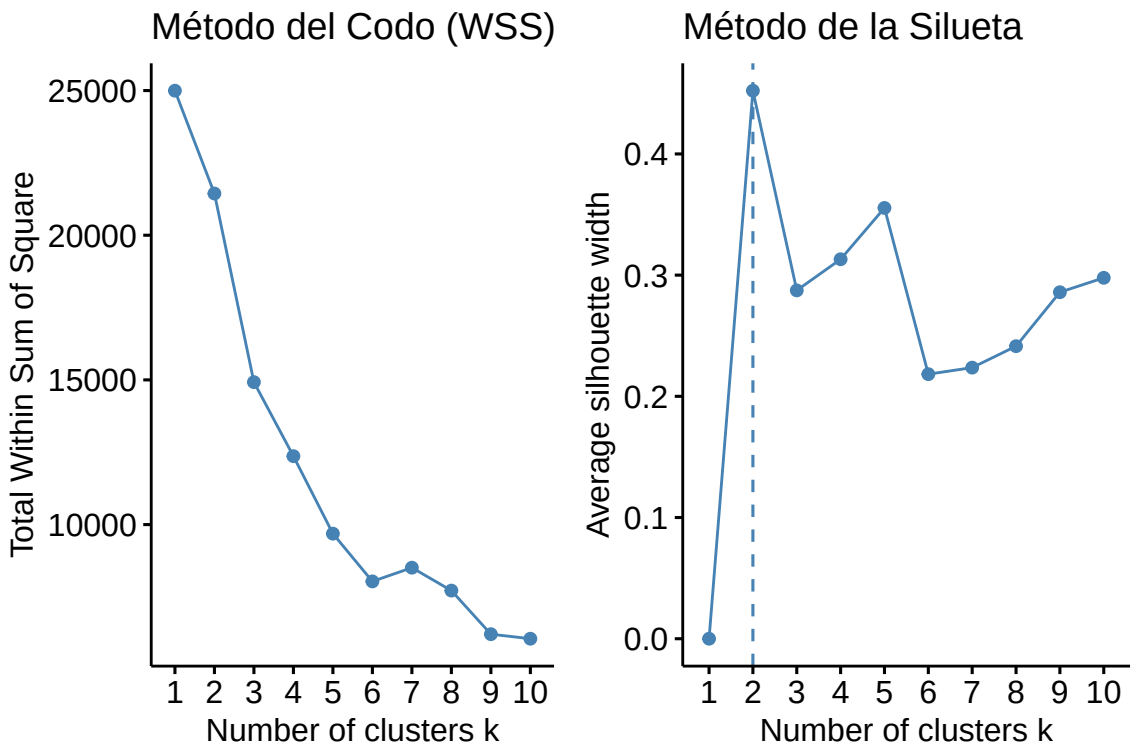
Clustering

Particional

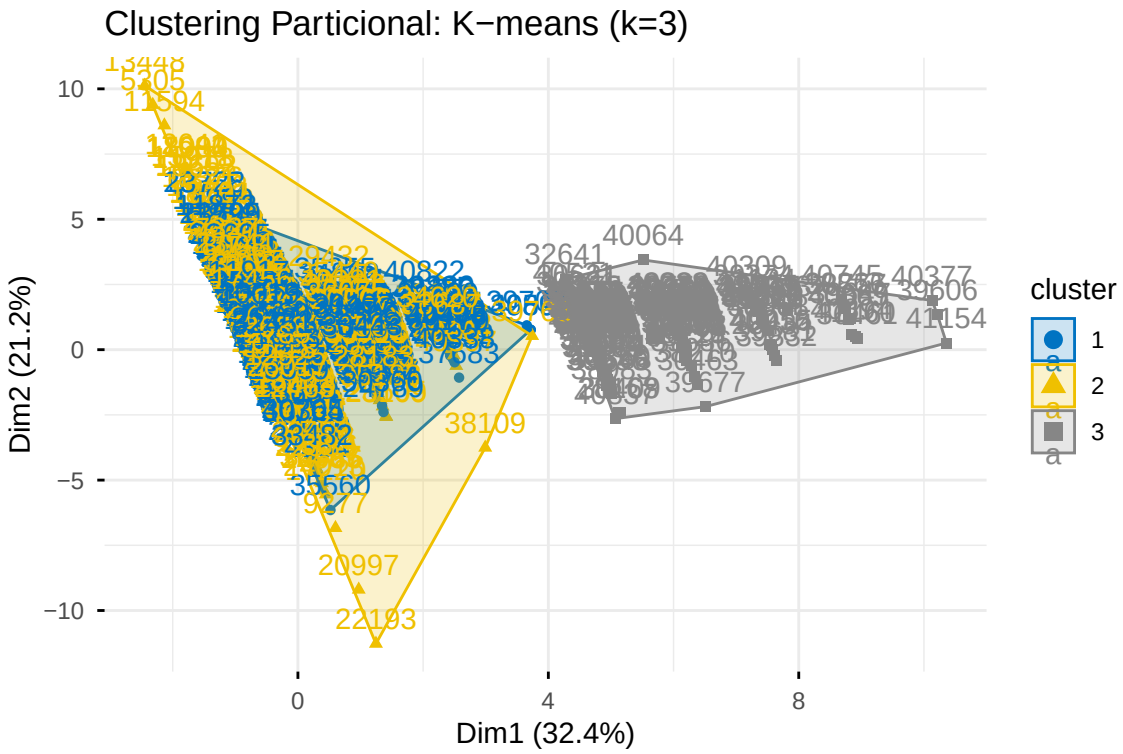
Para el análisis particional hemos seleccionado los algoritmos **K-means** y **PAM**. La elección de estos dos métodos es para contrastar la estabilidad de los grupos: K-means es ideal para identificar estructuras esféricas y compactas, mientras que PAM ofrece una mayor robustez frente a valores extremos al trabajar con medoides.

Selección de hiperparámetros (*k*): Utilizaremos los criterios de *WSS (Within Sum of Squares)* y la *Silueta*:

```
## [1] "age"      "duration" "campaign" "pdays"    "previous"
```

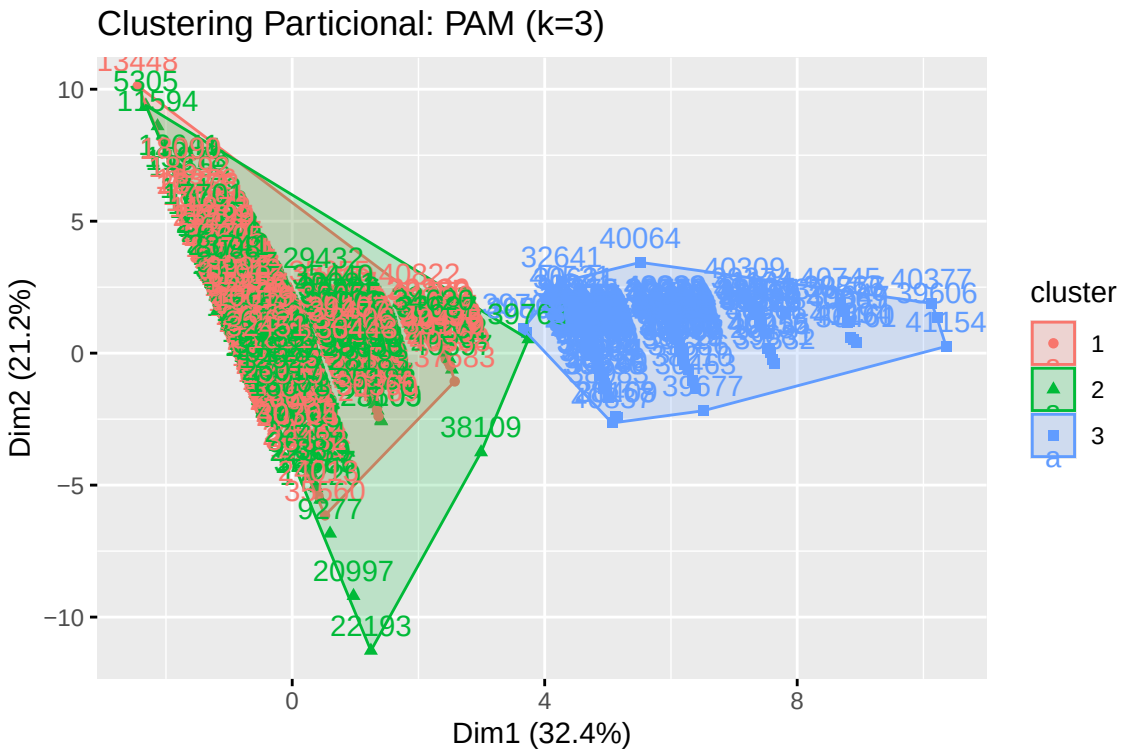


El análisis WSS muestra un punto de inflexión claro en *k=3*, donde la inercia intragrupo comienza a estabilizarse. Por otro lado, aunque el índice de la Silueta alcanza su máximo global en *k=2*. Seleccionaremos textbf{k=3} como hiperparámetro final, ya que esto nos permitirá una segmentación más rica y con mayor sentido de negocio (nuestro dataset), manteniendo una estructura de grupos cohesiva.



Vemos tres estructuras claras:

- El **Clúster 1** aparece como un grupo altamente cohesionado y segregado en el eje de la Dim1, lo que sugiere un perfil de cliente con un comportamiento de respuesta muy diferenciado (fidelizados).
- Los **Clústeres 2 y 3** muestran una mayor proximidad entre sí, con un ligero solapamiento en sus fronteras. Esto indica que la transición entre estos dos perfiles (basada posiblemente en edad o intensidad de la campaña) es más continua.



Como hemos mencionado antes, PAM utiliza *medoides* (puntos reales de la muestra) como centros de los clústeres, lo que reduce la sensibilidad del modelo ante valores atípicos o *outliers* presentes en variables como *duration* o *campaign*.

En la gráfica vemos la proyección de los datos sobre las dos primeras componentes principales, que explican un **53,6%** de la varianza total de la muestra:

- **Dimensión 1 (32,4%):** Actúa como el principal factor de discriminación, separando claramente al **Clúster 1** del resto. Esta dimensión captura principalmente la variabilidad ligada al historial de contactos previos.
- **Dimensión 2 (21,2%):** Aporta una segunda capa de información que permite perfilar las diferencias entre los **Clústeres 2 y 3**, basándose en la intensidad de la campaña y variables demográficas.

La capacidad del gráfico para representar más de la mitad de la varianza total (**53,6%**) valida la interpretación visual de los grupos. Entonces sí hay existencia de un segmento de clientes altamente diferenciado y dos grupos con características más transversales que requieren estrategias de marketing distintas.

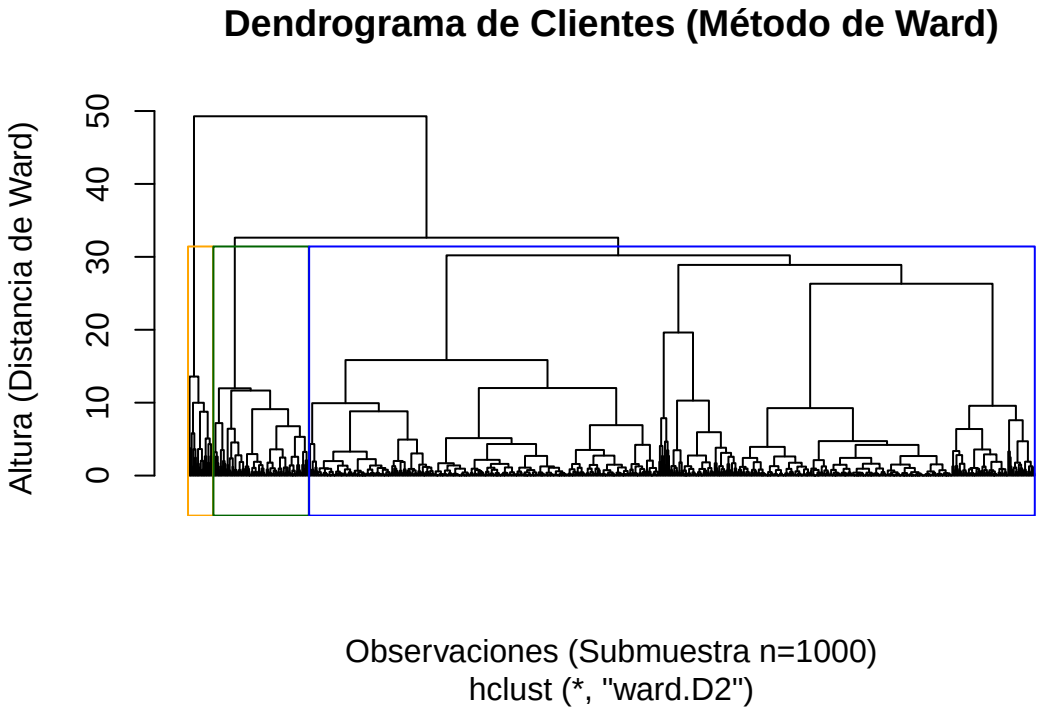
Después de contrastar los resultados de **K-means** y **PAM** para asegurar la estabilidad de la segmentación, hemos visto que K-means destaca por su eficiencia en grandes volúmenes de datos, el algoritmo **PAM** aporta una mayor robustez analítica en este conjunto de datos específico. Al utilizar *medoides* (puntos reales) en lugar de centroides calculados, PAM mitiga el impacto de los valores atípicos presentes en variables de alta dispersión como *duration* o *campaign*, y gestiona de forma más coherente los valores extremos de la variable *pdays*.

Jerárquico

Para el clustering jerárquico, utilizaremos una estrategia aglomerativa fundamentada en los siguientes criterios técnicos:

- **Distancia euclídea:** Seleccionamos esta métrica de disimilitud al ser la medida geométrica estándar para variables numéricas. Como los datos han sido estandarizados previamente, la distancia euclídea permite que todas las variables contribuyan equitativamente al cálculo de la separación entre individuos, evitando que las variables con magnitudes mayores (como *pdays*) dominen el análisis.
- **Método agregación de Ward (Ward.D2):** Hemos elegido el método de Ward debido a su capacidad para minimizar la pérdida de información en cada etapa de la agrupación. A diferencia de otros métodos de enlace, Ward tiende a generar clústeres compactos, esféricos y con tamaños equilibrados. Esta característica es esencial para una segmentación de marketing, nuestro caso, efectiva, ya que facilita la definición de perfiles de cliente claros y accesibles.

Árbol jerárquico



Con el dendrograma obtenido mediante el método de Ward, se ha validado la estructura de **3 clases**, resaltadas mediante un corte horizontal en el eje de altura (*height*). Esta partición permite diferenciar claramente los perfiles de comportamiento de la muestra:

- **Clúster azul:** Ocupa la mayor parte de la base del dendrograma. Representa el perfil de cliente estándar o mayoritario del banco, caracterizado por una receptividad media y, fundamentalmente, por no haber sido contactado con éxito en campañas anteriores.
- **Clúster naranja:** Este agrupa a un segmento reducido de clientes con una conducta específica durante la campaña actual. Destaca por presentar una presión comercial elevada (mayor número de contactos en *campaign*) o por pertenecer a nichos demográficos muy concretos que los separan del promedio.

- **Clúster verde:** Finalmente, este representa el grupo de clientes fidelizados o con resultados positivos en el pasado. Este grupo es pequeño pero altamente diferenciado.

El gráfico confirma que, aunque la mayoría de los clientes siguen un patrón común (Azul), existen dos nichos específicos (Naranja y Verde) que requieren estrategias de comunicación y oferta diferenciadas.

Profiling

El objetivo del profiling es interpretar y caracterizar los grupos obtenidos en el clustering: las técnicas como K-Means y PAM aplicadas anteriormente nos permiten identificar estructuras internas en los datos, pero el profiling nos permite darles significado.

Por este motivo, partimos del conjunto de datos utilizado en el clustering, al que se le añade la variable `cluster`, que indica la pertenencia de cada observación a uno de los grupos identificados.

Utilizaremos el profiling para PAM, ya que es un método más robusto y nos dará mejores resultados.

Visualizar las relaciones entre parejas de variables y clases

Fase 1: Significación de las variables

En esta primera fase pretendemos identificar qué variables permiten diferenciar de forma significativa los distintos clústeres. Para ello, se consideran todas las variables del conjunto excepto la variable `cluster`.

Aplicamos la función vista en clase que nos permite:

- **Para variables numéricas:**
  - Evaluar la normalidad mediante el test de Shapiro- Wilk.
  - Si la variable sigue una distribución normal, se aplica un ANOVA.
  - En caso contrario, se utiliza el test no paramétrico de Kruskal-Wallis.
- **Para variables categóricas:**
  - Se aplica el test chi-cuadrado de independencia, que permite analizar si hay relación entre variable y clúster.

Para seleccionar estas variables usamos el p.valor. Si este es menor de 0.05, rechazamos la hipótesis nula de igualdad, por lo que la variable se considera significativa. En caso contrario, no se considera relevante para diferenciar los grupos.

Una vez aplicada la función, observamos las variables que resultan significativas.

```
##  [1] "age"           "job"           "marital"       "education"
##  [5] "default"       "contact"       "month"         "duration"
##  [9] "campaign"      "pdays"         "previous"      "poutcome"
## [13] "emp.var.rate"  "cons.price.idx" "cons.conf.idx" "euribor3m"
## [17] "nr.employed"   "y"
```

En este caso 18 de las 22 variables resultan significativas, lo cual podría indicar que los clústers presentan diferencias relevantes en varias dimensiones y que no existe una única variable que explique estos grupos.

Una vez identificadas las variables significativas en la Fase 1, se procede a analizar cómo se distribuyen las variables numéricas dentro de cada clúster.

Para conseguirlo, usamos la función `psych::describeBy`, que permite obtener los principales estadísticos descriptivos de cada variable para cada grupo de clusterización. Primero lo hacemos para las numéricas:

La salida de la función ocupa mucho espacio, para solventar este problema, hemos creado una tabla resumen con las medias de variables por clústers.

Table 9: Medias numéricas de variables por clúster

variable	Cluster_1	Cluster_2	Cluster_3
age	33.23	50.36	40.52
duration	252.94	256.41	331.04
campaign	2.54	2.65	1.94
pdays	999.00	999.00	36.79
previous	0.11	0.11	1.79

A partir de los estadísticos descriptivos obtenidos, observamos diferencias claras entre los tres clústeres en varias variables o dimensiones:

- **Grupo 1:** Jóvenes (edad media de 33 años), sin experiencia previa en la campaña (previous = 0) y comportamiento moderado (duration = 253).
- **Grupo 2:** Individuos de mayor edad (media de 50 años), también sin contacto previo (previous = 0), pero con características similares al clúster 1 en comportamiento.
- **Grupo 3:** Grupo más pequeño y diferenciado, con contactos previos, menor precisión en campaña y mayor duración de la interacción.

Una vez analizadas las numéricas, procedemos a estudiar las categóricas con el objetivo de identificar los factores predominantes en cada clúster. Para eso, calculamos la moda de cada variable categórica dentro de cada grupo, es decir, la categoría más frecuente en cada clúster.

Table 10: Categorías más frecuentes por variables y clúster

variable	Cluster_1	Cluster_2	Cluster_3
job	admin.	blue-collar	admin.
marital	married	married	married
education	university.degree	university.degree	university.degree
default	no	no	no
contact	cellular	cellular	cellular
month	may	may	may
poutcome	nonexistent	nonexistent	success
y	no	no	yes

A partir de los resultados obtenidos, observamos los siguientes patrones:

- Algunas variables presentan la misma modalidad dominante en los tres grupos: predominan individuos casados en todos los clústers, los estudios universitarios, la mayoría no presenta impagos y predomina el contacto

vía móvil. Esto indica que estas variables carecen de poder discriminante entre los clústeres, aunque fueran significativas en la fase 1.

- Hay algunas variables que sí que diferencian a los clústers:
  - `job`: El clúster 2 presenta un perfil laboral distinto, más orientado a trabajos manuales.
  - `month`: El clúster 3 se sitúa en un momento temporal diferente, esto puede indicar un contexto distinto de campaña.
  - `poutcome`: Entre los clústeres 1 y 2 predominan los que no tienen historial previo de clientes, a diferencia del clúster 3, dónde se registran clientes con experiencia previa exitosa.
  - `y`: El clúster 3 concentra la respuesta positiva a la campaña, lo que lo convierte en el grupo más interesante desde el punto de vista del negocio.

En conjunto, las variables categóricas permiten identificar que la principal diferencia entre los clústeres no solo es demográfica, sino también en cuanto al historial con la campaña y de respuesta. Siendo el clúster 3 el grupo claramente diferenciado (cómo observábamos en los gráficos de los clusters), formado por clientes con experiencia previa exitosa, mayor interacción y mayor probabilidad de respuesta positiva.

Fase 2: Caracterización de los clústers

En la Fase 1 hemos visto qué variables diferencian los clústeres. En la fase 2 tenemos el objetivo de caracterizar en mayor detalle los clústeres obtenidos, para ello, se ha aplicado la función `catdes`. Esta nos permite identificar, de forma automática, qué variables y que modalidades están significativamente asociadas a cada grupo.

Como en los casos anteriores, estas funciones son para exploración y las salidas ocupan mucho espacio, para evitar esto, usaremos tablas resúmenes de cada parte.

Table 11: Variables numéricas más significativas por clúster

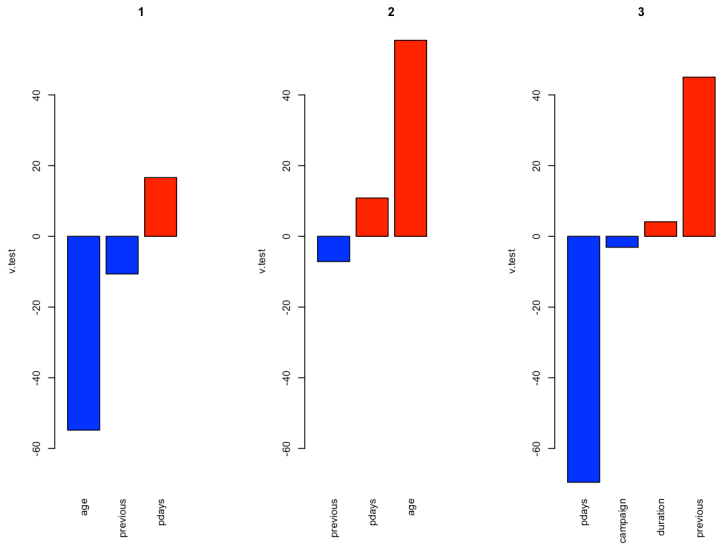
cluster	variable	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
1	age	-54.808	33.229	39.948	4.697	10.304	0.000
1	pdays	16.613	999.000	961.666	0.000	188.881	0.000
1	previous	-10.639	0.113	0.178	0.346	0.510	0.000
2	age	55.437	50.365	39.948	6.984	10.304	0.000
2	pdays	10.839	999.000	961.666	0.000	188.881	0.000
2	previous	-7.131	0.111	0.178	0.341	0.510	0.000
3	previous	45.021	1.794	0.178	1.030	0.510	0.000
3	pdays	-69.558	36.794	961.666	171.941	188.881	0.000
3	duration	4.123	331.041	257.273	252.220	254.161	0.000
3	campaign	-3.096	1.938	2.558	1.349	2.842	0.002

Los resultados confirman que las variables más relevantes para la diferenciación entre clústeres son `age`, `pdays`, `previous`, `poutcome` y `y`. Esto refuerza las conclusiones que hemos obtenido en la Fase 1.

En particular, el clúster 1 se asocia con individuos jóvenes, solteros y sin historial previo de campaña; el clúster 2 con individuos de mayor edad, casados y retirados; y el clúster 3 con clientes previamente contactados con éxito, mayor probabilidad de respuesta positiva y menor número de contactos necesarios en la campaña actual.

Visualizaciones en mapas de clases

Para complementar la interpretación de los clústeres, representaremos los mapas de clases obtenidos con `catdes`.

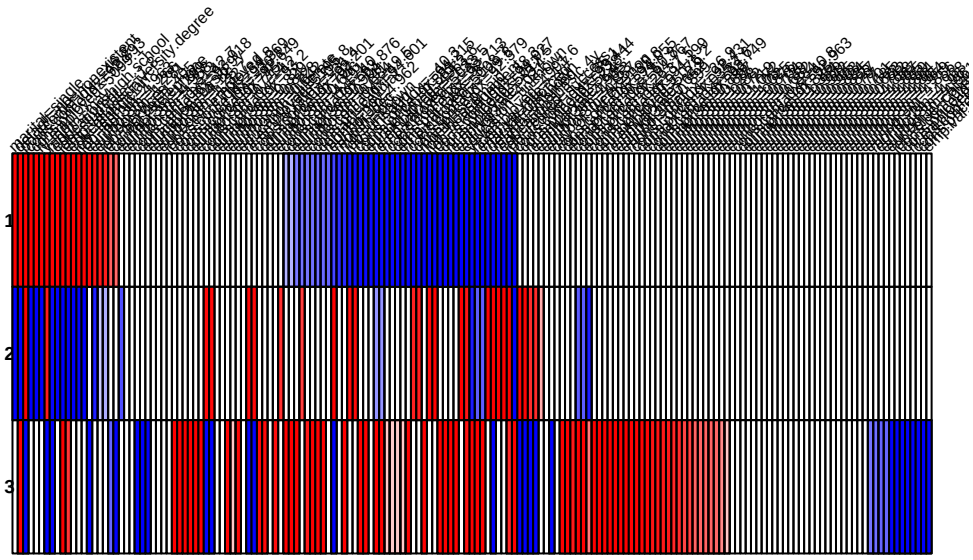


Este mapa de clases nos indica:

- **Clúster 1:** Se caracteriza por una edad claramente inferior a la media global y tiene valores altos de `pdays`, mientras que `previous` está por debajo. Esto nos reafirma lo que ya sabíamos: encaja con un perfil de clientes jóvenes y sin historial previo de contacto.
- **Clúster 2:** Destaca por una edad claramente superior a la media global. Representa un perfil de clientes de mayor edad, pero igualmente sin contacto previo.
- **Clúster 3:** Presenta el patrón opuesto en `pdays` y `previous`, el primero muy por debajo y el segundo muy por encima. Esto sugiere un grupo de clientes ya conocidos, con contacto reciente, más historial y mayor probabilidad de interacción positiva.

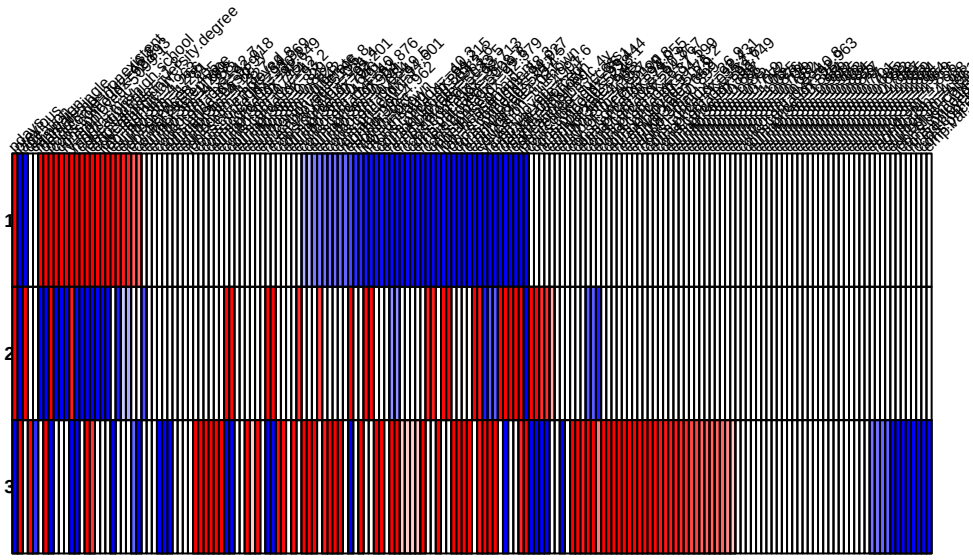
Este mapa de clases de variables cuantitativas confirma que la principal separación entre los clústeres viene dada por la edad y la experiencia previa con la campaña.

En el siguiente gráfico, haremos un mapa de clases cualitativas:



Aunque este gráfico es visualmente más difícil de leer, ya que hay muchas categorías, nos sirve para reforzar la diferenciación entre grupos. En particular en el clúster 3, que concentra modalidades asociadas al éxito previo y a la respuesta positiva en la campaña actual.

Por último, haremos un mapa global con la información cualitativa y cuantitativa.



Este resume la estructura obtenida: dos grupos mayoritarios sin experiencia previa en la campaña, diferenciados principalmente por la edad, y un tercer grupo, más pequeño, pero claramente diferente, asociado a clientes previamente contactados con éxito.

Para completar la caracterización de los clústeres, se usa la función `cluster.carac`, que permite identificar qué variables cuantitativas presentan diferencias significativas respecto a la media global en cada grupo.

Table 12: Top 5 variables continuas más características de cada clúster

cluster	variable	Test.Value	Class.Mean	Global.Mean
1	age	-54.808	33.229	39.948
1	pdays	16.613	999.000	961.666
1	previous	-10.639	0.113	0.178
1	cons.conf.idx	-6.244	-41.009	-40.668
1	nr.employed	4.723	5170.009	5165.923
2	age	55.437	50.365	39.948
2	pdays	10.839	999.000	961.666
2	previous	-7.131	0.111	0.178
2	euribor3m	6.112	3.783	3.589
2	nr.employed	6.062	5173.961	5165.923
3	pdays	-69.558	36.794	961.666
3	previous	45.021	1.794	0.178
3	nr.employed	-27.249	5026.436	5165.923
3	euribor3m	-21.213	0.989	3.589
3	emp.var.rate	-18.593	-1.995	0.056

Table 13: Top 5 modalidades más características de cada clúster

cluster	modalidad	Test.Value	p.Value	Class.Cat
1	marital.single	20.809	0	81.2
1	default.no	9.784	0	62.1
1	poutcome.nonexistent	8.430	0	60.9
1	y.no	5.461	0	59.9
1	month.may	5.376	0	63.8
2	job.retired	15.104	0	86.7
2	marital.married	13.930	0	45.1
2	education.basic.4y	13.309	0	65.7
2	default.unknown	11.900	0	53.6
2	marital.divorced	8.945	0	55.0
3	poutcome.success	36.600	0	100.0
3	y.yes	16.985	0	20.3
3	contact.cellular	10.038	0	5.7
3	job.student	6.609	0	20.0
3	month.oct	5.883	0	20.5

Los resultados confirman los patrones observados previamente. El clúster 1 se caracteriza por individuos significativamente más jóvenes, sin experiencia previa en la campaña y sin contactos recientes. El clúster 2 agrupa individuos de mayor edad, también sin historial previo, pero asociados a valores más altos de variables económicas.

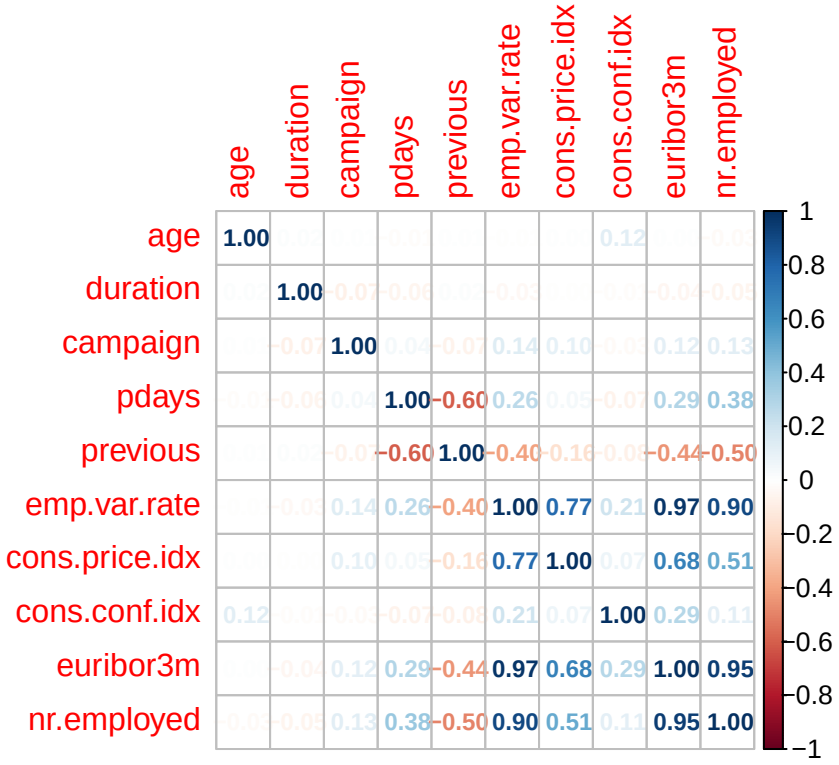
Por su parte, el clúster 3 presenta un comportamiento claramente diferenciado, con valores elevados en la variable `previous` y muy bajos en `pdays`, lo que indica contacto reciente con la identidad. Además, el grupo presenta mayor duración de interacción y menor número de intentos de contacto, lo que sugiere una mayor eficacia en la campaña.

ACP

Primeramente, construimos la matriz X, que contiene únicamente las variables numéricas del conjunto de datos. Este paso es necesario ya que ACP solo puede aplicarse sobre variables cuantitativas. Posteriormente, eliminamos variables con valores faltantes, puesto que la presencia de variables incompletas impediría realizar correctamente el análisis.

Seguidamente, calculamos las varianzas y las desviaciones de las variables, las cuales nos indican que están medidas en escalas diferentes, por tanto para hacer ACP necesitaremos estandarizar.

Por último, calculamos la matriz de correlaciones entre las variables numéricas y la representamos gráficamente. Esta matriz permite identificar relaciones lineales entre variables y detectar posibles multicolinealidades o redundancias.



Respecto a los resultados son los mismos obtenidos en el estudio bivariante.

En cuanto a los resultados, observamos fuertes correlaciones entre variables económicas. En concreto, emp.var.rate, euribor3m y nr.employed, las cuales presentan correlaciones positivas muy elevadas, lo que nos indica que contienen información muy similar.

Por otro lado, la variable previous presenta correlaciones negativas con pdays y con algunas variables económicas, lo que sugiere una relación inversa entre el historial previo de contactos y el contexto económico o de campaña.

Resultados principales del análisis

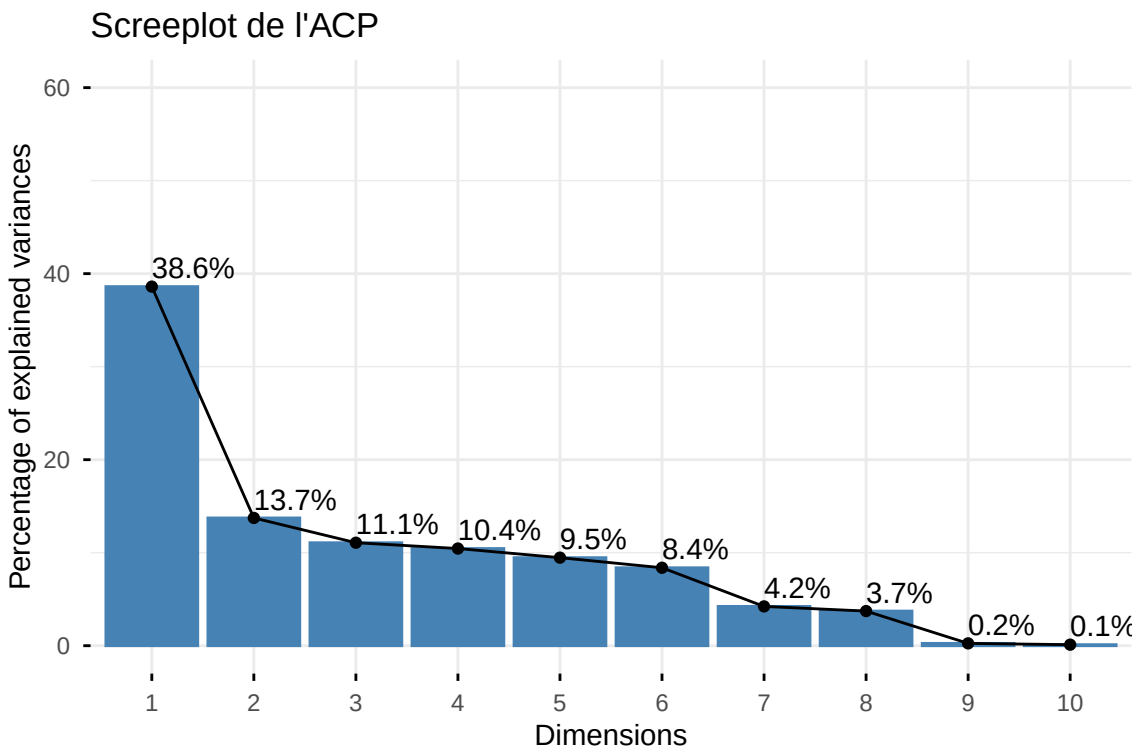
Ahora procedemos a realizar el Análisis de Componentes principales sobre la matriz X utilizando la función *PCA()* y estandarizando las variables.

```
## Principal Component Analysis Results for variables
##  ===================================================
##   Name       Description
## 1 "$coord"   "Coordinates for the variables"
## 2 "$cor"     "Correlations between variables and dimensions"
## 3 "$cos2"    "Cos2 for the variables"
## 4 "$contrib" "contributions of the variables"
```

Table 14: Valores propios de ACP

	eigenvalue	variance.percent	cumulative.variance.percent
Dim.1	3.861	38.607	38.607
Dim.2	1.373	13.734	52.341
Dim.3	1.107	11.070	63.412
Dim.4	1.045	10.445	73.857
Dim.5	0.946	9.464	83.321
Dim.6	0.838	8.378	91.699
Dim.7	0.422	4.222	95.922
Dim.8	0.372	3.721	99.642
Dim.9	0.025	0.249	99.891
Dim.10	0.011	0.109	100.000

Los valores propios indican cuánta variabilidad explica cada componente principal. La tabla muestra que la primera dimensión tiene un valor propio de 3.861 y explica el 38.607% de la variabilidad total. La segunda dimensión explica un 13.734%, de manera que las dos primeras componentes acumulan un 52.341% de la variabilidad. Si se añaden la tercera y la cuarta dimensión, la variabilidad acumulada alcanza el 73.857%. A partir de la quinta dimensión, el valor propio es inferior a 1, por lo que estas componentes aportan menos información que una variable original estandarizada.

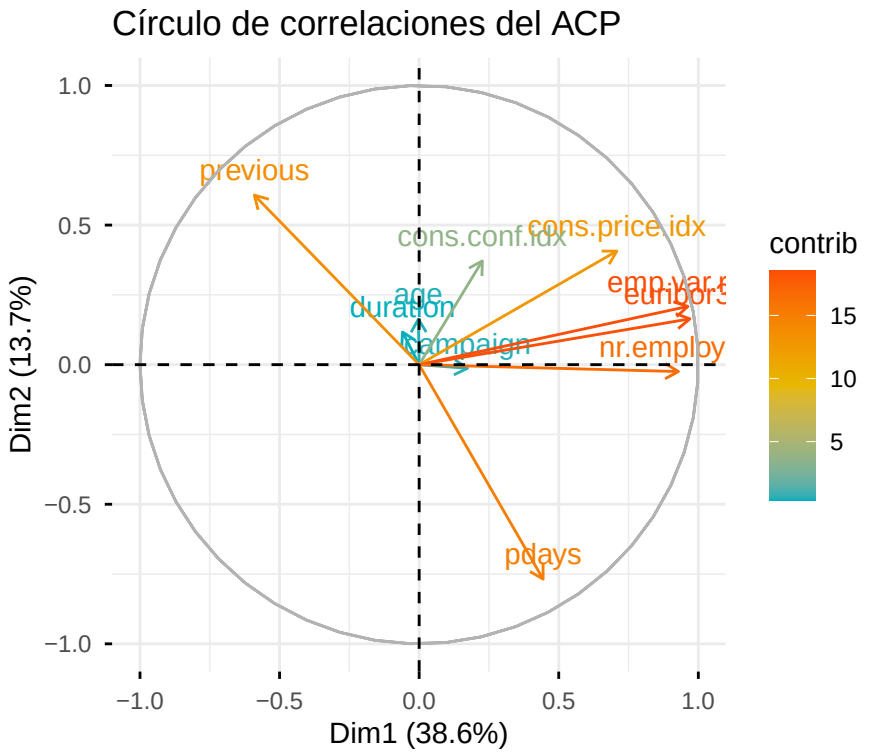


El screeplot muestra el porcentaje de varianza explicada por cada una de las componentes principales. Observamos claramente que la primera componente explica una proporción muy elevada de variabilidad total (38.6%), lo que nos indica que recoge gran parte de la información del conjunto de los datos.

A partir de la segunda componente, la varianza explicada disminuye de forma notable (13.7%), y continúa disminuyendo progresivamente en las siguientes dimensiones.

Visualmente podemos apreciar una especie de codo en el gráfico entre la segunda y la tercera componente. A partir de este punto llamado codo, la reducción de varianza explicada es más suave, lo que sugiere que las componentes adicionales aportan información cada vez menos relevante.

Por tanto, para la interpretación gráfica y conceptual del ACP, utilizaremos principalmente las dos primeras componentes, ya que permiten una representación en un número manejable de componentes manteniendo una cantidad significativa de información. No obstante, las componentes tercera y cuarta también podrían considerarse en análisis más detallados.



El círculo de correlaciones representa la relación entre variables originales y las dos primeras componentes principales. En la primera dimensión, observamos que variables como emp.var.rate, euribor3m, nr.employed y cons.price.idx están fuertemente alineadas en la misma dirección. Esto nos confirma los resultados obtenidos previamente, que están altamente correlacionadas positivamente y que contribuyen de forma importante a esta dimensión. Por tanto, podríamos interpretar la primera componente como un eje asociado al contexto económico.

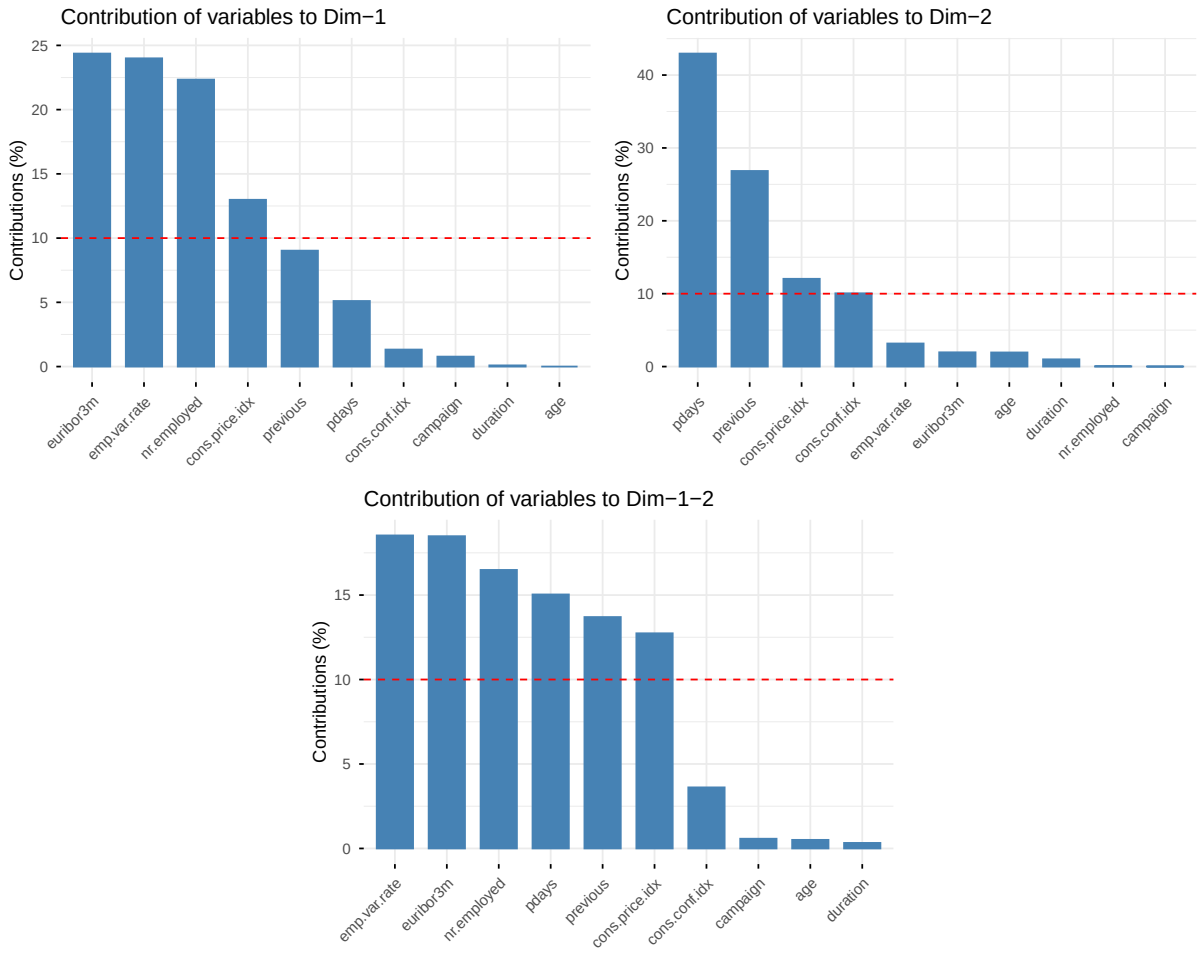
Por otro lado, variables como previous aparecen en dirección opuesta respecto a estas variables económicas, lo que indica una correlación negativa. Esto sugiere que un mayor número de contactos previos se asocia a valores más bajos en variables económicas.

En la segunda dimensión destaca pdays, que representa una contribución relevante en dirección negativa. Las variables cons.conf.idx y cons.price.idx también presentan contribuciones importantes positivas aunque en menor medida.

Las variables age, duration y campaign se encuentran cercanas al origen, esto indica que están peor representadas por las dos primeras dimensiones y, por tanto, su contribución es menor.

En conclusión, el gráfico nos permite identificar bien dos grandes bloques: por un lado un bloque constituido por variables económicas fuertemente correlacionadas entre sí, y por otro lado, variables relacionadas con el cliente.

Contribución de las variables



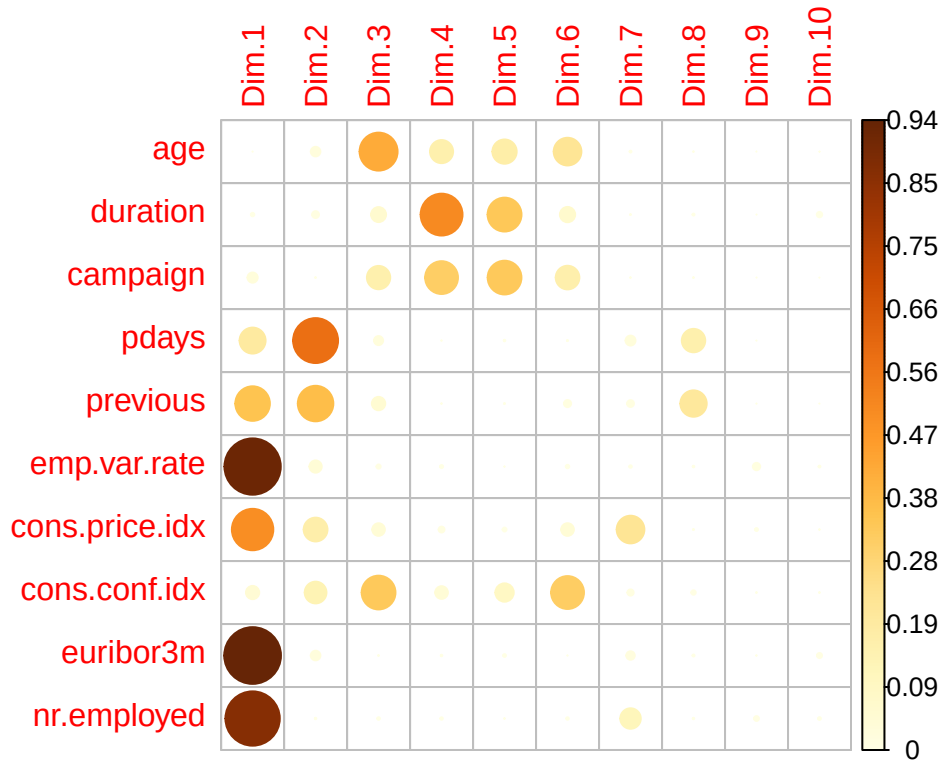
Estos gráficos de contribución nos permite identificar qué variables son las más importantes en la construcción de cada dimensión. En la primera dimensión, las variables que más contribuyen son euribor3m, emp.var.rate y nr.employed, seguidas de cons.price.idx. Todas ellas superan la contribución media representada por la línea roja. Este hecho nos confirma la interpretación de la dimensión uno dentro de un contexto económico.

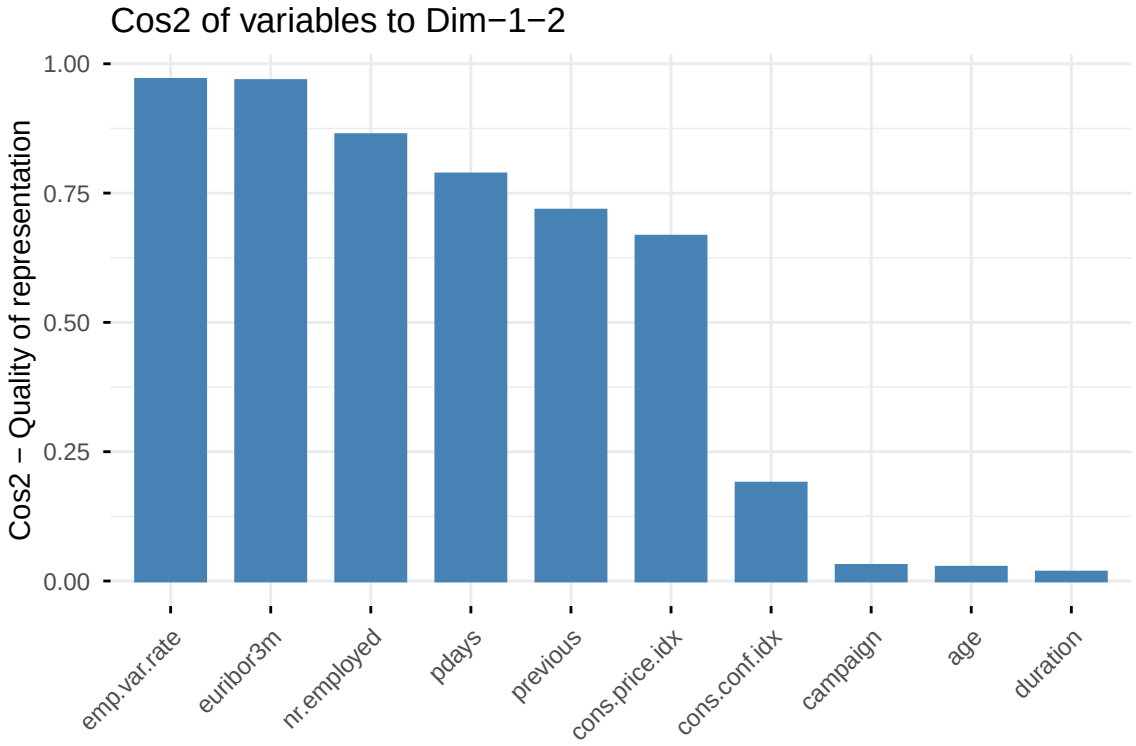
En la segunda dimensión, las variables que más contribuyen son pdays, seguida de previous. Esto indica que esta dimensión está principalmente relacionada con el historial de contacto con el cliente y ciertos aspectos de percepción económica.

Si consideramos conjuntamente las dimensiones 1 y 2, las variables más influyentes son emp.var.rate, euribor3m, nr.employed, pdays y previous. Estas variables son las que mejor explican la estructura de los datos.

La calidad de representación (cos^2) indica qué tan bien quedan representadas las variables en el plano formado por las dos primeras componentes.

Calidad de la representación





Observamos que emp.var.rate, euribor3m y nr.employed presentan valores de cos^2 muy elevados, cercanos a 1, lo que

indica que están muy bien representadas en el plano constituido por las dimensiones 1 y 2. También pdays y previous muestran una buena calidad de representación.

Por el contrario, como hemos mencionado anteriormente, las variables age, duration y campaign tienen valores bajos de cos^2, lo que indica que están peor representadas y su interpretación es limitada.

Descripción de las dimensiones

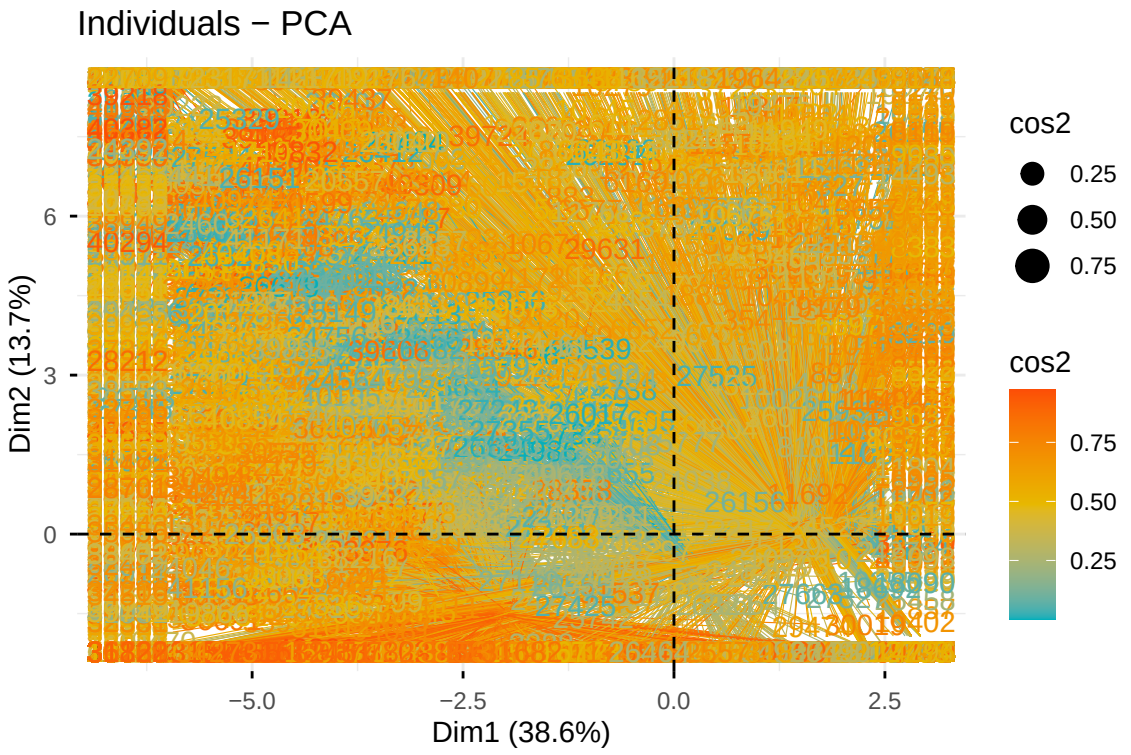
La descripción de las dimensiones permite identificar qué variables están más asociadas a cada componente principal y si esta relación es estadísticamente significativa.

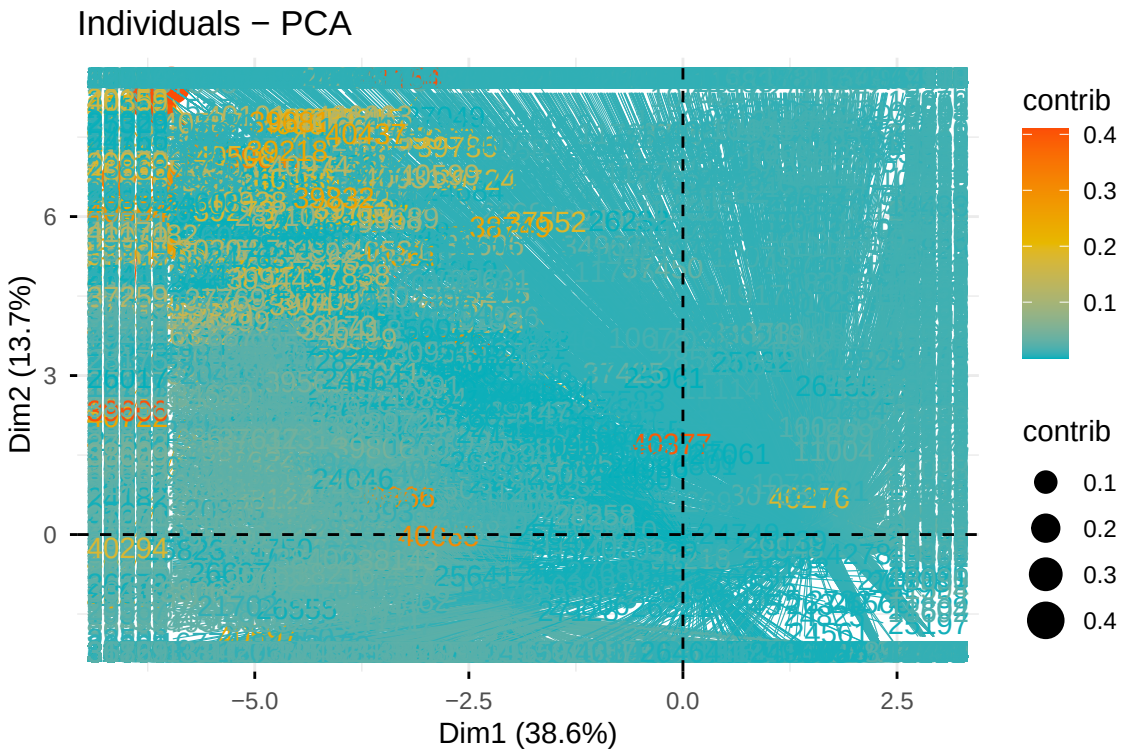
En la primera dimensión las variables más correlacionadas son euribor3m, emp.var.rate y nr.employed, con valores de correlación muy elevados y p-valores prácticamente nulos.

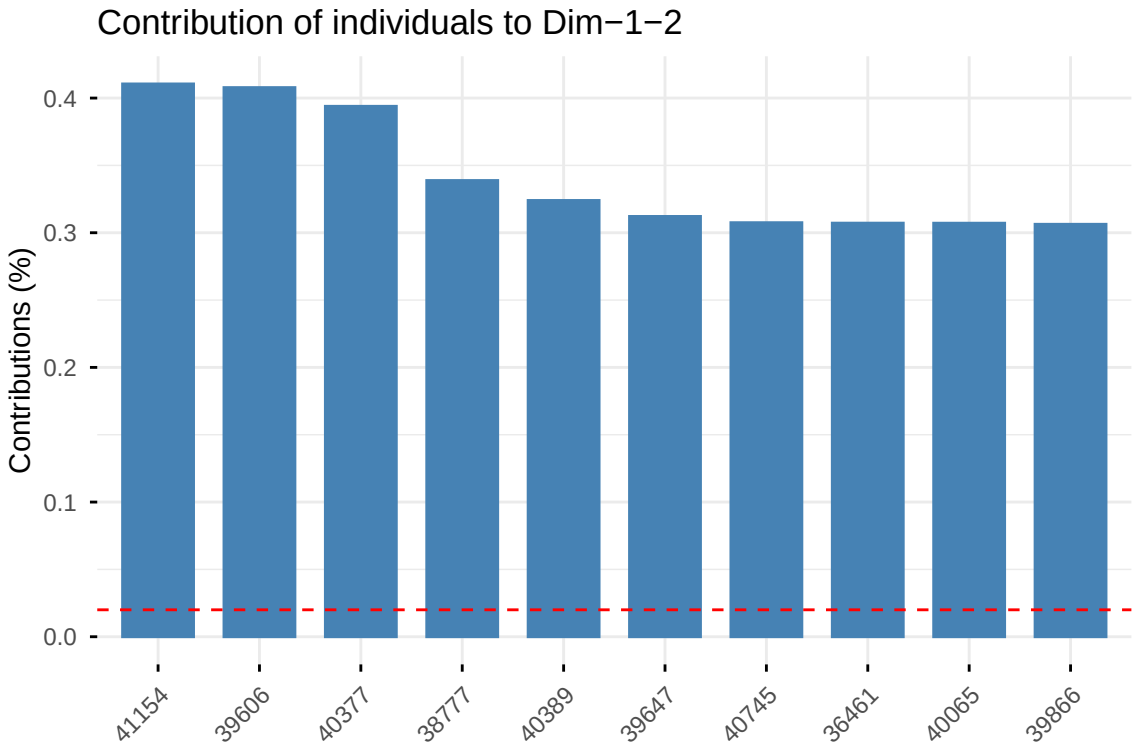
En la segunda dimensión, destacan principalmente previous y pdays, lo que indica que esta dimensión está asociada al historial de contacto con el cliente.

Añadimos la tercera dimensión para detallar nuestro análisis, pero observamos que las variables relevantes son menos claras y presentan una menor capacidad explicativa.

Interpretación de las relaciones entre variables y entre individuos





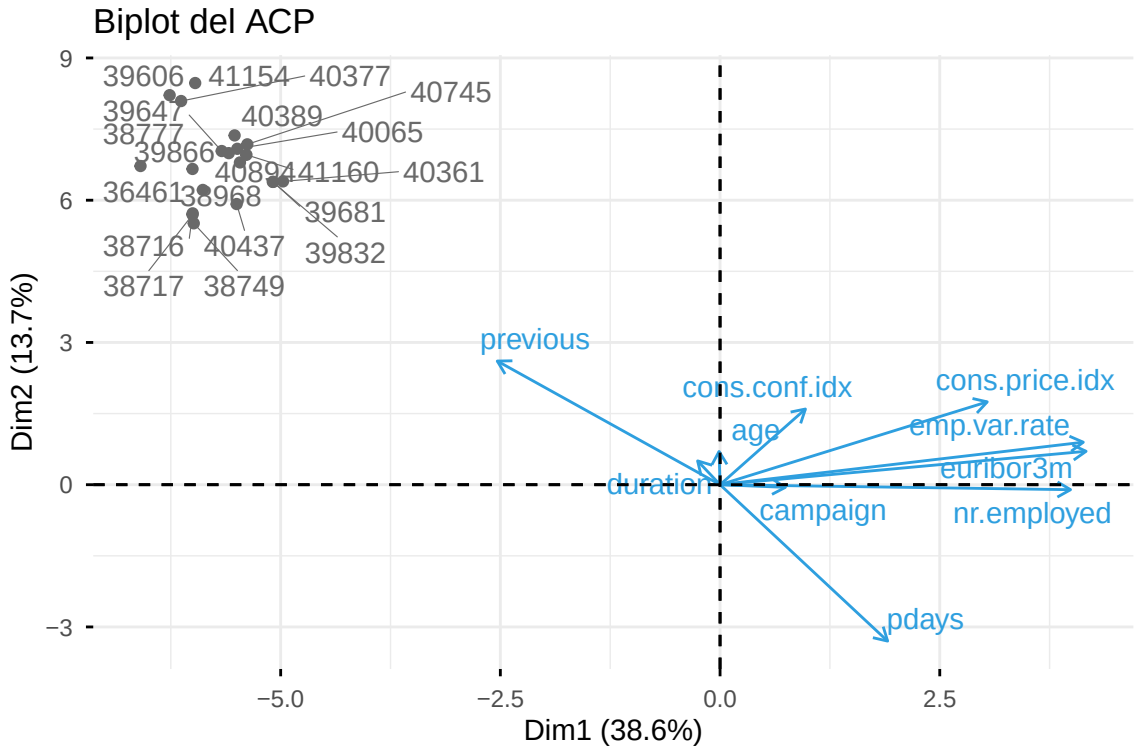


En el gráfico basado en el cos^2, vemos como los individuos mejor representados, es decir, los que tienen un color más intenso y mayor tamaño, son aquellos situados más lejos del origen. Por el contrario, los individuos cercanos al centro presentan baja calidad de representación.

En cuanto a la contribución, observamos que solo un pequeño grupo de individuos tiene una contribución destacada en la formación de las dimensiones. Estos individuos se sitúan en extremos del gráfico y son los más influyentes en la construcción de las dimensiones. Este hecho nos muestra que la mayoría de individuos presentan aportaciones bajas.

En conjunto, los individuos extremos son los que determinan la estructura del ACP, mientras que la mayoría de observaciones se agrupan alrededor del perfil medio.

El biplot nos permite interpretar a la vez la relación entre variables e individuos en las dos primeras componentes principales.



En este gráfico, observamos que las variables económicas como emp.var.rate, euribor3m, nr.employed y cons.price.idx apuntan en la misma dirección, lo que confirma su correlación altamente positiva y su importancia dentro de la primera dimensión.

Por otra parte, las variables previous y pdays aparecen en dirección contraria, indicando una relación negativa con el grupo de variables económicas.

En cuanto a los individuos, aquellos situados en la dirección de las variables económicas presentan valores más elevados en esas variables, mientras que los situados en dirección opuesta muestran valores más bajos. De la misma forma, individuos con direcciones similares a la de pdays o previous presentan características asociadas al historial de contacto.

Además, los individuos más alejados del origen son los más diferenciados y los que mejor se explican por las dos dimensiones principales, mientras que los cercanos al medio representan un perfil medio del individuo.

Conclusiones

En conclusión, el ACP nos ha permitido reducir la dimensión del conjunto de variables identificando las principales fuentes de variabilidad. Los resultados muestran una estructura clara constituida por dos grandes grupos: una primera dimensión asociada a variables económicas y definida por variables como emp.var.rate y euribor3m, y una segunda dimensión relacionada con el historial del cliente donde destacan variables como previous. La mayoría de individuos presentan perfiles cercanos a la media, mientras que los más extremos nos ayudan a formar la estructura del análisis.

ACM

El Análisis de Correspondencias Múltiples se aplica sobre las variables cualitativas del conjunto de datos con el objetivo de analizar las relaciones entre las distintas categorías. Éste nos ayuda a analizar las dependencias entre variables categóricas y a reducir la dimensionalidad.

Resultados principales del análisis

Antes de realizar el ACM, revisamos las variables cualitativas para detectar categorías problemáticas. Aunque tras el preprocesamiento no había valores NA explícitos, algunas variables contenían la categoría unknown, que representa información no disponible y no es una categoría interpretable.

Por tanto, hemos decidido tratar unknown como un valor faltante y después eliminar las observaciones incompletas únicamente para este análisis.

Table 15: Frecuencias relativas de variables cualitativas

Variable	Categoria	n	Proporcion
contact	cellular	3182	0.636
contact	telephone	1818	0.364
day_of_week	thu	1100	0.220
day_of_week	mon	1052	0.210
day_of_week	tue	974	0.195
day_of_week	fri	947	0.189
day_of_week	wed	927	0.185
default	no	3955	0.791
default	unknown	1045	0.209
education	university.degree	1480	0.296
education	high.school	1122	0.224
education	basic.9y	776	0.155
education	professional.course	643	0.129
education	basic.4y	492	0.098
education	basic.6y	266	0.053
education	unknown	217	0.043
education	illiterate	4	0.001
housing	yes	2575	0.515
housing	no	2331	0.466
housing	unknown	94	0.019
job	admin.	1274	0.255
job	blue-collar	1132	0.226
job	technician	779	0.156
job	services	470	0.094
job	management	381	0.076

job	retired	211	0.042
job	entrepreneur	174	0.035
job	self-employed	175	0.035
job	housemaid	133	0.027
job	unemployed	118	0.024
job	student	115	0.023
job	unknown	38	0.008
loan	no	4181	0.836
loan	yes	725	0.145
loan	unknown	94	0.019
marital	married	3050	0.610
marital	single	1380	0.276
marital	divorced	564	0.113
marital	unknown	6	0.001
month	may	1661	0.332
month	jul	873	0.175
month	aug	700	0.140
month	jun	682	0.136
month	nov	511	0.102
month	apr	325	0.065
month	oct	88	0.018
month	mar	74	0.015
month	sep	63	0.013
month	dec	23	0.005
poutcome	nonexistent	4309	0.862
poutcome	failure	520	0.104
poutcome	success	171	0.034
y	no	4413	0.883
y	yes	587	0.117

Para realizar el ACM nos basaremos en el método basado en la matriz indicadora. No obstante, sabemos que en el ACM los valores propios tienden a sobreestimar la varianza explicada, por este motivo consideramos la corrección de Benzécri sobre los valores propios.

A partir del resumen, observamos que la variabilidad explicada por cada dimensión es relativamente baja y se distribuye de forma más uniforme en el ACP. En concreto, la primera dimensión explica aproximadamente un 5.45% de la varabilidad, mientras que la segunda dimensión un 4.47%, acumulando ambas tan solo un 9.92%.

Para determinar el número de dimensiones, utilizamos distintos criterios. En primer lugar, consideraremos aquellas dimensiones con valores superiores a $1/p$, donde p es el número de variables categóricas.

En segundo lugar, nos basaremos en el Screeplot. El Screeplot muestra la variabilidad explicada por cada dimensión del ACM, entonces escogeremos el punto en el que haya una clara caída de la varianza explicada, es decir, el codo.

El criterio $\lambda > 1/p$ se cumple hasta aproximadamente la dimensión 18, lo que sugiere un número elevado de dimensiones relevantes. Este resultado es habitual en ACM ya que tiende a sobreestimar el número de dimensiones necesarias, por ello nos basamos también en el Screeplot.

En el gráfico observamos que la varianza explicada disminuye progresivamente sin presentar un codo claramente definido. A pesar de ello, utilizaremos las dos primeras dimensiones ya que concentran la mayor proporción de varianza explicada dentro del conjunto de dimensiones y permiten hacer una representación interpretable de los datos.

Comprobación de individuos y carcaterísticas

El Biplot permite representar a los individuos y a las categorías de las variables en las dos primeras dimensiones.

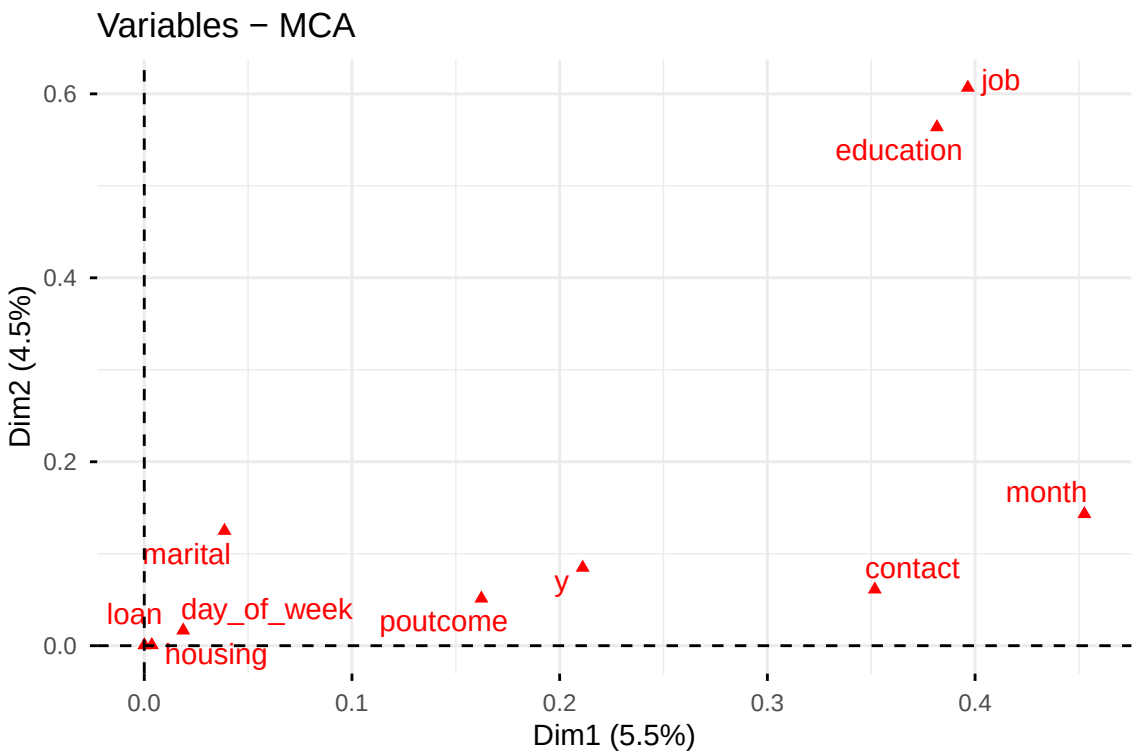
En este caso, el gráfico presenta una alta densidad de puntos, lo que nos dificulta hacer una lectura detallada a nivel individual. Aún así, podemos observar que la mayoría de los individuos se concentran alrededor del origen, por tanto, presentan perfiles medios sin características diferenciales.

La primera dimensión parece discriminar entre perfiles asociados a la respuesta de la campaña, situando en un extremo categorías basadas en la aceptación y el éxito y en otro aquellas relacionadas con la no respuesta. Por otra parte, la segunda dimensión refleja diferencias relacionadas con el perfil sociodemográfico, separando por profesiones y niveles educativos.

En conjunto, el gráfico nos sugiere que la respuesta a la campaña está asociada a características del cliente, aunque debido a la baja varianza explicada por las dos primeras dimensiones nos sugiere que las interpretaciones deben hacerse con cuidado.

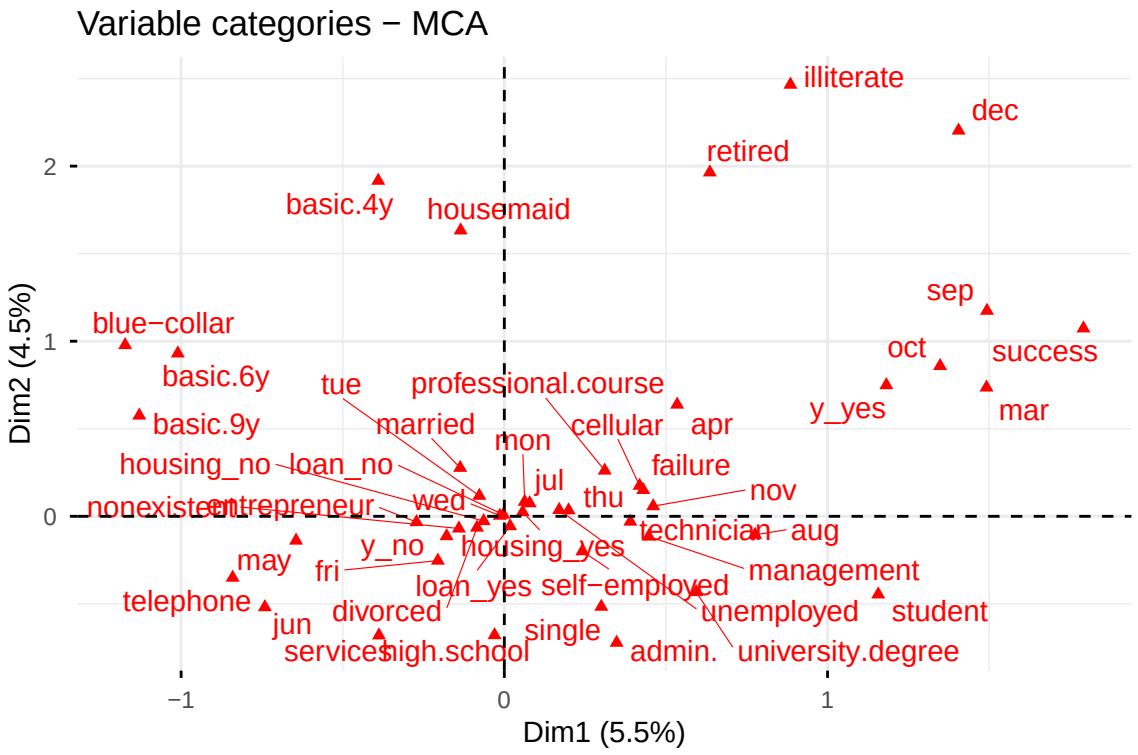
Variables en ACM

En este apartado analizamos las variables categóricas y sus categorías en relación con las dimensiones principales del ACM. En este caso utilizamos la pseudocorrelación, que mide el grado de asociación entre cada variables y las dimensiones.



Este gráfico muestra la pseudocorrelación entre variables categóricas y las dos primeras dimensiones. Observamos que variables como job, education, month y contact son las que más contribuyen a la definición de la dimensión 1, ya que están situadas en la esquina derecha indicando mayor capacidad explicativa. Por el contrario, las variables como loan, default, housing o marital aparecen muy cercanas al origen, lo que nos indica su poca relevancia. La segunda dimensión prácticamente no está explicada por ninguna variable fuerte, por tanto tiene una capacidad explicativa limitada.

Coordenadas de las categorías

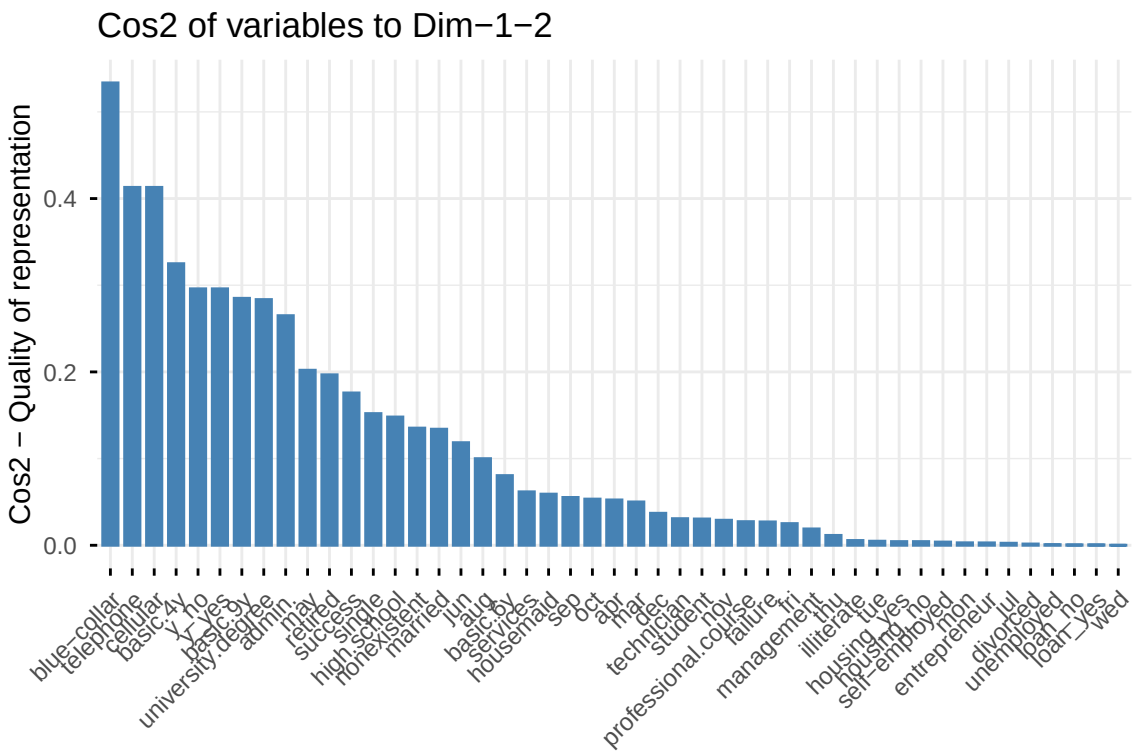


Este gráfico nos muestra claramente que la primera dimensión separa perfiles asociados a la respuesta de la campaña. A la derecha se sitúan categorías como y_yes, success, student o university.degree, mientras que a la izquierda aparecen y_no, blue-collar y niveles educativos inferiores, lo que sugiere una diferenciación entre clientes con mayor probabilidad de aceptación frente a aquellos con menor respuesta.

Por otro lado, la segunda dimensión recoge diferencias más específicas entre perfiles. Destacamos en la parte superior categorías como retired, illiterate o housemaid, las cuales corresponden a grupos más particulares, mientras que en la parte inferior se concentran perfiles más comunes.

Calidad de la representación

La calidad de representación indica qué categorías están mejor representadas en el plano principal. Las categorías con valores altos de cos^2 son las más fiables para interpretar las dimensiones.

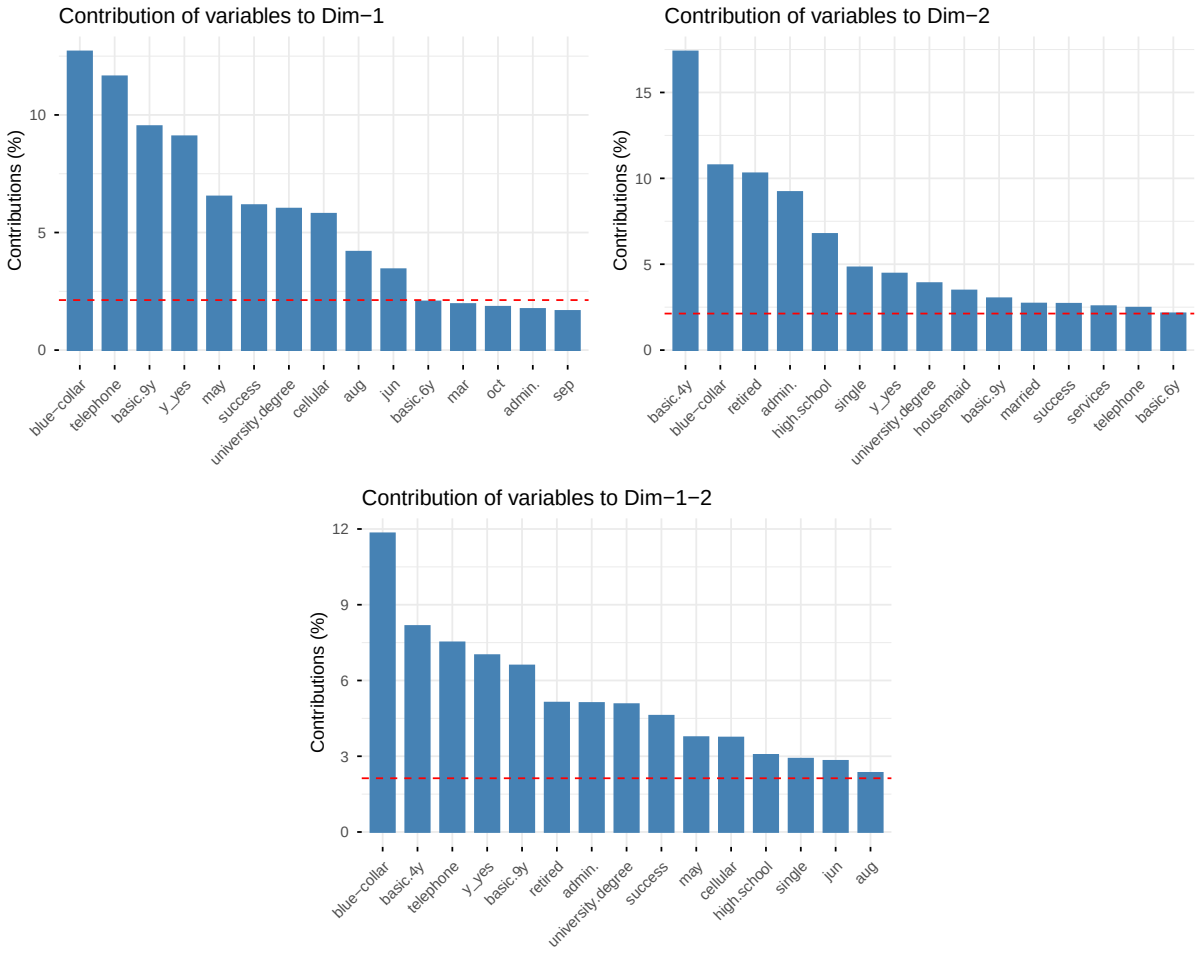


Observamos como solo un número reducido de categorías están bien representadas en las dos primeras dimensiones, destacando blue-collar, telephone, cellular, y algunos niveles educativos, que presentan valores de cos^2 más elevados. La mayoría de categorías tienen valores bajos, lo que indica que su interpretación en las dimensiones 1 y 2 debe interpretarse con cuidado.

Este resultado nos confirma que las dos primeras dimensiones recogen solo una parte limitada de la estructura de los datos, por lo que parte de la información relevante se encuentra en otras dimensiones.

Contribuciones

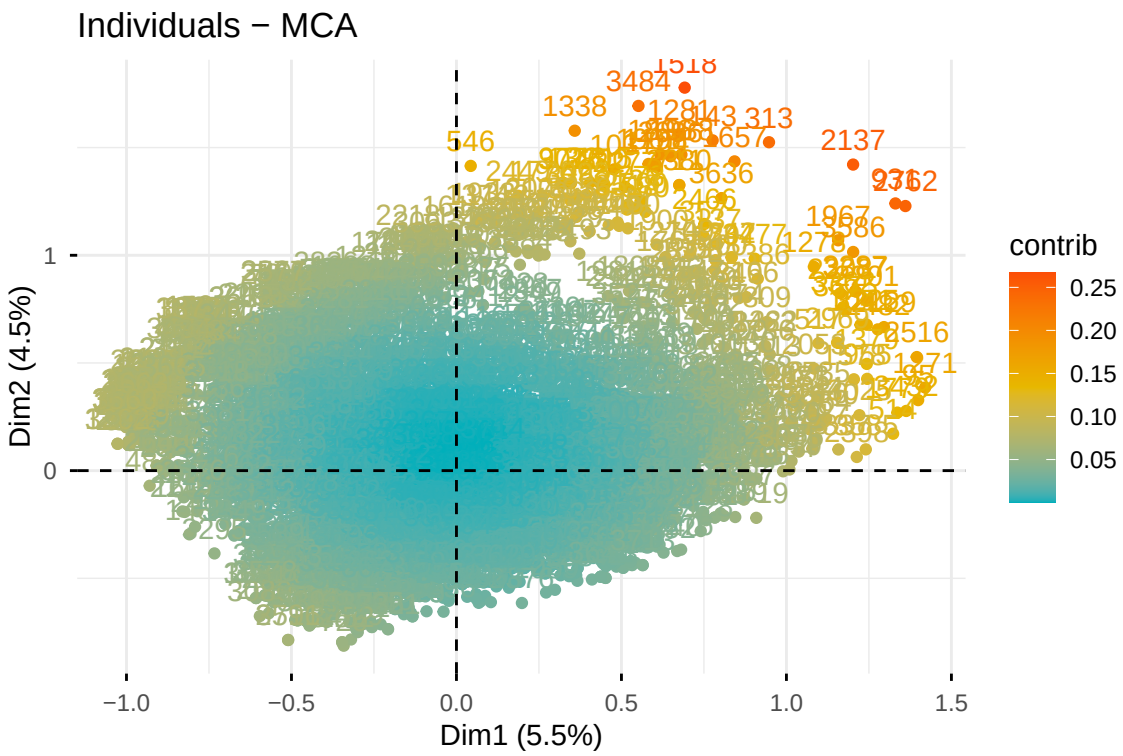
Las contribuciones permiten identificar qué categorías son las más importantes en cada dimensión. Aquellas que superan la contribución media son las que definen principalmente el eje y, por tanto, deben considerarse en su interpretación.



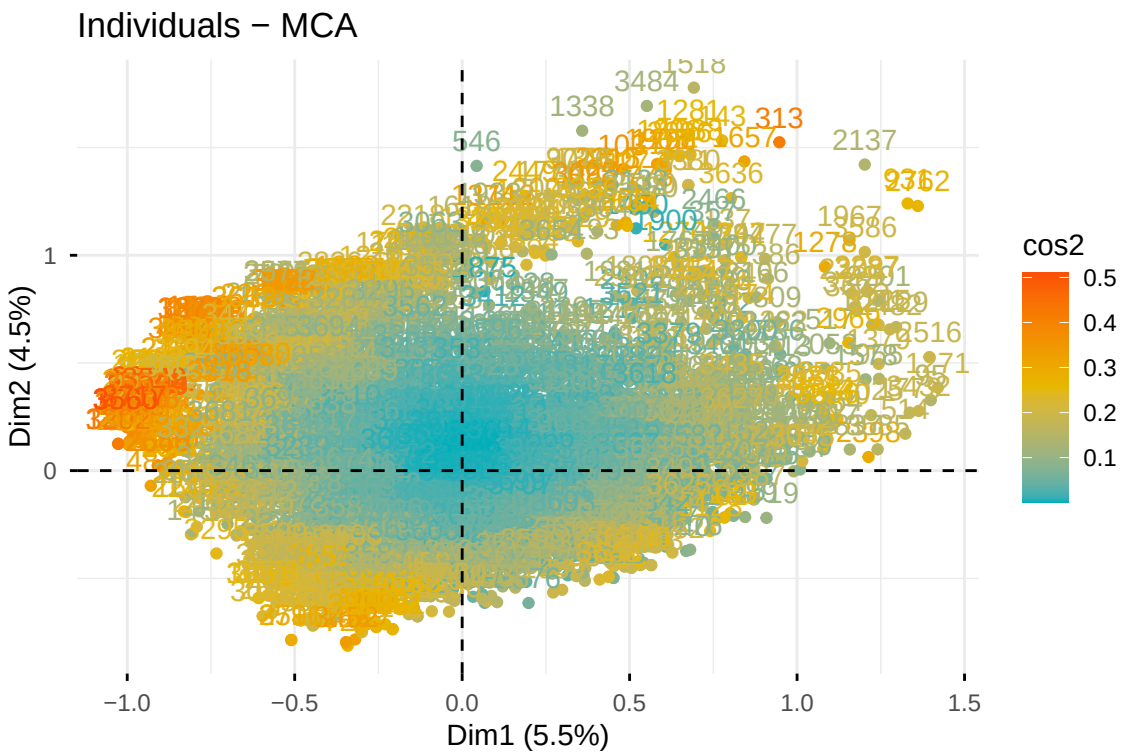
Las contribuciones muestran que la primera dimensión está principalmente definida por categorías como blue-collar, el tipo de contacto, niveles educativos y la variable respuesta, lo que nos facilita su interpretación como un eje asociado al perfil del cliente y su relación con la campaña. En la segunda dimensión destacan variables como basic.4y, retired o admin, que reflejan características sociodemográficas. Considerando ambas dimensiones, las categorías más influyentes son blue-collar, niveles educativos bajos, el tipo de contacto y la variable respuesta de la campaña.

Individuos

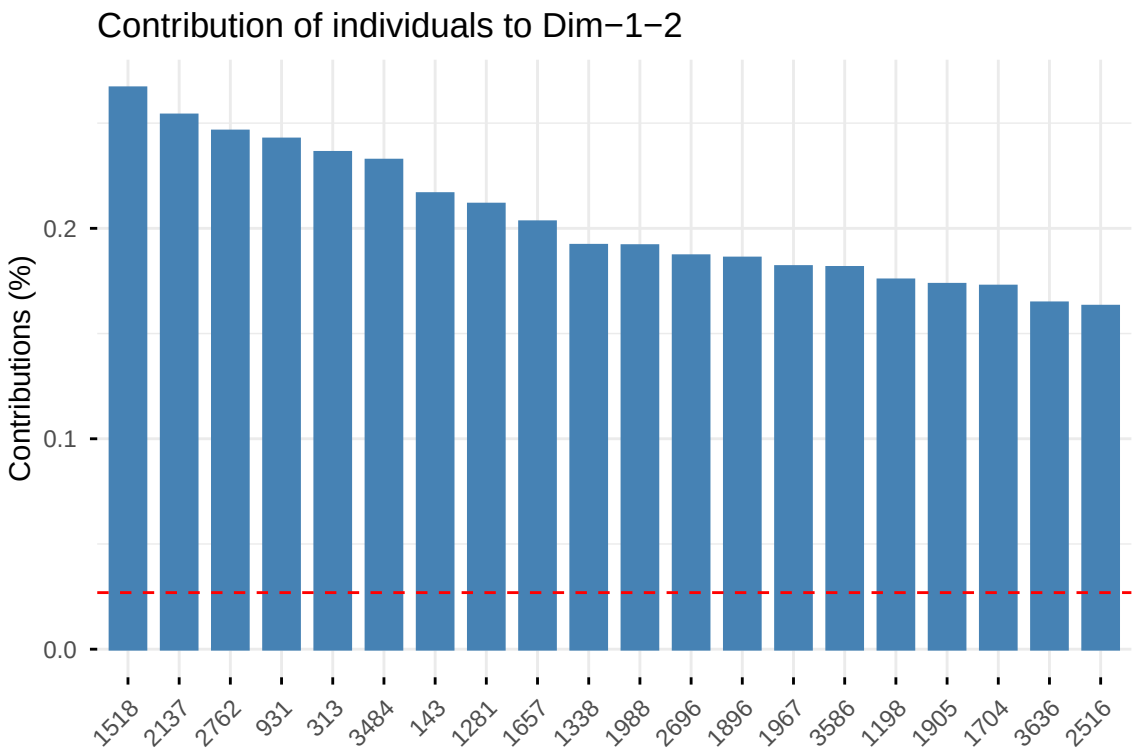
En este apartado se analizan los individuos en el espacio definido por las dimensiones principales del ACM. El objetivo es evaluar su distribución, identificar aquellos con mayor influencia en la construcción de las dimensiones y valorar la calidad de su representación.



Este gráfico muestra la distribución de los individuos en función de su contribución a las dos primeras dimensiones del ACM. Observamos una alta concentración de puntos en la zona central, lo que indica que la mayoría de individuos tienen una contribución baja. En cambio, los situados en los extremos presentan mayores niveles de contribución , siendo los más influyentes.



Este gráfico muestra la calidad de representación de los individuos en las dos dimensiones principales. La mayoría de los individuos presentan un cos^2 bajo, lo que indica que están pocos representados. Por el contrario los individuos en los extremos presentan valores más elevados, siendo los mejor representados y, por tanto, los más fiables para la interpretación.



Por último, observamos que un número reducido de observaciones presenta contribuciones superiores a la media, siendo las que más influyen en la definición del espacio. Sin embargo, estas representan una proporción muy pequeña del total, lo que indica que la estructura global del análisis no está determinada por casos individuales concretos, sino por el conjunto de los datos.

En el análisis de variables del ACM se observa que solo algunas categorías contribuyen de forma relevante a la definición de las dimensiones, especialmente en la primera, mientras que la mayoría presentan una baja calidad de representación. En conjunto, las dos primeras dimensiones capturan parcialmente la estructura de los datos, por lo que los resultados deben interpretarse con cuidado.

Descripción de dimensiones

La descripción de las dimensiones muestra que la Dimensión 1 está principalmente asociada a variables como month, job, education y contact, lo que indica que este eje recoge diferencias relacionadas con el perfil del cliente y el contexto de la campaña, tal y como hemos mencionado anteriormente.

Por su parte, la Dimensión 2 está más influenciada por variables como job y education, destacando categorías específicas como retired, blue-collar o niveles educativos bajos, lo que sugiere que este eje captura diferencias más estructurales de tipo sociodemográfico. En conjunto, la Dimensión 1 resulta más interpretable, mientras que la Dimensión 2 actúa como complemento.

Conclusiones

En conjunto, el ACM nos permite identificar asociaciones entre categorías y distintos perfiles de clientes, mostrando que variables como el nivel educativo o el tipo de contacto están relacionadas con la respuesta a la campaña. Aun así,

las primeras dimensiones explican poca varianza, lo que nos indica que la estructura de los datos es bastante compleja y que la información está repartida entre muchas dimensiones.

Encontrar las coincidencias y discrepancias con ACP

El ACM confirma en gran medida los resultados obtenidos en el ACP, ya que en ambos casos se observa que las variables relacionadas con la actividad económica y el contexto de la campaña son las que más influyen en la estructura de los datos. En ambos análisis observamos diferencias claras entre tipos de clientes, sobretodo relacionadas con su perfil y cómo se comportan con la campaña. La principal diferencia es que el ACP trabaja con variables numéricas y detecta relaciones más claras y directas, mientras que ACM trabaja con categorías y permite captar sus asociaciones.

En particular, el ACM muestra una clara diferenciación entre clientes que responden positivamente a la campaña y aquellos que no, asociada a características como nivel educativo, ocupación o el tipo de contrato. Como discrepancia, el ACM presenta una menor capacidad explicativa en las primeras dimensiones, lo que hace que la estructura sea más dispersa y difícil de interpretar en comparación con el ACP.

FAMD

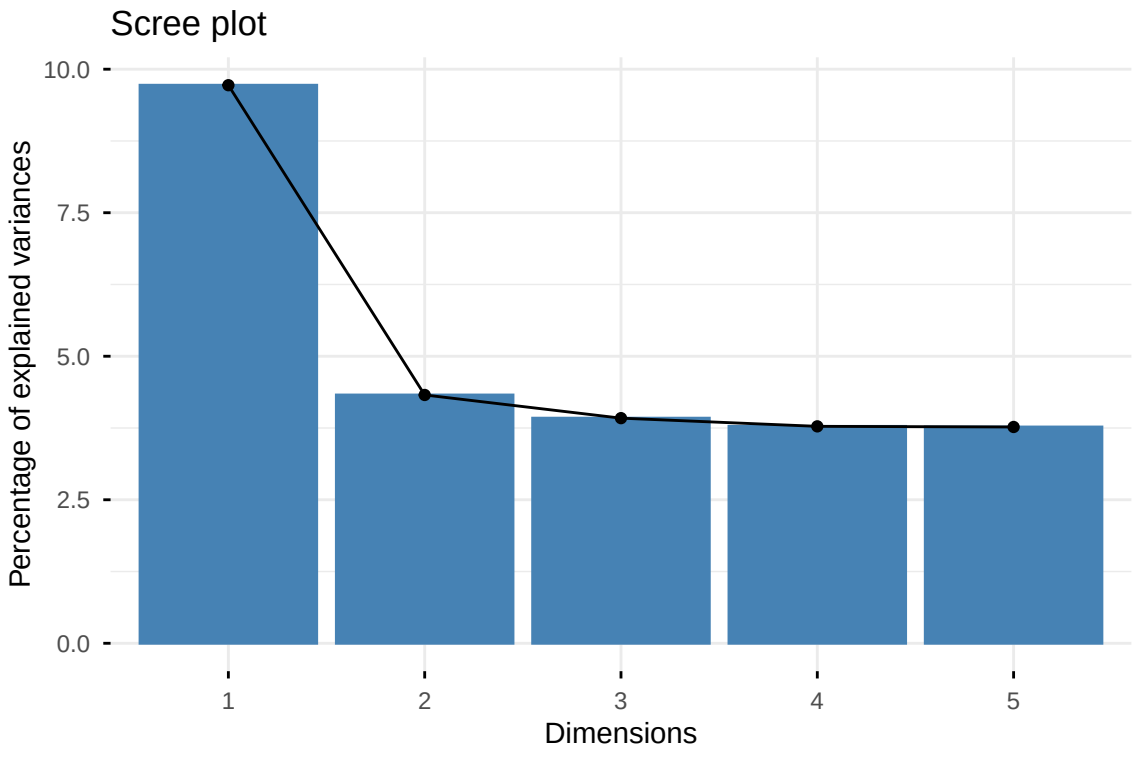
Aplicaremos el Factor Analysis of Mixed Data (FAMD) con el fin de analizar conjuntamente variables sociodemográficas, económicas y de comportamiento de los clientes, considerando la variable respuesta como suplementaria para facilitar la interpretación de los patrones observados.

Resultados principales del análisis

Una vez realizado el análisis factorial de datos mixtos, analizaremos los resultados:

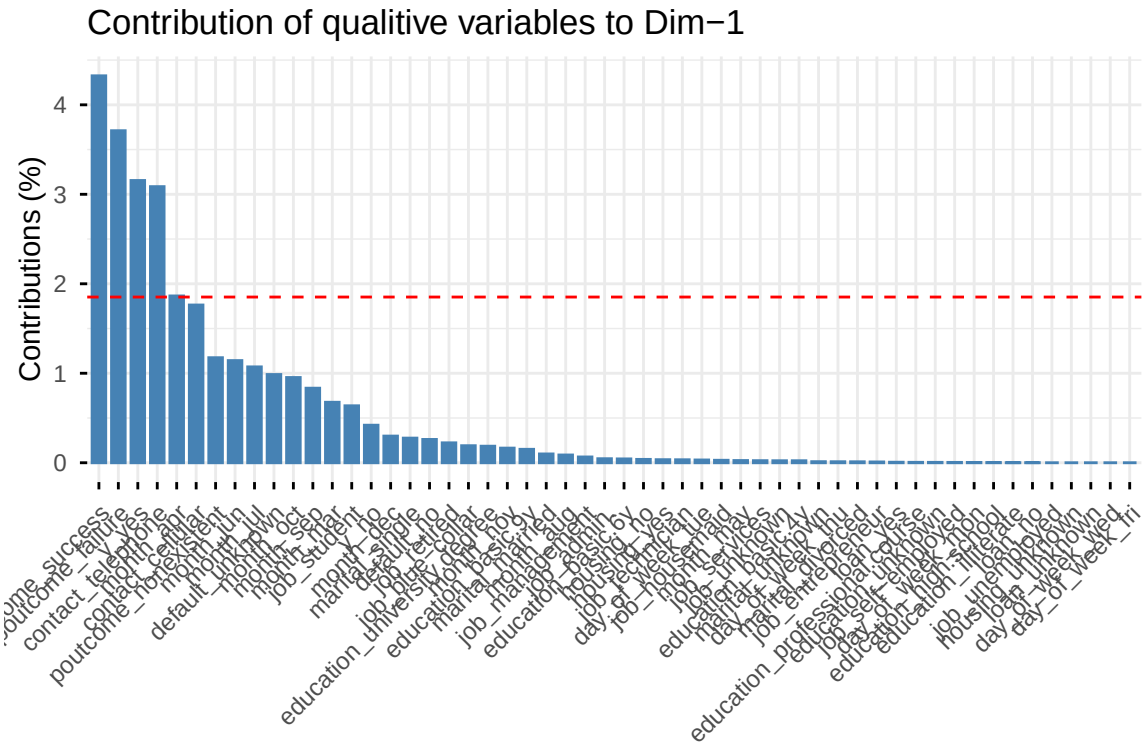
```
##        eigenvalue variance.percent cumulative.variance.percent
## Dim.1    5.152074         9.720895                    9.720895
## Dim.2    2.292350         4.325188                   14.046083
## Dim.3    2.078320         3.921359                   17.967443
## Dim.4    2.002596         3.778483                   21.745925
## Dim.5    1.996864         3.767668                   25.513593
```

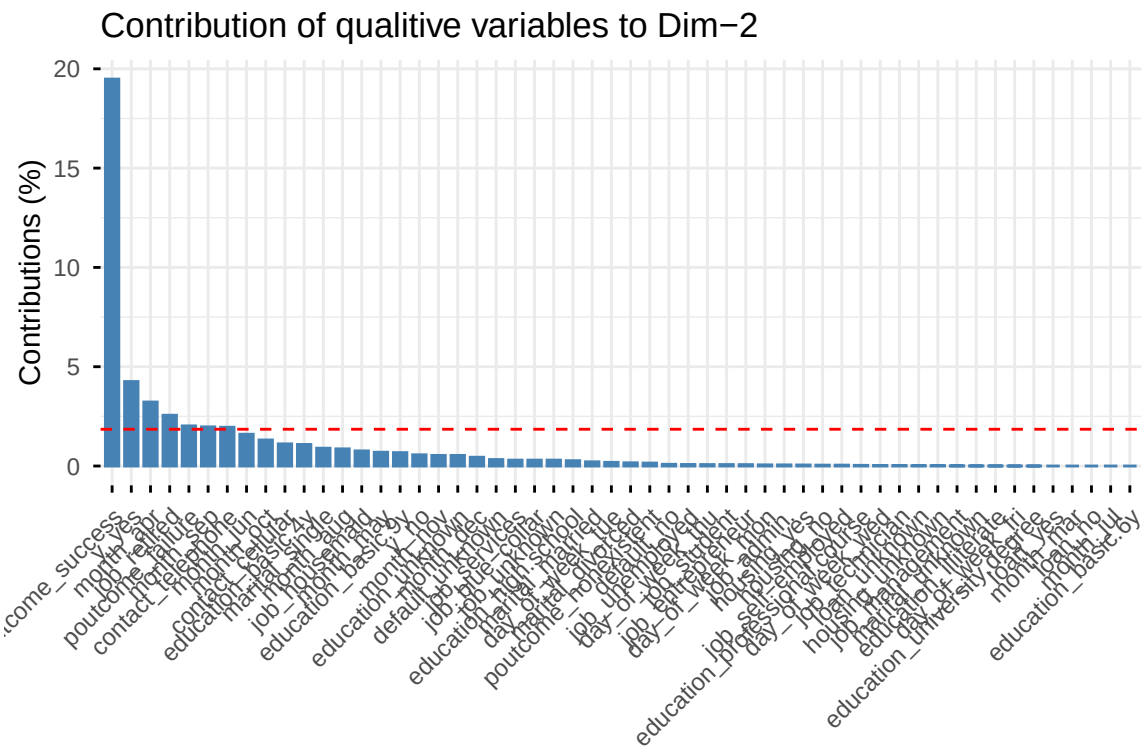
Los valores propios muestran una disminución progresiva sin cambios abruptos, lo que indica que la varianza se distribuye de manera relativamente homogénea entre las distintas dimensiones. Ningún componente destaca de forma clara como dominante. Además, el porcentaje de varianza explicada por cada dimensión es bajo (en torno al 1.5%–1.9%), y la varianza acumulada de las cinco primeras dimensiones apenas alcanza el 8.43%. Esto sugiere que la estructura de los datos es compleja y que se requieren múltiples dimensiones para capturar una proporción significativa de la variabilidad total, lo cual es habitual en análisis FAMD con un número elevado de variables mixtas.



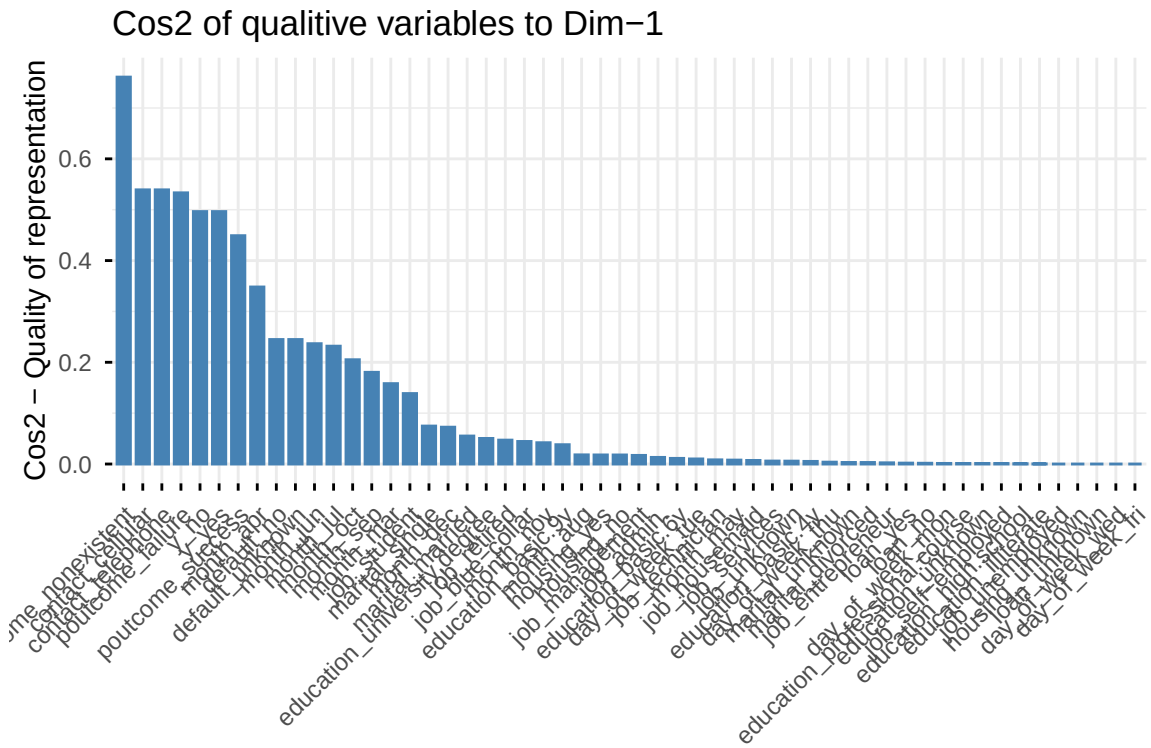
La estructura principal está en las primeras pocas dimensiones, nos podríamos quedar con las 2/3 primeras dimensiones, ya que a partir de ahí la caída es realmente pequeña.

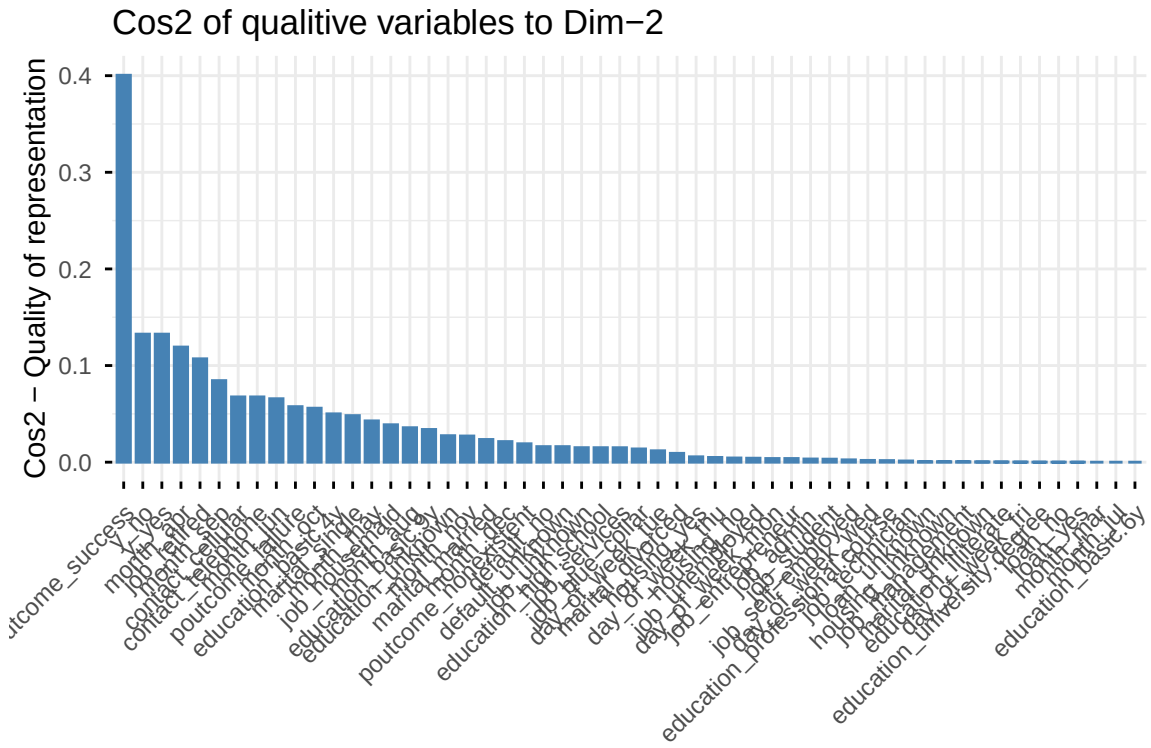
Interpretar las categorias





El gráfico de contribuciones muestra que la Dimensión 1 está explicada principalmente por unas pocas variables cualitativas con alta contribución (las primeras barras, por encima de la linea roja). La mayoría de las variables restantes tienen una contribución baja, por lo que su influencia en esta dimensión es limitada. La dimensión dos también está explicada por un número reducido de variables cualitativas de alta contribución, pero con una caída más rápida , indicando que muy pocas variables dominan esta dimensión.

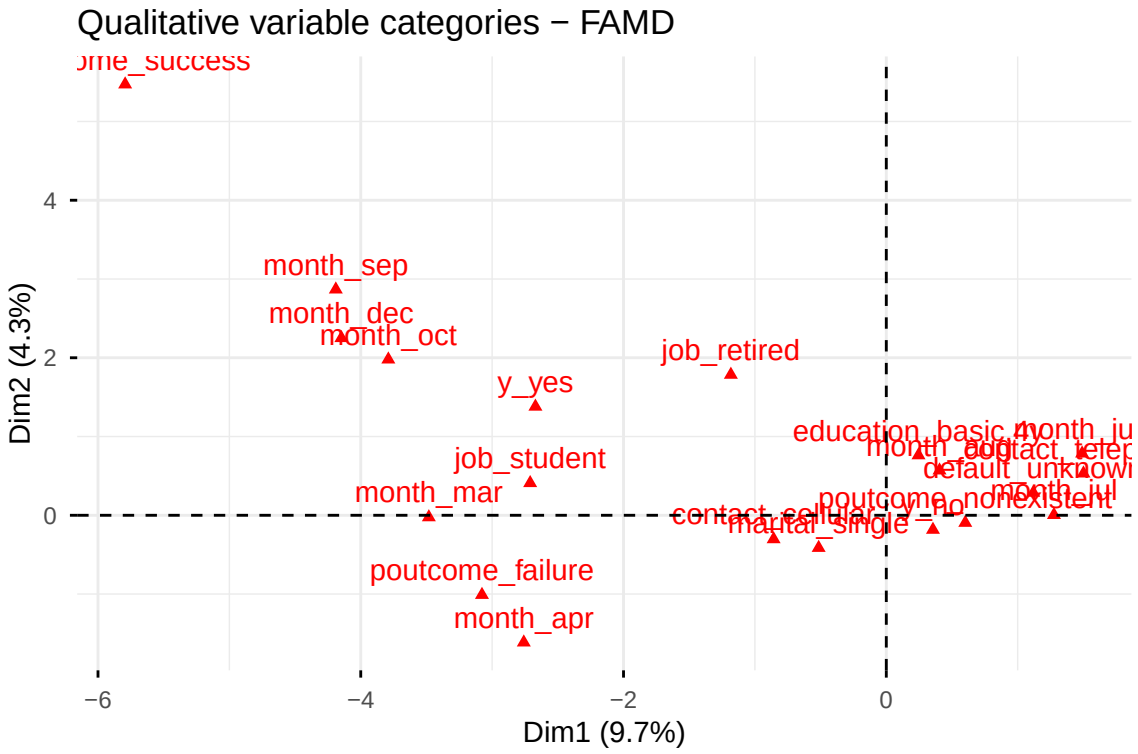




Estos gráficos muestran la calidad de representación de las variables cualitativas en las Dimensiones 1 y 2. En ambos casos, solo unas pocas variables tienen valores altos, lo que significa que están bien representadas en esas dimensiones.

La gran mayoría representan valores bajos, indicando que no se explican bien por estos ejes y su interpretación en ellos es limitada.

Interpretar las relaciones



El gráfico muestra que la Dimensión 1 separa principalmente categorías asociadas a resultados positivos (como poutcome_success o y_yes), que aparecen a la derecha, frente a otras menos favorables situadas a la izquierda. La Dimensión 2 introduce diferencias más secundarias, como el tipo de contacto (contact_telephone). La mayoría de categorías se concentran cerca del centro, lo que indica que tienen poca influencia en la estructura principal.

Clustering jerárquico

Describir la matriz y mostrar el árbol

Para el clustering jerárquico utilizamos como matriz de entrada las coordenadas de los individuos en las tres primeras dimensiones del FAMD. De esta forma, no trabajamos con las variables originales, sino con un espacio reducido que resume la información conjunta de variables cuantitativas y cualitativas.

```
##            Dim.1      Dim.2      Dim.3
## 2986   1.838540  0.4254554  0.2952842
## 29925 -1.898204 -2.4295523  1.9401561
## 29710 -1.974220 -2.2376327  2.0693168
## 37529 -2.186918 -0.8271656  4.1342727
## 2757   1.699318  0.4995092 -0.4097487
## 38938 -3.398789 -0.4547152 -1.8292537
```

Como las coordenadas del FAMD ya son variables numéricas, podemos calcular una distancia euclídea entre individuos (no necesitamos aplicar Gower). Esta distancia mide cómo de parecidos o diferentes son los clientes dentro del espacio factorial obtenido. Dos individuos cercanos en este espacio tendrán perfiles similares según la información combinada de las variables cuantitativas y cualitativas.

Una vez calculada la matriz de distancias, aplicamos distintos métodos de agregación jerárquica para comparar cómo se construyen los grupos. Probamos varios criterios de enlace: single, complete, average y Ward.D2.

El objetivo de comparar varios métodos es evitar escoger directamente un único criterio sin justificarlo.

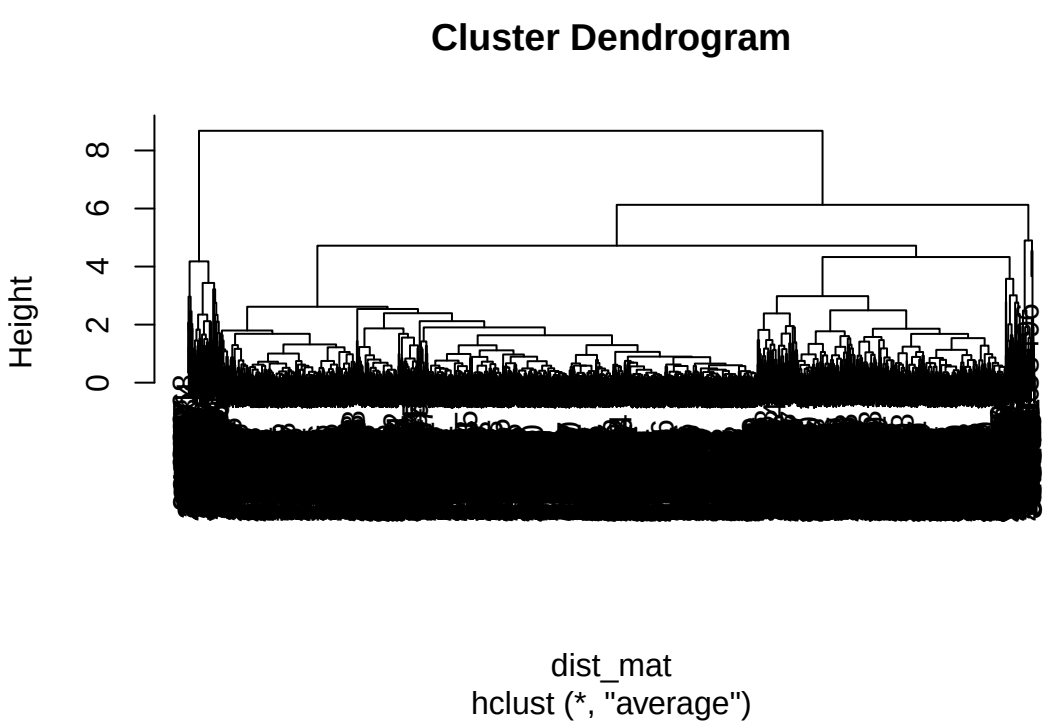
Para seleccionar el método de agregación más adecuado, comparamos los distintos dendrogramas mediante la correlación cofenética. Esta medida evalúa cómo de bien el dendrograma representa las distancias originales entre los individuos.

Table 16: Correlación cofenética por método de agregación

Metodo	Correlacion
Single	0.8073
Complete	0.8612
Average	0.8836
Ward.D2	0.6956

A partir de la correlación cofenética observamos que el método average presenta el valor más elevado (0.8836), lo que indica que es el que mejor preserva la estructura de distancias original entre los individuos.

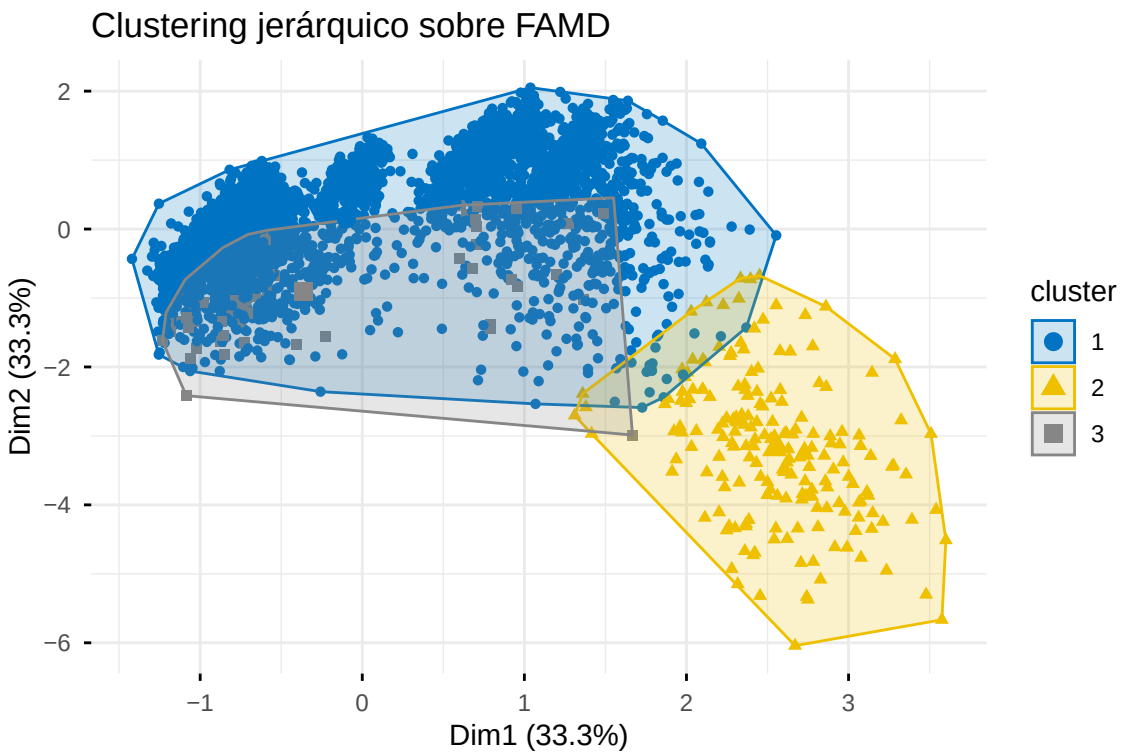
Aunque el método de Ward suele ser una opción habitual en clustering jerárquico, en este caso presenta un ajuste claramente inferior. Por este motivo, seleccionamos el método average como criterio de agregación final.



El dendrograma obtenido con el método average muestra una estructura bastante compleja, con muchas observaciones concentradas en niveles bajos de altura, lo que hace que no sea tan fácil identificar cortes claros a simple vista. Aun así, si nos fijamos en la parte superior del gráfico, sí se pueden distinguir aproximadamente tres grandes bloques, lo que sugiere que existe una estructura global de tres clústeres.

Por este motivo, optamos por seleccionar k = 3, ya que permite recoger la estructura principal de los datos sin dividirlos en demasiados grupos pequeños y difíciles de interpretar. Además, esta falta de separación tan marcada es coherente con los resultados del FAMD, donde vimos que la varianza se distribuye de forma bastante homogénea entre las dimensiones, indicando que estamos ante unos datos con una estructura más compleja de lo habitual.

Para visualizar los clústeres obtenidos mediante el método jerárquico, utilizamos una representación en el espacio de las componentes del FAMD, empleando funciones del paquete factoextra, que permiten representar los individuos coloreados según su pertenencia a cada grupo.



El gráfico muestra los clusters proyectados en las dos primeras dimensiones del FAMD. Se ve bastante claro que el cluster 2 está bien separado del resto, así que probablemente representa un grupo de clientes bastante diferente.

En cambio, los clusters 1 y 3 están bastante mezclados entre sí, sobre todo en la parte izquierda, lo que indica que no son tan distintos o que cuesta separarlos bien en estas dimensiones.

También se observa que el cluster 1 es el más grande y disperso, mientras que el cluster 2 es más compacto.

En general, la estructura está bastante marcada por ese cluster 2 que se separa claramente, mientras que los otros dos son más parecidos entre sí. Aun así, hay que tener en cuenta que solo estamos viendo dos dimensiones, así que parte de la separación real entre grupos puede estar en dimensiones adicionales del FAMD.

Profiling de los clusters

Se realiza una primera fase de filtrado con el objetivo de identificar aquellas variables que presentan diferencias significativas entre los clústeres.

Para las variables numéricas se utilizan contrastes ANOVA o Kruskal-Wallis según el cumplimiento de normalidad, mientras que para las variables categóricas se aplica el test chi-cuadrado.

A partir de estos resultados, se seleccionan únicamente aquellas variables con p-valor inferior a 0.05, ya que son las que realmente permiten diferenciar los grupos.

```
##  [1] "age"            "duration"       "campaign"       "pdays"
##  [5] "previous"       "emp.var.rate"   "cons.price.idx" "cons.conf.idx"
##  [9] "euribor3m"      "nr.employed"    "job"            "marital"
```

```
## [13] "education"      "default"        "housing"        "loan"
## [17] "contact"        "month"          "poutcome"       "y"
```

En la primera fase del profiling vemos que prácticamente todas las variables originales presentan diferencias significativas entre los clústeres. Esto tiene bastante sentido, ya que los grupos se han construido a partir de las dimensiones del FAMD, que resumen la información conjunta de variables tanto numéricas como categóricas.

Aun así, que una variable salga significativa no quiere decir que sea clave para interpretar los clústeres. Por eso, en la siguiente fase nos centraremos solo en aquellas variables que realmente destacan más entre grupos, apoyándonos en los resultados de catdes y cluster.carac.

A continuación, se analizan las características de cada clúster a partir de las variables seleccionadas.

Para las variables numéricas se observan las medias por grupo, mientras que para las variables categóricas se identifican las categorías más frecuentes en cada clúster.

Esto permite construir un perfil descriptivo de cada grupo y entender qué tipo de clientes lo componen.

A partir de las medias por clúster, vemos que el clúster 1 es claramente el grupo mayoritario, con 4733 clientes. Presenta valores muy cercanos al perfil general: edad media alrededor de 40 años, duración media de llamada de 254 segundos y prácticamente sin contactos previos.

El clúster 2 es mucho más pequeño, con 193 clientes, pero está bastante diferenciado. Destaca por tener una mayor duración media de llamada, más contactos previos (previous = 1.75) y un valor de pdays mucho más bajo, lo que indica que son clientes que sí habían sido contactados anteriormente. Además, presenta valores económicos más bajos, como euribor3m y nr.employed.

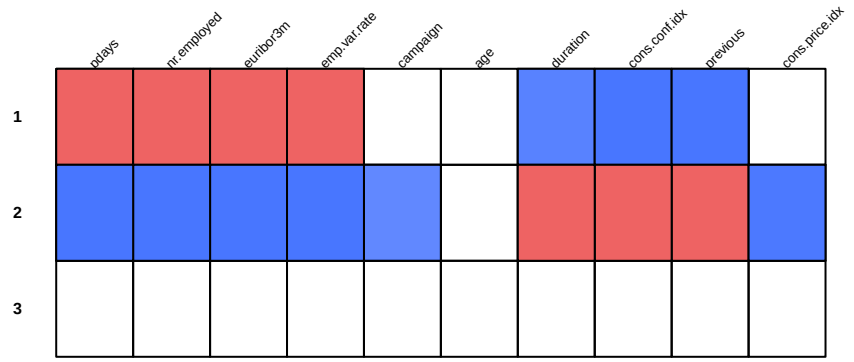
El clúster 3 es el más pequeño, con 74 clientes. Se caracteriza por no tener contactos previos recientes (pdays = 999, previous casi 0), una duración de llamada menor y valores económicos más altos, especialmente en euribor3m y nr.employed.

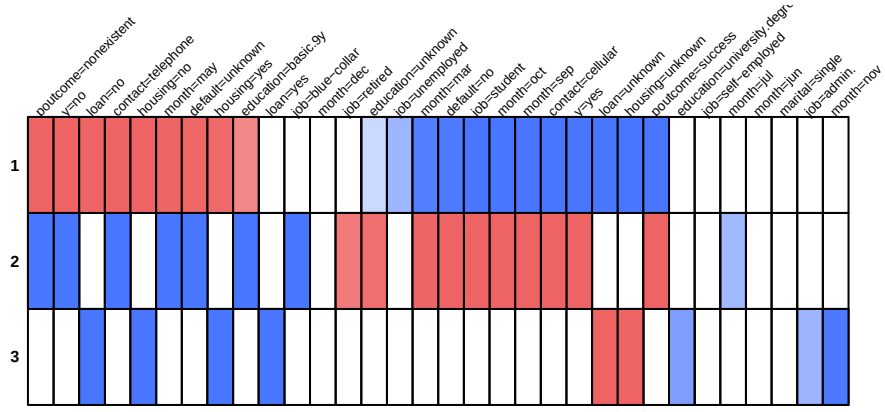
En conjunto, el clúster 2 parece ser el grupo más diferenciado desde el punto de vista del historial de campaña, mientras que los clústeres 1 y 3 son más parecidos entre sí, aunque el tercero aparece asociado a un contexto económico más favorable.

A partir de las variables categóricas se ve que los tres clústeres comparten bastantes cosas, así que no están totalmente separados. En general, la mayoría de clientes en todos los grupos son casados, no tienen impagos, han sido contactados por móvil y la campaña se concentra sobre todo en mayo. Es decir, hay un perfil bastante común que se repite en todos.

Aun así, sí hay alguna diferencia interesante. El clúster 2 es el único donde el resultado de campañas anteriores aparece como success y además es el único donde la variable objetivo es yes. Esto encaja bastante con lo que ya habíamos visto, ya que parece ser el grupo de clientes más propensos a aceptar la oferta.

En cambio, los clústeres 1 y 3 tienen poutcome = nonexistent y y = no, así que agrupan clientes con menor respuesta a la campaña. También hay pequeñas diferencias en cosas como el tipo de trabajo o el nivel de estudios, pero en general aquí las diferencias entre grupos son más suaves que en las variables numéricas.





En general, los clústeres 1 y 2 son los que realmente se diferencian, mientras que el clúster 3 queda bastante más neutro y no tiene un perfil tan claro.

El clúster 1 parece estar más ligado a un contexto económico más fuerte (valores altos en emp.var.rate, euribor3m, etc.), pero con menos interacción en campañas (duration y previous más bajos). En cambio, el clúster 2 es justo al revés: clientes más activos en campañas y con más interacción, pero en un contexto económico más bajo.

El clúster 3, en cambio, no destaca especialmente en nada, así que es un grupo más "mezcla" o menos definido.

Además, en las categóricas se ve que el clúster 2 está más asociado a respuestas positivas (y = yes, poutcome = success), mientras que los otros dos tienden más a resultados negativos o sin respuesta.

Los resultados del v-test confirman bastante bien lo que ya habíamos visto antes, pero aquí queda más claro qué variables son realmente importantes en cada clúster.

El clúster 1 está claramente asociado a valores altos de variables económicas (euribor3m, emp.var.rate, nr.employed) y a no haber tenido interacción previa (pdays alto y previous muy bajo). Además, en las categóricas se asocia sobre todo a y = no y poutcome = nonexistent, así que son clientes poco activos y con baja probabilidad de respuesta.

El clúster 2 es el más distinto. Destaca muchísimo en previous y duration, lo que indica clientes con bastante interacción en campañas. Además, tiene valores económicos más bajos y, en categóricas, aparece fuertemente ligado a poutcome = success y y = yes. Es decir, es el grupo más propenso a aceptar la oferta.

El clúster 3 es más pequeño y menos claro. Tiene valores algo más altos en variables económicas, pero sin diferencias tan fuertes. En categóricas destaca por valores unknown en housing y loan, lo que sugiere que es un grupo más irregular o con información menos definida.

En conjunto, el v-test permite reforzar las conclusiones obtenidas anteriormente, confirmando qué variables son realmente discriminantes en la formación de los clústeres y aportando una caracterización más sólida de cada grupo.

Como conclusión final, etiquetaremos los clusters:

- *Clúster 1:* clientes estándar, poco activos en campañas y asociados a un contexto económico más favorable
- *Clúster 2:* clientes activos, con más interacción y mayor probabilidad de respuesta positiva
- *Clúster 3:* clientes poco definidos, con menor interacción y comportamiento más neutro

Compararación de resultados

Comparando con el profiling anterior, vemos que la idea general se mantiene bastante. En los dos casos aparece un grupo más interesante para el banco: clientes con más interacción previa, llamadas más largas y más tendencia a aceptar la oferta. Antes este perfil aparecía como el clúster 3 del PAM, y ahora aparece como el clúster 2 del clustering sobre FAMD.

La diferencia principal es que ahora los grupos se han creado usando las componentes del FAMD, así que el análisis combina mejor la información numérica y categórica. Por eso, la interpretación ya no depende tanto solo de las variables numéricas, sino que también recoge mejor el efecto de variables como poutcome, y, contact o month.

También cambia un poco la lectura de los otros clústeres. En el profiling anterior, los grupos 1 y 2 se separaban sobre todo por la edad. Ahora, en cambio, la diferencia parece ir más por el contexto económico y el historial de campaña. El clúster 1 queda como el grupo mayoritario, con poca interacción previa y baja respuesta, mientras que el clúster 3 es más pequeño y menos definido.

En resumen, los dos análisis llegan a una conclusión parecida: hay un segmento de clientes con más probabilidad de responder positivamente. Pero el análisis con FAMD queda más completo porque mezcla mejor todos los tipos de variables y, además, el v-test ayuda a ver con más claridad qué caracteriza a cada clúster.

Análisis discriminante

Resultados del análisis

Para realizar el análisis discriminante sobre datos mixtos, utilizaremos las coordenadas factoriales del FAMD, ya que resumen toda la información relevante.

```
## Call:
## lda(clase ~ ., data = datos_lda)
##
## Prior probabilities of groups:
##      1      2      3
## 0.9466 0.0386 0.0148
##
## Group means:
##        Dim.1      Dim.2       Dim.3
## 1  0.2227591 -0.2138690 -0.04197375
## 2 -5.7778220  5.1460738 -0.96565700
## 3  0.8216330  0.2574309  5.20315652
##
## Coefficients of linear discriminants:
##               LD1         LD2
## Dim.1 -0.5171864 -0.01568833
## Dim.2  1.0243878  0.16545355
## Dim.3 -0.2758325  0.75066068
##
## Proportion of trace:
##    LD1    LD2
## 0.9258 0.0742
```

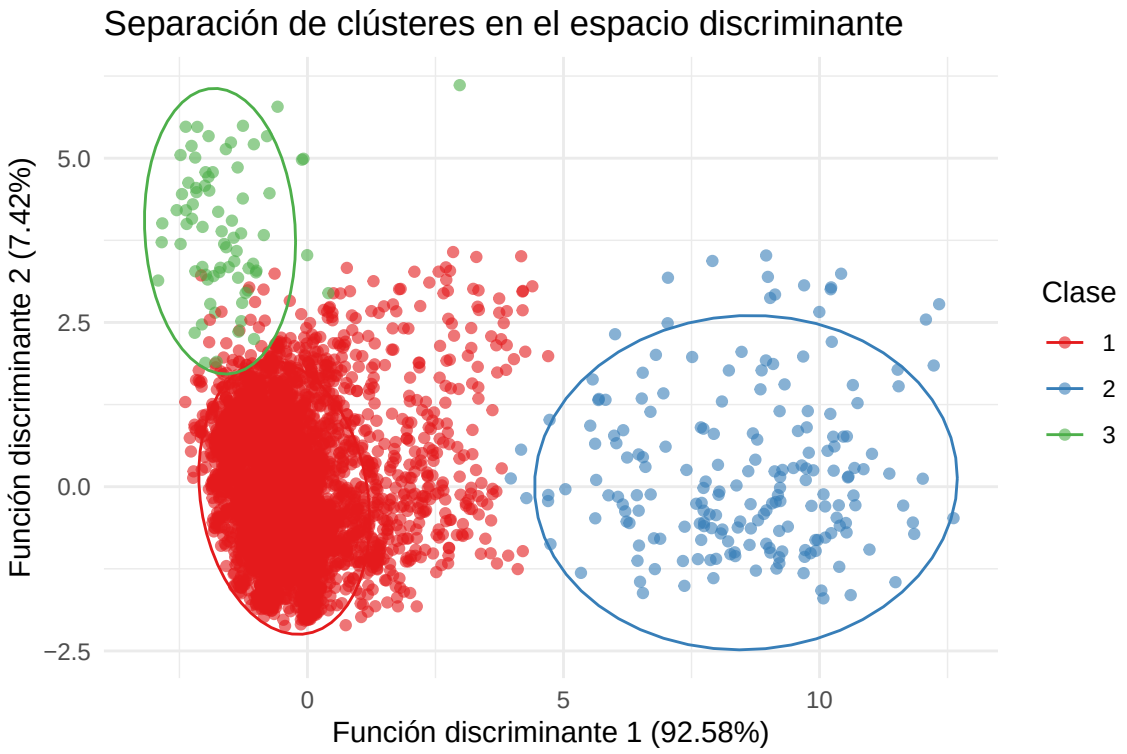
Los resultados muestran una capacidad de discriminación muy alta:

- *Probabilidades a priori:* El modelo reconoce la estructura desequilibrada de la muestra, donde el Clúster 1 es el mayoritario (94.6%), mientras que los Clústeres 2 (3.8%) y 3 (1.4%) e presentan como clases de baja frecuencia relativa.
- *Proporción de traza (Eficacia):* La primera función discriminante (LD1) explica el 92.58% de la varianza entre grupos. Esto significa que casi toda la diferenciación de los clientes se puede explicar con un solo eje. La segunda función (LD2) solo aporta un 7.42% adicional.
- *Interpretación de los coeficientes (Funciones discriminantes):*

$$LD1 = -0.51 \cdot \text{Dim.1} + 1.02 \cdot \text{Dim.2} - 0.27 \cdot \text{Dim.3}$$

$$LD2 = -0.01 \cdot \text{Dim.1} + 0.16 \cdot \text{Dim.2} + 0.75 \cdot \text{Dim.3}$$

- LD1 (El "Eje de actividad y éxito"): Está dominado por la Dim.2 del FAMD (coeficiente 1.02). Como vimos en el perfilado, esta dimensión separa a los clientes con historial de éxito previo. Un valor alto en LD1 nos indica un cliente con alta probabilidad de suscripción.
- LD2 (El "eje de contexto económico"): Está dominado casi totalmente por la Dim.3 (coeficiente 0.75). Este eje ayuda a separar al Clúster 3, que tenía valores económicos (Euribor/Empleo) más específicos.
- *Medias de los grupos (Centroides):*
- El Clúster 2 se sitúa en el extremo negativo de la Dim.1 (-5.77) y positivo de la Dim.2 (5.14). Es el grupo más "extremo" y, por tanto, el más fácil de identificar.
- El Clúster 3 destaca radicalmente en la Dim.3 (5.20), confirmando que su diferencia es de naturaleza económica/temporal.



El gráfico de dispersión en el espacio discriminante muestra una separación nítida de los tres grupos. La primera función discriminante (LD1) logra segregar casi por completo al Clúster 2, situándolo en valores positivos altos, lo que demuestra la existencia de un perfil de cliente claramente diferenciable. Por su parte, la segunda función (LD2), aunque con menor peso relativo, resulta esencial para proyectar el Clúster 3 fuera de la nube de puntos del Clúster 1, confirmando la validez de la estructura de tres grupos obtenida en la fase de clustering.

Matriz de confusión e interpretación

Para validar el modelo, cruzamos las clasificaciones reales con las predicciones del LDA:

```
## [1] 0.9964
```

Table 17: Matriz de confusión del análisis discriminante lineal

1	2	3
4728	2	3
3	190	0
10	0	64

La matriz de confusión ratifica la altísima robustez del modelo discriminante, alcanzando una precisión global del 99.64%.

Destaca la excelente clasificación del Clúster 2 (el segmento con mayor tasa de éxito en la campaña), donde prácticamente no existe error de omisión. Esto demuestra que las variables de interacción previa (previous, poutcome) combinadas con la duración de la llamada, crean una firma estadística inconfundible para este grupo.

La mínima confusión observada se da entre los Clústeres 1 y 3 (10 casos), lo cual es coherente con nuestro análisis previo, ya que ambos grupos comparten la característica de no haber sido contactados con éxito anteriormente, diferenciándose principalmente por indicadores macroeconómicos que, en algunos casos limítrofes, pueden solaparse.

Discriminador o clasificador alternativo

Para esta sección elegimos como clasificador alternativo el Random Forest. Este es un método de aprendizaje automático basado en la combinación de múltiples árboles de decisión. Entre las alternativas disponibles, el LDA ya implementado es el método más interpretable pero impone supuestos de normalidad estrictos que los datos bancarios difícilmente cumplen. Un árbol de decisión simple sería muy fácil de explicar visualmente pero tiende a sobreajustarse. La regresión logística es otro clasificador que podría plantearse como alternativa en este contexto. Sin embargo, en su formulación estándar presenta una limitación importante: está diseñada para problemas de clasificación binaria, es decir, cuando la variable respuesta tiene únicamente dos categorías. En nuestro caso, la variable clase tiene tres categorías (clústeres 1, 2 y 3), por lo que habría que recurrir a la regresión logística multinomial, que es una extensión del modelo original para más de dos clases.

Random Forest es un método no paramétrico y que no requiere ningún supuesto distribucional. Es robusto ante desequilibrio de clases (el Clúster 1 tiene el 94.6% de las observaciones) y funciona bien con datos mixtos. Además, proporciona una medida de importancia de variables que permite comparar directamente con los coeficientes discriminantes del LDA. El principal inconveniente de este método es la difícil justificación de los resultados obtenidos ya que sería necesario justificar las diversas elecciones de cada árbol.

Matriz de confusión

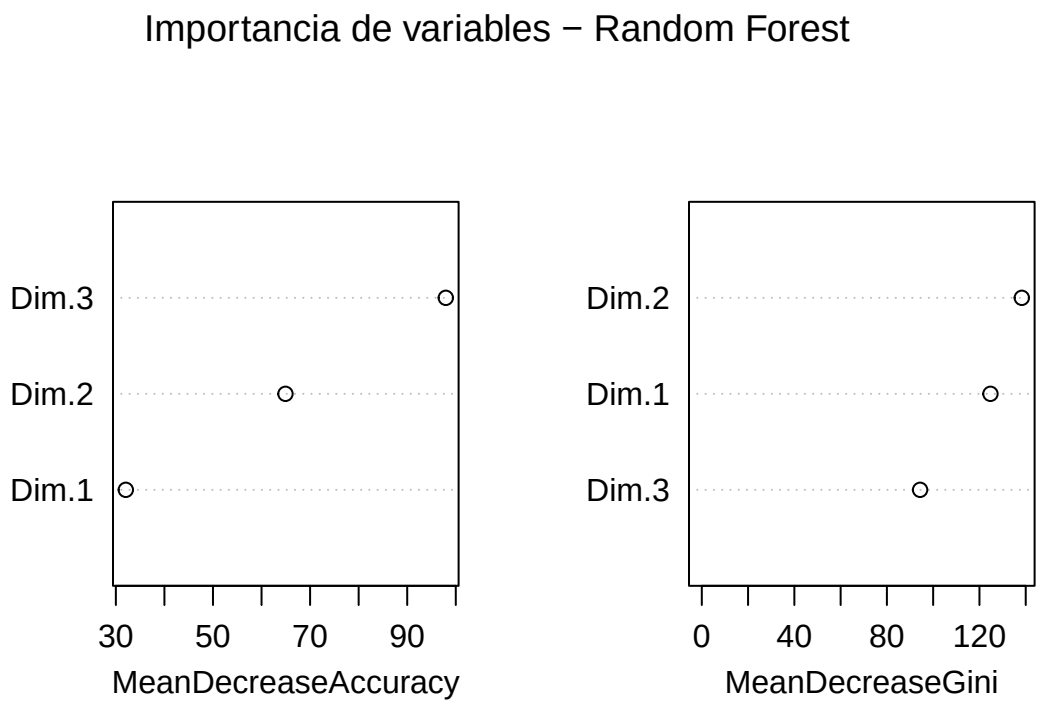
Table 18: Matriz de confusión del Random Forest

1	2	3
1418	1	0
0	57	0
3	0	19

La matriz de confusión del Random Forest muestra los resultados obtenidos sobre el conjunto de test, es decir, sobre datos que el modelo no había visto durante el entrenamiento. Esto es importante porque ofrece una estimación más realista del rendimiento del modelo que la que obtendríamos evaluándolo sobre los mismos datos con los que fue entrenado.

Los resultados muestran una precisión global del 99.73%, lo cual confirma que el modelo clasifica correctamente casi la totalidad de los clientes. Analizando cada fila de la tabla:
- El clúster 1, siendo el grupo mayoritario con 1419 observaciones en el conjunto de test, solo presenta 1 error de clasificación, lo que supone una tasa de error prácticamente nula.
- El clúster 2, que representa el grupo de clientes más activos y con mayor probabilidad de respuesta positiva, se clasifica perfectamente, sin ningún error. Esto confirma que este grupo tiene una firma estadística muy diferenciada del resto.
- El clúster 3, el más pequeño y menos definido, presenta 3 errores de clasificación, todos ellos confundidos con el clúster 1. Este resultado es coherente con lo observado durante el profiling, donde estos dos grupos mostraban mayor similitud entre sí.

Importancia de las variables



Este gráfico muestra qué variables han sido más útiles para que el modelo tome decisiones correctas. Se presentan dos métricas:
- MeanDecreaseAccuracy: mide cuánto empeora la precisión del modelo si se elimina esa variable. Cuanto mayor sea el valor, más importante es la variable.
- MeanDecreaseGini: mide cuánto contribuye cada variable a reducir la impureza en los nodos de los árboles. Un valor alto indica que esa variable permite separar bien las clases.

En el gráfico se observa que Dim.3 es la variable más importante según el criterio de precisión, seguida de Dim.2 y finalmente Dim.1. Sin embargo, según el criterio Gini, Dim.2 pasa a ser la más relevante, seguida de Dim.1 y Dim.3.

A partir de los resultados en el FAMD, Dim.2 estaba principalmente relacionada con el historial de campañas previas y la respuesta positiva del cliente, mientras que Dim.3 recogía diferencias de naturaleza más económica y temporal. El hecho de que ambas dimensiones sean las más importantes para el Random Forest confirma que son precisamente estas dos fuentes de variabilidad las que mejor permiten distinguir entre los tres perfiles de clientes identificados.

Dim.1, que resumía la mayor parte de la variabilidad general de los datos, resulta sin embargo menos discriminante a la hora de clasificar, lo que sugiere que recoge un patrón común a todos los clientes más que diferencias entre grupos.

Comparación con el análisis discriminate y justificación de las diferencias

El modelo Random Forest obtiene una precisión similar al LDA, confirmando que la estructura de los tres clústeres es sólida y no dependiente del método utilizado. La principal diferencia reside en los supuestos: el LDA asume normalidad multivariante e igualdad de covarianzas entre grupos, supuestos difíciles de garantizar en datos bancarios reales, mientras que el Random Forest no impone ninguna restricción distribucional.

Ambos modelos han obtenido una precisión muy elevada, por encima del 99%, lo que confirma que la estructura de los tres clústeres es sólida y reproducible independientemente del método utilizado. Sin embargo, existen diferencias importantes entre ellos que conviene analizar en detalle.

El LDA alcanza una precisión del 99.64% evaluada por resubstitución, es decir, entrenando y prediciendo sobre los mismos datos. El Random Forest obtiene una precisión del 99.73% evaluada sobre un conjunto de test independiente que el modelo no había visto durante el entrenamiento. Aunque numéricamente el Random Forest parece ligeramente superior, la diferencia más relevante es metodológica: la estimación del Random Forest es más fiable porque se basa en datos nuevos, mientras que la del LDA puede estar ligeramente inflada por el hecho de evaluar sobre los mismos datos de entrenamiento.

Analizando la clasificación de cada grupo por separado, ambos modelos coinciden en que el clúster 2 es el más fácil de identificar, con prácticamente cero errores en ambos casos. Esto confirma que este grupo, formado por clientes con historial previo de éxito en campañas y mayor interacción con el banco, posee un perfil estadístico muy diferenciado del resto. La mayor fuente de error en ambos modelos se concentra en la frontera entre los clústeres 1 y 3, que son los dos grupos más parecidos entre sí. El LDA comete 10 errores en esta frontera, mientras que el Random Forest comete únicamente 3. Esto sugiere que el Random Forest es capaz de capturar mejor las diferencias sutiles entre estos dos grupos, probablemente gracias a su capacidad para detectar relaciones no lineales que el LDA no es capaz de modelar.

En relación a la interpretabilidad, el LDA ofrece una ventaja clara: sus funciones discriminantes tienen coeficientes explícitos que permiten entender exactamente qué dimensiones del FAMD contribuyen más a separar los grupos. En este caso, LD1 estaba dominada por Dim.2, relacionada con el historial de campañas previas, y LD2 por Dim.3, asociada al contexto económico. Esta interpretación directa es más difícil de obtener con el Random Forest, que ofrece medidas de importancia de variables pero no permite cuantificar el efecto de cada una de forma tan precisa.

En resumen, ambos modelos llegan a las mismas conclusiones sustantivas: existe un perfil de cliente claramente diferenciable asociado al éxito previo en campañas, y la mayor dificultad de clasificación se da entre los clientes estándar y los menos definidos. Sin embargo, el Random Forest resulta más adecuado desde el punto de vista estadístico por su mayor robustez, su capacidad para capturar relaciones no lineales y su evaluación sobre datos independientes. El LDA, por su parte, sigue siendo útil como complemento por su mayor interpretabilidad y la claridad de sus funciones discriminantes.

Análsis comparativa

Disusión general

En conjunto, todos los métodos muestran que los datos presentan una estructura compleja y heterogénea, donde las variables económicas, el historial de campañas previas y determinadas características sociodemográficas juegan un papel fundamental en la diferenciación de los clientes.

El ACP permitió resumir la información numérica identificando principalmente dos grandes ejes: uno asociado al contexto económico y otro relacionado con el historial del cliente. Este análisis mostró relaciones lineales muy claras entre variables como euribor3m, emp.var.rate y nr.employed, evidenciando una fuerte redundancia entre indicadores macroeconómicos.

Por otro lado, el ACM permitió estudiar las asociaciones entre categorías cualitativas, detectando perfiles diferenciados según variables como job, education, contact o la propia respuesta de la campaña (y). En concreto, muestra una clara diferenciación entre clientes que responden positivamente a la campaña y aquellos que no. Aunque la capacidad explicativa de las primeras dimensiones fue menor que en el ACP, el ACM permitió captar relaciones categóricas que no podían observarse únicamente mediante variables numéricas.

El FAMD, combinando simultáneamente variables cuantitativas y cualitativas, permitió obtener una representación más global y realista de los clientes, ya que en este tipo de problemas las diferencias entre individuos no dependen únicamente de variables económicas, sino también de factores sociodemográficos y del comportamiento frente a campañas anteriores.

Finalmente, el clustering jerárquico y los métodos discriminantes permitieron transformar esta estructura factorial en perfiles concretos de clientes. Los resultados mostraron la existencia de un grupo claramente diferenciado, caracterizado por una mayor interacción previa con la campaña y, por tanto, una probabilidad significativamente más alta de respuesta positiva.

En general, los distintos métodos no deben interpretarse como técnicas independientes, sino como herramientas complementarias que permiten analizar los datos desde distintos puntos de vista: reducción de dimensión, interpretación de relaciones, detección de perfiles y validación de grupos.

Análisis de las coincidencias y divergencias entre métodos

A pesar de que cada técnica trabaja sobre tipos de variables diferentes y utiliza metodologías distintas, los resultados obtenidos presentan varias coincidencias importantes.

En primer lugar, todos los métodos identifican que existe una diferenciación clara entre clientes más activos y receptivos frente a la campaña y clientes con menor interacción y menor probabilidad de respuesta positiva. Tanto el ACP como el clustering muestran que variables como previous, pdays y duration son fundamentales para distinguir perfiles de comportamiento. Del mismo modo, el ACM detecta asociaciones entre categorías relacionadas con el éxito previo de campañas y la respuesta positiva.

Otra coincidencia importante es la relevancia del contexto económico. En el ACP, variables como euribor3m, emp.var.rate y nr.employed dominan claramente la primera dimensión. Posteriormente, el clustering confirma que algunos grupos presentan valores económicos claramente diferenciados. El FAMD también recoge esta estructura, aunque de forma más distribuida debido a la combinación de información numérica y categórica.

Además, todos los métodos coinciden en que la mayoría de individuos presentan perfiles relativamente similares y cercanos al promedio, mientras que únicamente un grupo reducido de observaciones extremas es el que realmente define gran parte de la estructura de los datos.

Sin embargo, también aparecen diferencias importantes entre técnicas.

La principal diferencia es que el ACP muestra una estructura mucho más clara y estable que el ACM. En el ACP las dos primeras dimensiones consiguen explicar una parte importante de la variabilidad total y permiten interpretar fácilmente los ejes asociados al contexto económico y al historial de campañas. En cambio, en el ACM la varianza queda mucho más repartida y las categorías aparecen más dispersas, dificultando encontrar separaciones tan claras entre perfiles.

Otra diferencia importante aparece en la interpretación de los clústeres. En el clustering realizado únicamente sobre variables numéricas, las diferencias entre grupos estaban muy influenciadas por variables como la edad o ciertos indicadores económicos. Sin embargo, cuando se utiliza FAMD, los grupos pasan a estar más relacionados con el comportamiento frente a campañas anteriores y con variables categóricas como poutcome, contact o y. Esto hace que los clústeres obtenidos mediante FAMD resulten más interpretables desde el punto de vista del negocio.

También observamos diferencias en la separación de grupos. En el clustering jerárquico sobre FAMD aparece un clúster claramente separado del resto, mientras que los otros dos presentan bastante solapamiento. Esto sugiere que existe un perfil de cliente muy diferenciable, pero que gran parte de los clientes mantienen comportamientos relativamente parecidos entre sí.

Finalmente, los métodos discriminantes confirman que la mayor separación entre clientes se produce precisamente alrededor del clúster asociado a campañas exitosas. Tanto el LDA como el Random Forest consiguen clasificar este grupo con un error prácticamente nulo, reforzando la idea de que este perfil posee características muy diferenciadas respecto al resto de clientes.

En conjunto, aunque cada técnica enfatiza aspectos distintos de los datos, todas convergen en una conclusión común: el historial previo de interacción con el banco y el comportamiento frente a campañas anteriores son los factores que más diferencian a los clientes y los que mejor permiten identificar perfiles con mayor probabilidad de respuesta positiva.

Conclusiones generales

Los resultados obtenidos permiten concluir que el comportamiento previo de los clientes frente a campañas anteriores es el factor más determinante para explicar la respuesta positiva a una nueva campaña bancaria.

Las técnicas de reducción de dimensionalidad han mostrado que gran parte de la estructura de los datos puede resumirse mediante unas pocas dimensiones relacionadas principalmente con el historial de campañas previas, las condiciones económicas y el nivel de interacción del cliente con la entidad.

Por otra parte, los métodos de clustering han permitido identificar distintos perfiles de clientes, destacando especialmente un grupo claramente asociado a campañas exitosas y con elevada probabilidad de suscripción.

Además, los modelos discriminantes muestran que los grupos obtenidos no son aleatorios, sino que presentan diferencias reales y detectables. Esto refuerza la validez de la segmentación obtenida y su posible utilidad práctica dentro del contexto bancario.

En conjunto, el trabajo muestra cómo las técnicas multivariantes y de aprendizaje no supervisado permiten extraer patrones relevantes, simplificar datos complejos y construir perfiles de clientes útiles para la toma de decisiones.

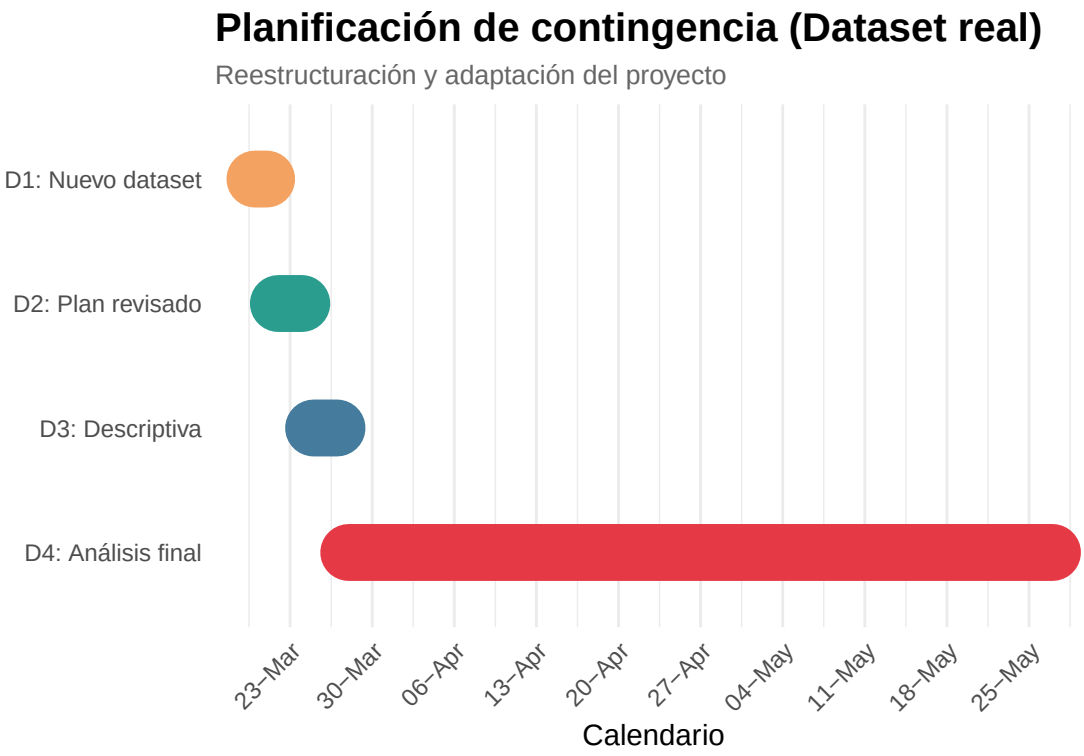
Una posible línea futura consistiría en estudiar la evolución temporal de las campañas, incorporando información longitudinal para analizar cómo cambia el comportamiento de los clientes a lo largo del tiempo.

Además, podría ampliarse el estudio incluyendo nuevas variables socioeconómicas o indicadores externos que ayuden a explicar mejor las diferencias entre clientes y el impacto del contexto económico sobre las campañas.

Finalmente, una aplicación especialmente interesante sería utilizar los perfiles obtenidos para diseñar campañas personalizadas y estrategias de segmentación comercial más eficientes, permitiendo optimizar recursos y aumentar la tasa de éxito de futuras campañas bancarias.

Plan de trabajo real

Durante la elaboración del trabajo hemos tenido diferentes contratiempos, los cuales han afectado al planteamiento inicial del proyecto. Durante la realización de la tercera entrega nos dimos cuenta de que el dataset escogido inicialmente era una simulación y que no se adaptaba a los requerimientos del proyecto. Por tanto, tuvimos que cambiar el conjunto de datos por el actual y volver a empezar gran parte del trabajo, por ello los plazos de entregas se ven relativamente alterados ya que fueron adaptados a este cambio.


Planificación de contingencia (Dataset real)
Reestructuración y adaptación del proyecto
D1: Nuevo dataset
D2: Plan revisado
D3: Descriptiva
D4: Análisis final
23–Mar
30–Mar
06–Apr
13–Apr
20–Apr
27–Apr
04–May
11–May
18–May
25–May
Calendario

Referencias

Moro, Sérgio, Paulo Cortez, and Paulo Rita. 2014. “A Data-Driven Approach to Predict the Success of Bank Telemarketing.” *Decision Support Systems*. https://doi.org/10.1016/j.dss.2014.03.001.

UCI Machine Learning Repository. 2012. “Bank Marketing Data Set.” https://archive.ics.uci.edu/ml/datasets/Bank+Marketing.